

Máster Universitario en Lógica, Computación en Inteligencia Artificial

Escuela Superior Técnica de Ingeniería Informática
Universidad de Sevilla

TRABAJO FIN DE MÁSTER

Cribado de cáncer de pulmón

Ramón Trinidad Acedo

Sevilla, Marzo de 2026

Tutor: Carlos Loucera Muñecas

Índice de Contenidos

Índice de Contenidos ..... **ii**
Índice de Figuras ..... **iii**
Índice de Tablas ..... **iv**
Agradecimientos ..... **v**
Resumen ..... **vi**
Abstract ..... **vii**
1 Capítulo 1 ..... **1**
1.1 Presentación de los datos 1
1.2 Selección de características 2
1.3 Ingeniería de características médicas 4
1.3.1 Atributos reveladores de cáncer de pulmón 4
1.3.2 Diagnósticos y procedimientos 4
1.3.2.1 Despliegue SNOMED Browser local 5
1.3.2.2 Extracción de ancestros 5
1.3.3 Medicamentos 5
1.4 Resultados de laboratorio 6
1.5 Modelos predictivos de aprendizaje automático. 7
1.5.1 Random Forest 7
1.5.2 Gradient Boosting 8
2 Capítulo 2. Resultados y Evaluación de Modelos **9**
2.1 Metodología y Búsqueda de Hiperparámetros (Tuning) 9
2.2 Rendimiento en el Conjunto de Test 9
A Apéndice A **12**
A.1 Atributos reveladores de cáncer de pulmón 12
Referencias **13**

Índice de Figuras

Figura 1 Curvas de evaluación del modelo logístico. 2
Figura 1a Curvas ROC en los conjuntos de train, test y validación. 2
Figura 1b Curvas PR para el modelo logístico 2
Figura 2 Rendimiento del modelo según el número de variables seleccionadas 3
Figura 3 Comparativa en test de los modelos propuestos PR-AUC y ROC-AUC. 10

Índice de Tablas

Tabla 1 «Reporte de clasificación del modelo logístico con pipeline inicial.» 2
Tabla 2 «Ejemplo de mapeo de RxNorm a ATC nivel 2.» 6
Tabla 3 «Métricas de evaluación comparativa en conjunto de test (datos no observados).» 10
Tabla A.1 «Variables y marcadores reveladores de estado oncológico eliminados para prevenir data leakage.» 12

Agradecimientos

Tus agradecimientos aquí

Resumen

Tu resumen aquí

Palabras clave: Palabra01, Palabra02

Abstract

Tu resumen en inglés aquí

Keywords: Word01, Word02

1
CAPÍTULO

Capítulo 1

Este primer capítulo aborda un cribado general con el objetivo de predecir indicios de cáncer de pulmón. Se trata de un estudio estático, con una base de datos puntual, es decir, no se implementarán modelos longitudinales en el tiempo, sino un corte transversal en el historial médico de los pacientes en el preciso momento de la toma de datos.

1.1 Presentación de los datos

Se introduce el conjunto de datos que se utilizará para este primer capítulo. Los datos provienen de la plataforma de datos sintéticos *Synthea*, y usaremos como referencia el estudio realizado en el artículo [1].

Como un primer aproach, realizaremos un preprocesamiento básico de los datos, imputando NAs y estandarizando las variables numéricas para el correcto funcionamiento de los algoritmos de aprendizaje automático. Para ello, creamos el siguiente pipeline de preprocesamiento y planteamiento de un modelo de regresión logística:

```
from sklearn.compose import make_column_selector, ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import OrdinalEncoder, StandardScaler
from sklearn.feature_selection import SelectKBest
from sklearn.impute import SimpleImputer


cat_pipeline = Pipeline([
    ("codif", OrdinalEncoder(handle_unknown='use_encoded_value',
unknown_value=-1)),
    ("imputer",SimpleImputer(strategy="constant",
fill_value=0.0,keep_empty_features=True)),
])

num_pipeline = Pipeline([
    ("imputer",SimpleImputer(strategy="constant",
fill_value=0.0,keep_empty_features=True)),
    ("scaler", StandardScaler())
])

preprocesamiento = ColumnTransformer([
    ("cat", cat_pipeline, make_column_selector(dtype_include="object")),
    ("num", num_pipeline,make_column_selector(dtype_exclude="object"))
], remainder=(SimpleImputer(strategy="constant", fill_value=0.0)),
verbose_feature_names_out=False)
```

```
seleccion = Pipeline([
    ("preprocesamiento", preprocesamiento),
    ("50mejores", SelectKBest(k=50)),
])

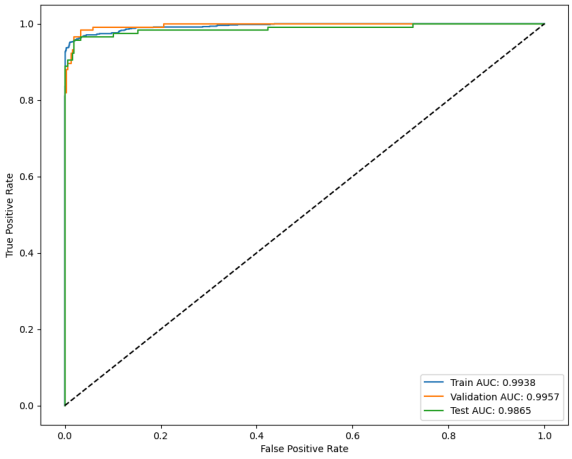
regresor = Pipeline([
    ("seleccion", seleccion),
    ("logistic_regression", LogisticRegressionCV(max_iter=1000,
n_jobs=-1,scoring="recall", cv=5,random_state=625)),
])
```

Este pipeline obtiene un rendimiento excelente en el conjunto de test:

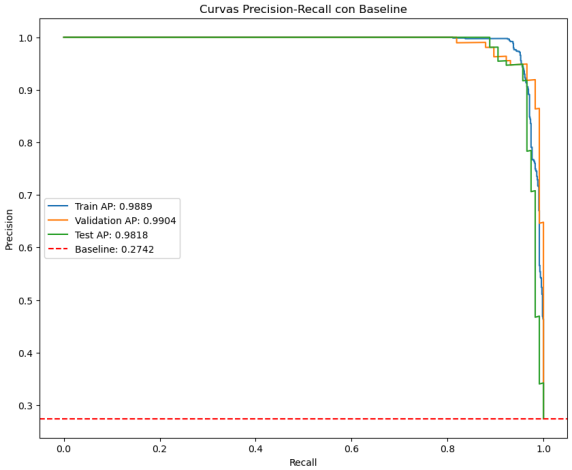
Tabla 1: «Reporte de clasificación del modelo logístico con pipeline inicial.»

Accuracy	Recall	F1	AUC
0.97	0.95	0.97	0.986

Y unas curvas ROC y PR:



(a) Curvas ROC en los conjuntos de train, test y validación.



(b) Curvas PR para el modelo logístico

Figura 1: Curvas de evaluación del modelo logístico.

1.2 Selección de características

En el anterior apartado hemos obtenido un rendimiento excelente en el conjunto de test con únicamente 50 variables del dataset original. Es lógico preguntarse, ¿cuántas variables son necesarias para obtener un rendimiento óptimo?. En esta sección se elabora un análisis del rendimiento del modelo aplicando técnicas de cross-validation anidado para obtener una estimación veraz del rendimiento del modelo, teniendo en cuenta tanto el sesgo como la varianza del modelo.

La idea es la siguiente: en lugar de realizar una única partición del conjunto de datos, se emplea una estrategia robusta denominada validación cruzada anidada (*Nested Cross-Validation*). En el bucle externo (`outer_cv`), se evalúa la capacidad de generalización dividiendo el conjunto de entrenamiento en 5 particiones estratificadas. A su vez, para cada una de estas iteraciones, se ejecuta un bucle interno (`inner_cv` con otras 5 particiones) mediante un ajustador paramétrico (`GridSearchCV`) encargado de encontrar los hiperparámetros óptimos. En este espacio de búsqueda se evalúa el rendimiento del *pipeline* iterando sobre el número de características seleccionadas ($k \in \{1, 3, 5, 10, 20, 50\}$) y penalizaciones de regularización matemática (C), usando el área bajo la curva exhaustiva (PR-AUC o `average_precision`) como métrica objetivo.

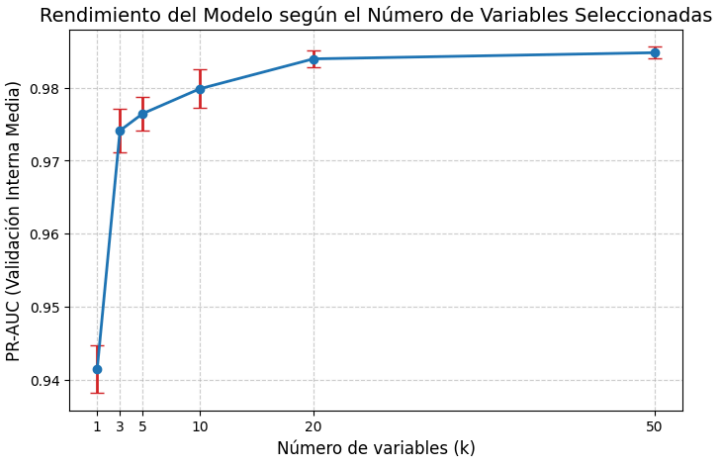


Figura 2: Rendimiento del modelo según el número de variables seleccionadas

1.3 Ingeniería de características médicas

En este apartado, vamos a adentrarnos en los sistemas de nomenclatura médicos estándar usados para la codificación de las variables del dataset. En primer lugar, se debe acceder al repositorio github del artículo y extraer la codificación de las variables. Se observan que todas las variables, excepto tres, empiezan con el prefijo «C-» y luego un número identificativo cuya nomenclatura dependerá del tipo de variable médico.

Principalmente, en el análisis de datos médicos solemos encontranos con cuatro tipos de variables:

- **Diagnósticos:** Se refiere al registro médico de enfermedades, signos o síntomas padecidos por el paciente a lo largo de su historia clínica. En nuestros datos, estas dolencias suelen mapearse utilizando **SNOMED-CT**[2].
- **Procedimientos:** Pruebas analíticas, estudios por imagen o intervenciones quirúrgicas solicitadas por el equipo médico a un paciente para la prevención, detección o tratamiento de diagnósticos y riesgos subyacentes. También se usa para estos el sistema SNOMED-CT.
- **Medicamentos:** Comprende el historial de fármacos y principios activos prescritos, dispensados o administrados al paciente con fines terapéuticos o paliativos. Se mapean mediante el vocabulario **RxNorm** [3]
- **Resultados de laboratorio:** Consiste en mediciones de laboratorio o evaluaciones fisiológicas (por ejemplo, analíticas de sangre o valores de presión). Estos resultados sirven como indicadores del estado biológico del modelo. En el dataset siguen la nomenclatura **LOINC** [4].

A continuación, declararemos el plan de ejecución según el sistema de nomenclatura para realizar una extracción de características adecuado al objetivo de nuestro análisis.

1.3.1 Atributos reveladores de cáncer de pulmón

El alto rendimiento del primer pipeline básico implementado anteriormente hace sospechar acerca de un problema de *data leakage* en el dataset inicial. Probablemente, entre las 765 variables predictoras de las que disponemos existan algunas de ellas que constituyan marcadores tumorales que pueden estar influyendo de manera crucial en el modelo pero que, sin embargo, no son marcadores habituales en la población general sino muestras de que un paciente ya está en altas sospechas o confirmación del tumor.

A simple vista, podemos detectar variables sospechosas como: `C-88040-1`: *Response to cancer treatment* o `C-59557-9`: *Treatment status Cancer*, que son marcadores tumorales del estado oncológico del paciente. Además, de estas variables evidentes, buscaremos en el análisis anterior las variables más extrañamente relevantes.

Los resultados de esta revisión se encuentran en el apendice

1.3.2 Diagnósticos y procedimientos

Para la estandarización de este tipo de variables, se emplea SNOMED-CT (*Systematized Nomenclature of Medicine – Clinical Terms*). Tal y como indica el Ministerio de Sanidad español [2], se trata de la terminología clínica de mayor amplitud y precisión a nivel global, cuyo propósito es permitir a los profesionales sanitarios codificar y comunicar información clínica de forma adecuada e inequívoca.

Las variables del dataset ya siguen esta nomenclatura, sin embargo, aprovecharemos la estructura jerárquica de SNOMED para elaborar agrupaciones ontológicas y conseguir de esta manera reducir la granularidad de la base de datos inicial.

1.3.2.1 Despliegue SNOMED Browser local

Inicialmente, se trató de interactuar con la API pública de SNOMED International [5] con consultas ECL con el objetivo de poder extraer la estructura de padres e hijos de un cierto diagnóstico. Por ejemplo, tener *anemia* (con código SNOMED 271737000), se situa en la estructura de SNOMED como descendiente de *trastorno de componente celular sanguíneo* (414022008), que a su vez es descendiente de *hallazgo relacionado con el sistema inmunitario, la sangre y los linfáticos* (299691001). Y todo esto es accesible mediante la consulta ECL: `>> 271737000 |anemia|`.

No obstante, durante este intento surgieron limitaciones debido al gran número de consultas que se debía realizar. Para superar estas limitaciones, se optó por desplegar una infraestructura propia de servidor terminológico. Se seleccionó **Snowstorm**, la implementación de referencia de código abierto mantenida por SNOMED International y se realizó mediante contenedorización con **Docker.**

La carga de la ontología médica se realizó mediante la importación de archivos *International Edition* de SNOMED CT, debido a que esta era la versión usada en nuestras variables iniciales. Se completó la indexación de conceptos con aproximadamente 526000 conceptos activos , relaciones y descripciones.

1.3.2.2 Extracción de ancestros

En este punto, se realiza el reconocimiento de los códigos SNOMED de las variables y las consultas de ancestros de estos códigos para su agrupación por ontología médica. La metodología seguida fue la siguiente:

- Los diagnósticos, divididos en *disorder* y *finding* en la nomenclatura SNOMED se sometieron al proceso de análisis de ancestros con la heurística de agrupar unicamente las enfermedades poco frecuentes en nuestros datos. Además, se eliminaron las variables con más de un 99% de los registros nulos. El resultado obtenido fue: de las 178 variables iniciales de *disorder* y *finding* se redujo hasta unas 90 variables más generales.
- Los procedimientos, comprendidos en SNOMED por las categorías *procedure* y también *therapy* fueron sometidos al mismo proceso, teniendo en este caso como resultado la reducción del número de variables de 186 a 123.
- El resto es una mezcla de variables sociodemográficas, situaciones sociales o atributos relevantes no incluidos en los grupos anteriores. Este grupo aporta 14 variables.

1.3.3 Medicamentos

Originalmente aparecen codificados en RxNorm. Desarrollado por la Biblioteca Nacional de Medicina de EE. UU. (NLM), esta es una nomenclatura terminológica que normaliza los nombres de los medicamentos clínicos y presentan una granularidad profunda (una variable por principio activo). [3]

Nuestro objetivo fue reducir la granularidad y agrupar medicamentos por zona y efecto. Para ello, realizamos un mapeo de RxNorm a ATC. La nomenclatura RxNorm está pensada para logística y prescripción, por lo que su alta especifidad es innecesaria para un análisis estadístico y puede llegar a generar demasiado ruido. El sistema ATC (Anatomical Therapeutic Chemical) es mantenido por la Organización Mundial de la Salud (OMS) [6]. A diferencia de RxNorm, que se centra en el principio activo y la receta exacta, el ATC organiza los fármacos según dónde actuan y qué hacen. Además, la codificación ATC presenta niveles de especifidad del 1 al 5 siendo el nivel 5 el nivel más específico (principio activo) y el 1 la zona del cuerpo a la que afectan, por lo que nos permite escoger el nivel de granularidad que deseemos.

En este caso, se realizó el mapeo de los principios activos de RxNorm a ATC nivel 5 y después se generalizó, agrupando con códigos ATC nivel 2. A continuación se muestra el ejemplo:

Tabla 2: «Ejemplo de mapeo de RxNorm a ATC nivel 2.»

RxNorm	Nombre RxNorm	ATC nivel 5	ATC nivel 2	Nombre ATC nivel 2
562251	Amoxicillin 250 MG / Clavulanate 125 MG Oral Tablet	J01CR02	J01	Antibacterianos para uso sistémico

Finalmente, se redujo en número de medicamentos de 200 principios activos iniciales a 43 variables interpretables y con sentido clínico para nuestro análisis.

1.4 Resultados de laboratorio

Estas variables están codificadas según la nomenclatura LOINC, que es el estándar internacional para la identificación de mediciones de salud, observaciones clínicas y documentos [4].

De todas las incluidas originalmente, haremos una selección de las más comunes para el análisis.

1.5 Modelos predictivos de aprendizaje automático.

El proyecto que plantamos se enmarca en el mundo de la inteligencia artificial y el aprendizaje automático como un problema de aprendizaje supervisado, donde tenemos un conjunto de datos con variables predictoras y una variable objetivo, y queremos entrenar un modelo que pueda predecir la variable objetivo a partir de las variables predictoras. En nuestro caso, la variable objetivo es el diagnóstico de cáncer de pulmón, y las variables predictoras son el resto de variables del dataset.

Para la realización del aproach inicial recurrimos a uno de los modelos más tradicionales en el mundo del aprendizaje automático, la regresión logística. Este modelo es un modelo lineal, es decir, se trata de modelar la variable objetivo en base a una combinación lineal de características. A pesar de su simplicidad, es un modelo efectivo que puede ser utilizado como línea base para comparar con otros modelos más complejos.

Nuestro objetivo ahora es aumentar la complejidad y trabajar con algoritmos más sofisticados, que puedan extraer información más completa de los datos (relaciones no lineales, interacciones complejas, etc.) y que nos permitan obtener mejores resultados. A continuación se describen con detalle los algoritmos que se usan en este proyecto. Principalmente, introduciremos métodos basados en árboles. Estos algoritmos nacen de aplicar a un conjunto de árboles de decisión distintos métodos de ensamblaje. Dependiendo del tipo de ensamblaje tenemos:

- Bagging: Se basa en la idea de usar un predictor determinado sobre distintos subconjuntos de datos del conjunto de entrenamiento elegidos muestra a muestra con reemplazamiento. Gracias a esto, el modelo predictivo final es más robusto ante el sobreajuste, ya que pierde la dependencia excesiva de los modelos al conjunto de entrenamiento.
- Boosting: se refiere a cualquier método de ensamblaje que combine una serie de aprendices débiles para conformar un modelo predictivo más complejo y potente.

1.5.1 Random Forest

Es un método de ensamblaje de árboles de decisión entrenado con la metodología bagging. Se basa en la generación de un gran número de árboles en una muestra *bootstrap*.

Consiste en aplicar secuencialmente el siguiente algoritmo,

1. Tomar $B = 500, 1000, \ldots$ Desde $b = 1$ hasta B
    1. Generar una muestra con reposición del mismo tamaño que la muestra de aprendizaje (muestra bootstrap)
    2. Construir un árbol T_b en la muestra anterior repitiendo recursivamente los siguientes pasos hasta que cada nodo terminal del árbol alcance un número mínimo κ_0 de registros:
        1. Generar una muestra aleatoria simple sin reposición de $\tilde{m}$ variables de las r totales.
        2. Seleccionar la mejor variable entre las $\tilde{m}$ escogidas y el corte que minimice la impureza.
        3. Ramificar el nodo en sus dos nodos hijos
2. Para hacer predicciones sobre nuevos puntos x, consideramos la media de las predicciones de los distintos árboles.

$$\hat{f}_{rf}^{B} = \frac{1}{B}\sum_{b=1}^{B} T_b(x)$$

Se observa que la muestra generada para la construcción de los árboles de regresión de los Bosques Aleatorios se considera con reposición, esto quiere decir que podemos encontramos el mismo registro varias veces y a su vez, registros de la muestra de aprendizaje que no aparezcan en la muestra usada

por el árbol. Estos últimos se conocen como registros *fuera de la bolsa* y nos pueden ser útiles como muestra independiente para estimar el error de predicción del bosque $\frac{1}{B}\sum_b e(T_b)$, siendo

$$e(T_b) = \frac{1}{T}\sum_{t=1}^{T}(y_t - T_b(x_t))^2$$

Luego gracias a los registros fuera de bolsa se construye el estimador de error de predicción del bosque $\frac{1}{B}\sum_b \widehat{e(T_b)}$ mediante el estimador del error de predicción de cada árbol,

$$\widehat{e(T_b)} = \frac{1}{U}\sum_{i=1}^{U}(y_i - T_b(x_i))^2$$

con U el número de elementos en la muestra fuera de bolsa.

1.5.2 Gradient Boosting

2
CAPÍTULO

Capítulo 2. Resultados y Evaluación de Modelos

En este capítulo se detallan los resultados obtenidos tras el preprocesamiento de los distintos conjuntos de datos (diagnósticos clínicos, procedimientos, histórico de medicamentos y pruebas de laboratorio) y el posterior entrenamiento y evaluación de diversos algoritmos de *Machine Learning*. El objetivo principal de esta fase experimental ha sido encontrar el modelo más preciso y robusto para la predicción de cáncer de pulmón, basándose puramente en indicadores clínicos estructurados.

2.1 Metodología y Búsqueda de Hiperparámetros (Tuning)

Previo a la evaluación final, se ejecutó un proceso sistemático para optimizar los hiperparámetros de diferentes familias de algoritmos y determinar su configuración con mayor capacidad predictiva. Esta validación se realizó aplicando validación cruzada estratificada con 5 particiones (5-Fold Cross-Validation), empleando como métrica de optimización principal el `f1_weighted`. Elegir esta métrica asegura un buen balance penalizando correctamente predicciones desproporcionadas entre clases.

Se evaluaron e iteraron combinaciones para cuatro tipos de modelos:

- **Random Forest**: Se evaluaron 36 combinaciones ajustando el número de árboles estimadores, la profundidad máxima, el mínimo de muestras para la partición y la selección de características.
- **SVM (Máquinas de Vectores de Soporte)**: Se evaluaron 16 combinaciones explorando el parámetro de regularización matemática C, tipos de kernel y su grado.
- **XGBoost (Extreme Gradient Boosting)**: Evaluado mediante 432 combinaciones. Las pruebas abarcaron alteraciones sobre la ratio de aprendizaje (*learning rate*), reguladores de penalización L1 (`reg_alpha`) y L2 (`reg_lambda`), profundidad de los árboles y porcentajes de submuestreo.
- **MLPClassifier (Red Neuronal Multicapa)**: Dos combinaciones con topología predefinida y variaciones en la tasa de aprendizaje adaptativa.

2.2 Rendimiento en el Conjunto de Test

Con las configuraciones óptimas descubiertas, los modelos fueron entrenados de forma final y desplegados sobre un conjunto de test independiente, un entorno de simulación equivalente a operar con datos clínicos nunca antes vistos por el sistema.

A las las métricas críticas evaluadas (F1-score, Precision y Recall) fueron añadidas nuevas métricas sobre las probabilidades del modelo, como el Área bajo la Curva Operativa del Receptor (ROC-AUC) y el Área Bajo la Curva de Precisión Exhaustiva (PR-AUC).

Tabla 3: «Métricas de evaluación comparativa en conjunto de test (datos no observados).»

Modelo	F1-Score	Precision	Recall	ROC-AUC	PR-AUC
Random Forest	0.8535	0.8525	0.8558	0.9206	0.8228
XGBoost	0.8526	0.8520	0.8534	0.9235	0.8245
MLPClassifier	0.8494	0.8491	0.8534	0.9330	0.8334
SVM	0.8325	0.8422	0.8440	0.9125	0.8092

Los resultados confirman que **Random Forest** y **XGBoost** poseen la mayor solidez algorítmica para discriminar diagnósticos bajo la perspectiva conjunta de *F1-Score*, superando ligeramente el umbral del 0.85. Sin embargo, en el apartado probabilístico para separabilidad de rangos estocásticos, la red neuronal densa (**MLPClassifier**) destaca situando el **ROC-AUC** en el rango de 0.9330.

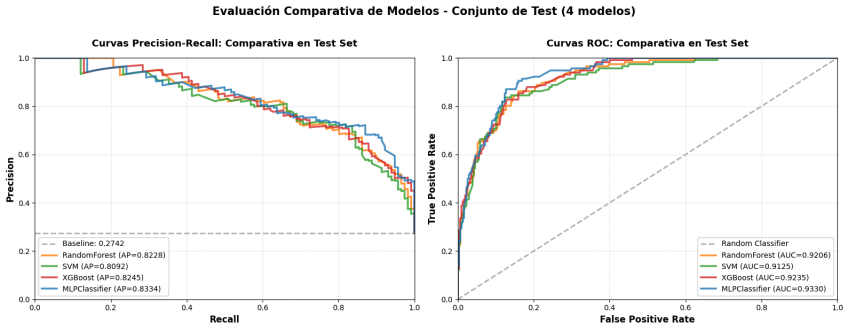


Figura 3: Comparativa en test de los modelos propuestos PR-AUC y ROC-AUC.

Apéndice

A
Apéndice

Apéndice A

A.1 Atributos reveladores de cáncer de pulmón

Tabla A.1: «Variables y marcadores reveladores de estado oncológico eliminados para prevenir data leakage.»

Código	Descripción
C-33756-8	Polyp size greatest dimension by CAP cancer protocols
C-88040-1	Response to cancer treatment
C-59557-9	Treatment status Cancer
C-21908-9	Stage group.clinical Cancer
C-85318-4	HER2 [Presence] in Breast cancer specimen by FISH
C-85319-2	HER2 [Presence] in Breast cancer specimen by Immune stain
C-85337-4	Estrogen receptor Ag [Presence] in Breast cancer specimen by Immune stain
C-85339-0	Progesterone receptor Ag [Presence] in Breast cancer specimen by Immune stain
C-21924-6	Tumor marker Cancer
C-367336001	Chemotherapy (procedure)
C-703423002	Combined chemotherapy and radiation therapy
C-108290001	Radiation oncology AND/OR radiotherapy
C-385798007	Radiation therapy care
C-597195	Carboplatin 10 MG/ML Injectable Solution
C-583214	Paclitaxel 100 MG Injection
C-1860480	DOCEtaxel 20 MG/ML Injection
C-1734919	Cyclophosphamide 1000 MG Injection
C-429609002	Lung volume reduction surgery
C-88039007	Transplant of lung
C-232657004	Lung Transplant
scc	Squamous Cell Carcinoma Antigen

Referencias

[1] A. Chen y D. O. Chen, «Simulation of a machine learning enabled learning health system for risk prediction using synthetic patient data», *Scientific Reports*, vol. 12, n.º 1, p. 17917, 2022.

[2] Ministerio de Sanidad, «Definición de SNOMED CT». Accedido: 5 de marzo de 2026. [En línea]. Disponible en: https://www.sanidad.gob.es/areas/saludDigital/interoperabilidadSemantica/factoriaRecursos/snomedCT/home.htm

[3] RxNorm, Accedido: 4 de marzo de 2026. [En línea]. Disponible en: https://www.nlm.nih.gov/research/umls/rxnorm/index.html

[4] LOINC, Accedido: 4 de marzo de 2026. [En línea]. Disponible en: https://loinc.org/

[5] SNOMED International, «SNOMED CT Browser». Accedido: 5 de marzo de 2026. [En línea]. Disponible en: https://browser.ihtsdotools.org/?perspective=full&conceptId1=404684003&edition=MAIN/SNOMEDCT-ES/2026-02-10&release=&languages=es,en

[6] Vademecum, «Clasificación ATC». Accedido: 5 de marzo de 2026. [En línea]. Disponible en: https://www.vademecum.es/atc