

Máster Universitario en Lógica, Computación en Inteligencia Artificial

Escuela Superior Técnica de Ingeniería Informática
Universidad de Sevilla

TRABAJO FIN DE MÁSTER

Cribado de cáncer de pulmón

Ramón Trinidad Acedo

Sevilla, Julio de 2026

Tutor: Carlos Loucera Muñecas

Índice de Contenidos

Índice de Contenidos ..... **ii**
Índice de Figuras ..... **v**
Índice de Tablas ..... **vi**
Agradecimientos ..... **vii**
Resumen ..... **viii**
Abstract ..... **ix**
1 Introducción **1**
1.1 Motivación clínica: cáncer de pulmón y detección precoz 1
1.2 Del cribado por criterios de elegibilidad al riesgo individualizado 2
1.3 Estado del arte 2
1.3.1 Modelos de riesgo: PLCOm2012 y criterios USPSTF 2
1.3.2 Aprendizaje profundo sobre series clínicas irregulares 2
1.3.3 Análisis de supervivencia con redes neuronales 3
1.3.4 Proyecto CASSANDRA: cribado de cáncer de pulmón con TCBD 3
1.4 Objetivos 3
1.5 Contribuciones 4
1.6 Estructura de la memoria 4
2 Materiales **5**
2.1 Synthea: generación sintética y alcance de las conclusiones 5
2.2 Fuentes crudas: pacientes, condiciones y observaciones 5
2.3 Pools discovery y holdout 6
2.4 Definición de la cohorte: criterios de entrada, evento y censura 6
2.5 Vocabularios: LOINC y mapeo de SNOMED a ICD-10-CM 7
2.6 Entorno computacional y pipeline reproducible 9
2.6.1 Las tres etapas del grafo 10
2.6.2 Configuración declarativa: añadir un modelo es editar YAML 10
2.6.3 Entorno y ejecución 11
3 Métodos **12**
3.1 Marco de supervivencia 12
3.1.1 Tiempo hasta evento, censura y riesgos competitivos 12
3.1.2 El modelo de Cox y la verosimilitud parcial 13
3.1.3 Riesgo basal de Breslow y probabilidad a horizonte 14
3.1.4 Landmarking: predicción a edad fija, ventana de cinco años y anidamiento de cohortes 14
3.2 Descripción de la cohorte y de las secuencias 15
3.2.1 Variables y estadísticos de la tabla de características 15
3.2.2 Medidas de dispersión, co-ocurrencia y muestreo informativo 15
3.3 Representación de los datos 16
3.3.1 Secuencias irregulares con códigos ICD-10-CM 16
3.3.2 Tripletas (t, f, v) frente a matriz densa 16
3.3.3 Fuga de información: eliminación de variables reveladoras 17
3.4 Modelos 17
3.4.1 Línea base tabular: Cox con LOCF 17
3.4.2 Procesamiento secuencial y RNN básicas 18
3.4.3 LSTM 19

3.4.4 GRU y GRU-D 20
3.4.5 STraTS: Transformer sobre tripletas de observación 20
3.5 Protocolo experimental 22
3.5.1 Partición por paciente, sobremuestreo de eventos y parada temprana 22
3.5.2 Ablación de códigos ICD-10-CM 22
3.5.3 Presupuesto de entrenamiento e hiperparámetros 22
3.6 Evaluación 23
3.6.1 Discriminación: el C-index de Harrell y su falta de horizonte 24
3.6.2 AUROC dependiente del tiempo a cinco años 24
3.6.3 Ponderación IPCW y el C-index de Uno 24
3.6.4 Brier IPCW e IPA frente al modelo nulo 25
3.6.5 Intervalos de confianza por bootstrap a nivel de paciente 25
3.6.6 Agregación sobre landmarks anidados: estimando agrupado y cluster bootstrap 26
4 Resultados 27
4.1 Características de la cohorte 27
4.2 Caracterización de las secuencias 28
4.2.1 Lo que ve el modelo en cada corte 28
4.2.2 Muestreo informativo 29
4.2.3 Densidad de observación 30
4.2.4 Magnitudes y normalización 31
4.3 Discriminación por landmark 32
4.4 Utilidad frente al modelo nulo 33
4.5 Resumen agregado por modelo 34
4.6 Ablación de códigos ICD-10-CM 35
4.7 Coste computacional 36
5 Discusión 37
5.1 Análisis de la cohorte 37
5.1.1 Por qué la rejilla va de 45 a 70 años 37
5.1.2 Lo que el modelo ve y con qué frecuencia se mide 37
5.2 Qué diferencias soporta la evidencia y cuáles no 38
5.3 Horizonte frente a orden global 38
5.4 El tramo en torno al landmark 60 39
5.5 Qué aportan realmente los diagnósticos 39
6 Limitaciones y trabajo futuro 40
6.1 Límites del contrato común de encoder ante arquitecturas no recurrentes 40
6.2 Límites del dato sintético 40
6.3 Amenazas a la validez 41
6.3.1 Riesgos competitivos tratados como censura independiente 41
6.3.2 Una sola semilla por modelo 41
6.3.3 Ausencia de línea base clínica y de validación externa 41
6.3.4 STraTS sin preentrenamiento autosupervisado 41
6.4 Trabajo futuro 42
7 Conclusiones 43
7.1 Cierre de objetivos 43
7.2 Reflexión final 43
A Modelo predictivo estático sobre corte transversal 45
A.1 Presentación de los datos 45
A.2 Selección de características 46

A.3 Ingeniería de características médicas 48
A.3.1 Atributos reveladores de cáncer de pulmón 48
A.3.2 Diagnósticos y procedimientos 48
A.3.2.1 Despliegue SNOMED Browser local 49
A.3.2.2 Extracción de ancestros 49
A.3.2.3 Referencias cruzadas con nomenclatura CIE-10 diagnósticos 49
A.3.3 Medicamentos 49
A.4 Resultados de laboratorio 50
A.5 Modelos predictivos de aprendizaje automático. 51
A.5.1 Random Forest 51
A.5.2 Gradient Boosting 52
B Resultados y evaluación del modelo estático 53
B.1 Modelo tras ingeniería de características. 53
B.2 Modelo solo con variables de laboratorio. 54
B.2.1 Metodología y Búsqueda de Hiperparámetros (Tuning) 54
B.2.2 Rendimiento en el Conjunto de Test 54
B.3 Modelo solo con variables de CIE-10 diagnósticos. 55
B.3.1 Análisis explaratorio de variables 55
B.3.2 Metodología y Búsqueda de Hiperparámetros (Tuning) 55
B.3.3 Rendimiento en el Conjunto de Test 55
B.4 Evaluación del modelo en nuevas cohortes 55
C Atributos reveladores de cáncer de pulmón 56
C.1 Variables eliminadas por riesgo de data leakage 56
Referencias 58

Índice de Figuras

Figura 1 Grafo de reglas del pipeline: dependencias entre las nueve reglas de Snakemake. 10
Figura 2 Esquema de una celda recurrente, con la entrada del instante, el estado anterior y la salida. 18
Figura 3 La misma celda desplegada en el tiempo. El despliegue es una forma de ver el cálculo, no una red distinta. 19
Figura 4 Incidencia acumulada de diagnóstico por split, con intervalo de confianza al 95 %. 28
Figura 5 Muestras por corte, proporción sin analítica previa y magnitudes disponibles cuando hay datos. 29
Figura 6 Tasa de visitas con analítica por año de seguimiento en los pacientes sin evento y con evento. 30
Figura 7 Analíticas por visita, presencia de cada analítica en pacientes y en visitas, e intensidad por banda de edad. 31
Figura 8 Distribución de los valores estandarizados observados por analítica, con los límites de ±5. 32
Figura 9 C-index IPCW (Uno) por edad de landmark en holdout, con intervalo de confianza al 95 % por bootstrap de paciente. 33
Figura 10 Brier IPCW a cinco años por landmark en holdout. 34
Figura 11 Índice de precisión (IPA) a cinco años por landmark en holdout, con la línea del modelo nulo en cero. 34
Figura 12 Riesgo de cáncer de pulmón a cinco años por landmark en holdout. Discriminación (A), utilidad frente al modelo nulo (B) y resumen agrupado (C). 35
Figura A.1 Curvas de evaluación del modelo logístico. 46
Figura 1a Curvas ROC en los conjuntos de train, test y validación. 46
Figura 1b Curvas PR para el modelo logístico 46
Figura A.2 47

Índice de Tablas

Tabla 1 «Distribución por estadio al diagnóstico y supervivencia relativa a cinco años en cáncer de pulmón y bronquios (SEER 21, 2016-2022, ambos sexos).» 1
Tabla 2 «Filas de los ficheros crudos de cada pool (cabecera excluida), y tamaño comprimido del conjunto.» 6
Tabla 3 «Pacientes y eventos por pool y por split.» 6
Tabla 4 «Conceptos SNOMED CT que definen el evento, con la descripción oficial de SNOMED CT International Edition (2025-02-01) [1].» 7
Tabla 5 «Los 23 códigos LOINC que entran al modelo, con su denominación oficial y el grupo al que pertenecen [2].» 8
Tabla 6 «Parámetros entrenables por modelo, contados sobre los artefactos entrenados. En Cox el número es por landmark, porque se ajusta un modelo distinto en cada corte.» 21
Tabla 7 «Configuración de cada modelo. Las filas idénticas en las cinco columnas forman el presupuesto común, y las diferencias se deben a la arquitectura.» 23
Tabla 8 «Composición de la cohorte por split. El seguimiento se mide desde la fecha índice (18 años) y los pacientes sin evento quedan censurados.» 27
Tabla 9 «C-index IPCW (Uno) en holdout en los extremos de la rejilla de landmarks.» 33
Tabla 10 «Estimandos agrupados en holdout con intervalo de confianza al 95 % por cluster bootstrap. En Brier IPCW el valor bajo es el mejor.» 35
Tabla 11 «Ablación de los códigos de diagnóstico: mismas arquitectura e hiperparámetros, con y sin el bloque ICD-10-CM.» 36
Tabla 12 «Duración de cada regla en la ejecución final. Los entrenamientos y las evaluaciones se lanzaron en paralelo, de modo que sus tiempos se solapan y no son aditivos.» 36
Tabla A.1 «Reporte de clasificación del modelo logístico con pipeline inicial.» 46
Tabla A.2 «Ejemplo de mapeo de RxNorm a ATC nivel 2.» 50
Tabla A.3 «Métricas de evaluación en modelo tras ingeniería de características completo en conjunto de test.» 53
Tabla A.4 «Top 5 variables más importantes del modelo tras ingeniería de características.» 54
Tabla A.5 «Métricas de evaluación en conjunto de test del modelo con variables de laboratorio.» . 54
Tabla A.6 «Métricas de evaluación en conjunto de test del modelo con variables de CIE-10.» 55
Tabla A.7 «Variables y marcadores reveladores de estado oncológico eliminados para prevenir data leakage.» 57

Agradecimientos

Tus agradecimientos aquí

Resumen

El cribado del cáncer de pulmón consiste en decidir a quién se le hace una prueba antes de que aparezcan síntomas, y esa decisión se apoya cada vez más en modelos de riesgo construidos sobre la historia clínica. Esta memoria compara cinco de ellos sobre una cohorte sintética de Synthea: un modelo de Cox con la última observación arrastrada, una LSTM, dos GRU-D que se distinguen por recibir o no los códigos de diagnóstico, y una adaptación del transformer STraTS. Los cinco comparten cohorte, representación, 26 puntos de corte entre los 45 y los 70 años y un horizonte de predicción de cinco años, y se evalúan en un pool de holdout con C-index IPCW, AUROC a horizonte, Brier IPCW e índice de precisión, todos con intervalos por bootstrap agrupado a nivel de paciente. Los cuatro modelos secuenciales se agrupan entre 0,902 y 0,934 de AUROC y entre 0,769 y 0,804 de C--index IPCW, y todos baten al modelo nulo. Cox se queda en 0,758 de AUROC aunque su C-index sea comparable al de los demás, lo que muestra que ordena a los pacientes sin llegar a calibrar el riesgo a cinco años. La discriminación no separa a los secuenciales entre sí, y donde la evidencia separa es en el índice de precisión, con STraTS y la LSTM por encima de los dos GRU-D. La ablación de los códigos de diagnóstico no cambia las cifras de forma concluyente. El análisis exploratorio explica parte del resultado. El 79 % de las muestras no tiene ninguna analítica anterior al corte, la secuencia se trunca a 200 posiciones, lo que penaliza más al transformer que a los modelos recurrentes. La conclusión es que el protocolo pesa más que la arquitectura, y que estas cifras describen un generador y no una población real.

Palabras clave: cribado de cáncer de pulmón, series temporales irregulares, análisis de supervivencia, transformers, GRU-D

Abstract

Lung cancer screening comes down to deciding who gets a test before symptoms appear, and that decision relies increasingly on risk models built from the clinical history. This thesis compares five of them on a synthetic cohort from Synthea: a Cox model with last observation carried forward, an LSTM, two GRU-D models that differ only in whether they receive diagnosis codes, and an adaptation of the STraTS transformer. All five share the cohort, the representation, 26 cut-off points between ages 45 and 70 and a five-year prediction horizon, and are evaluated on a holdout pool with IPCW C-index, time-dependent AUROC, IPCW Brier and the index of prediction accuracy, each with patient--level cluster bootstrap intervals. The four sequential models fall between 0.902 and 0.934 AUROC and between 0.769 and 0.804 IPCW C-index, and all of them beat the null model. Cox stays at 0.758 AUROC although its C-index is comparable, which shows that it ranks patients without calibrating the five-year risk. Discrimination does not separate the sequential models from one another, and the evidence separates them on the index of prediction accuracy, where STraTS and the LSTM sit above both GRU-D models. Ablating the diagnosis codes does not change the figures conclusively. The exploratory analysis accounts for part of the result. Seventy-nine per cent of the samples have no laboratory measurement before the cut-off, sequences are truncated at 200 positions, which penalises the transformer more than the recurrent models. The conclusion is that the protocol weighs more than the architecture, and that these figures describe a generator rather than a real population.

Keywords: lung cancer screening, irregular time series, survival analysis, transformers, GRU-D

CAPÍTULO 1

Introducción

Detectar un tumor de pulmón antes de que dé síntomas exige saber a quién buscar. Durante años la respuesta fueron los criterios de elegibilidad, construidos sobre la edad y el hábito tabáquico, y en la última década esa respuesta se ha desplazado hacia modelos que estiman el riesgo individual con la historia clínica del paciente. La pregunta que queda abierta es qué arquitectura conviene para leer esa historia cuando llega de forma irregular y con huecos.

1.1 Motivación clínica: cáncer de pulmón y detección precoz

El cáncer de pulmón es el tumor más diagnosticado en el mundo y la primera causa de muerte por cáncer. En 2024 se estimaron 2 637 005 casos nuevos, los diagnosticados en ese año, y 1 861 839 muertes, que suponen respectivamente el 12,8 % y el 19,1 % de todos los cánceres diagnosticados y de todas las muertes por cáncer [3].

En España la incidencia es algo menor: el cáncer de pulmón representa el 11,6 % de los tumores diagnosticados en 2026, con 34 908 casos [4]. La mortalidad, en cambio, es mayor, y concentra el 20 % de las muertes por cáncer, una cada 20 minutos [5], [6].

El pronóstico depende del estadio en que se detecta el tumor (Tabla 1) [7].

Tabla 1: «Distribución por estadio al diagnóstico y supervivencia relativa a cinco años en cáncer de pulmón y bronquios (SEER 21, 2016-2022, ambos sexos).»

Estadio al diagnóstico	Casos	Supervivencia relativa a 5 años
Localizado (restringido al órgano primario)	24 %	65,5 %
Regional (con afectación de los ganglios regionales)	21 %	38,2 %
Distante (con metástasis)	51 %	10,5 %
Desconocido (sin estadificación)	4 %	17,5 %

Para el conjunto de los estadios, la supervivencia relativa a cinco años es del 29,5 %.

El cribado persigue adelantar el diagnóstico, y dos ensayos aleatorizados han medido su efecto en población de alto riesgo. El primero es el NLST (*National Lung Screening Trial*), un ensayo estadounidense con 53 454 participantes: tres rondas anuales de tomografía computarizada de baja dosis (TCBD) en lugar de radiografía de tórax redujeron la mortalidad por cáncer de pulmón un 20,0 % (IC 95 %: 6,8-26,7) [8]. El segundo es el NELSON, un ensayo de los Países Bajos y Bélgica con 15 789 participantes, en el que el cribado por volumen dio un cociente de tasas de mortalidad a diez años de 0,76 en hombres y de 0,67 en mujeres [9].

En este contexto, una detección temprana es clave para mejorar la supervivencia y resulta decisiva en el pronóstico y la vida del paciente.

1.2 Del cribado por criterios de elegibilidad al riesgo individualizado

Tradicionalmente, el cribado mediante TCBD se selecciona con dos criterios de elegibilidad, estar en una determinada franja de edad y superar un umbral de consumo de tabaco (paquetes-año) [10]. Son fáciles de aplicar, porque solo necesitan dos datos que ya constan en la historia clínica. No obstante, identifican a la población por su exposición histórica al tabaco, no por su probabilidad estimada de desarrollar el tumor. Además, son reglas estáticas, fijas, que no tienen en cuenta el resto de factores de riesgo ni la dinámica temporal de estos.

El desajuste entre ambas cosas es medible. De 345 pacientes operados de cáncer de pulmón en un centro, solo el 19 % habría cumplido los criterios vigentes, y entre los no elegibles más de la mitad nunca había fumado [11]. Es más, en una cohorte de 883 casos, los criterios que estuvieron en vigor hasta 2021 solo habrían seleccionado al 46,7 % de las mujeres y al 64,6 % de los hombres que desarrollaron el tumor [12]. Un criterio mal elegido deja fuera a quien habría que cribar y gasta pruebas en quien no las necesita.

Una estimación de riesgo por paciente sustituye la regla fija por una probabilidad individual y la hace evaluable. La cuestión que este trabajo añade es temporal. La mayoría de estos modelos son estáticos, una foto del paciente en un instante, mientras que su historia clínica se acumula de forma irregular durante décadas. Estimar el riesgo a partir de esa trayectoria, y no de un corte único, es el hueco que aborda esta memoria.

1.3 Estado del arte

1.3.1 Modelos de riesgo: PLCOm2012 y criterios USPSTF

Para pasar de los criterios a una probabilidad individual existen modelos de riesgo consolidados. El más citado en cribado de pulmón es PLCOm2012 [13], un modelo estadístico que estima la probabilidad de que a una persona se le diagnostique un cáncer de pulmón en los próximos seis años. Se apoya en once variables, entre ellas la edad, el nivel educativo, el índice de masa corporal, los antecedentes de enfermedad pulmonar obstructiva crónica, la historia familiar de cáncer de pulmón y el patrón de consumo (intensidad, duración y años desde el abandono), pero no en los paquetes-año. Se ajustó y se comprobó con los 80 375 fumadores y exfumadores de un ensayo de cribado estadounidense, el PLCO (*Prostate, Lung, Colorectal and Ovarian Cancer Screening Trial*). Según el propio estudio, la discriminación alcanzada fue de 0,803 (IC 95 %: 0,782-0,813) sobre los datos de ajuste y de 0,797 en los de comprobación, y con el mismo número de cribados su sensibilidad fue del 83,0 % frente al 71,1 % de los criterios del NLST.

En paralelo, las guías estadounidenses fijan quién debe cribarse. La recomendación vigente de la *US Preventive Services Task Force*, de 2021 y con grado B, propone cribado anual con TCBD para adultos de 50 a 80 años con al menos 20 paquetes-año que fumen o hayan dejado de fumar en los últimos 15 años [10]. Son criterios más amplios que los de 2013, pero siguen siendo reglas de elegibilidad.

Tanto PLCOm2012 como los criterios USPSTF usan variables explicativas fijas, medidas en un único instante. La probabilidad individualizada, en cambio, es una función de una historia clínica que se actualiza con cada consulta y cada analítica.

1.3.2 Aprendizaje profundo sobre series clínicas irregulares

Una historia clínica electrónica no es una serie temporal regular. Las variables se registran en instantes distintos (en una visita hay tensión y hemograma; en la siguiente, solo tensión), y en general la ausencia de un dato es también informativa. Que a un paciente se le pidan ciertas analíticas dice algo sobre su estado, aunque el valor falte. Che et al. (2018) lo llaman *informative missingness* y lo ilustran con el caso clínico habitual: en una unidad de cuidados intensivos la frecuencia cardíaca se monitoriza de forma

continua, mientras que el lactato se mide de forma esporádica. Si se imputa el hueco con la media, se ignora esa diferencia [14].

La forma de representar estos datos separa a los modelos. Una opción es la matriz densa, un vector de valores por visita, una máscara que indica qué se midió y un delta con el tiempo transcurrido desde la última observación. Es la representación de los modelos recurrentes, y GRU-D la usa para decaer la última observación hacia la media de la población y el estado oculto a lo largo del tiempo [14]. La alternativa es la tripleta: cada observación es una terna (t, f, v), instante, variable y valor, y la serie es una secuencia ordenada de ellas, sin necesidad de una rejilla común [15].

1.3.3 Análisis de supervivencia con redes neuronales

Predecir supervivencia con redes neuronales consiste en estimar el riesgo de que ocurra un evento en un horizonte temporal a partir de una secuencia de datos o una imagen estática de los mismos. Con este objetivo, la decisión que más condiciona un modelo de supervivencia es la función de pérdida. Los autores de DeepSurv [16] proponen usar la verosimilitud parcial de Cox, la misma función objetivo del modelo lineal pero sustituyendo el predictor lineal por una red neuronal.

Otra línea desplaza el foco al momento en que se calcula el riesgo. Jarrett et al. construyen un modelo de predicción dinámica con convoluciones temporales, que tiene en cuenta de forma explícita la ausencia de datos y se evaluó sobre el seguimiento de pacientes con Alzheimer [17].

El marco de evaluación es el *landmarking*. En lugar de un único punto de corte, define una rejilla de instantes (en este TFM, edades de 45 a 70 años) y exige al modelo predecir, desde cada uno, la aparición del evento en un horizonte fijo de cinco años [18]. Así se evalúa el modelo como lo que pretende ser: un estimador que se recalcula a medida que el paciente envejece y su historia crece.

1.3.4 Proyecto CASSANDRA: cribado de cáncer de pulmón con TCBD

En España no existe un programa poblacional de cribado de cáncer de pulmón, entendido como una invitación sistemática a toda la población elegible dentro del Sistema Nacional de Salud [19]. De hecho, el proyecto CASSANDRA (*Cancer Screening, Smoking Cessation and Respiratory Assessment*), impulsado por la SEPAR junto a otras sociedades científicas, es el primer piloto multicéntrico integrado en el Sistema Nacional de Salud [20].

El proyecto recluta a fumadores o exfumadores de 50 a 75 años con más de 20 paquetes-año y combina la TCBD con el abandono del tabaco [19]. Sus resultados son todavía preliminares y no han pasado una revisión por pares, es decir, no los ha evaluado ningún grupo de investigadores ajeno al proyecto ni se han publicado en una revista científica, de modo que lo que se conoce de ellos procede de los comunicados del propio proyecto y de la prensa especializada. El avance más reciente son 1 479 voluntarios reclutados y 33 casos positivos identificados hasta septiembre de 2026 [21]; en la presentación de los primeros resultados, con 658 voluntarios, el 77 % había obtenido un resultado negativo, el 19 % quedó como indeterminado y un 3,2 % resultó positivo [22].

Este trabajo no usa datos de CASSANDRA ni aporta evidencia clínica. Su relación con el proyecto es de método: elegir a quién cribar sigue siendo un problema abierto, y aquí se explora, sobre datos sintéticos, si el riesgo estimado a partir de la historia clínica irregular puede ayudar a resolverlo. Los resultados describen un generador sintético, así que no son trasladables al Sistema Nacional de Salud.

1.4 Objetivos

El trabajo persigue tres objetivos principales:

- Construir un pipeline reproducible que vaya de los registros crudos de Synthea a la comparación de modelos, de modo que cualquier resultado de esta memoria pueda regenerarse desde la configuración.

- Definir la representación de la historia clínica irregular que usa cada arquitectura, sin imponer una codificación única. Se cumple si los cinco modelos parten de la misma cohorte y se evalúan sobre los mismos 26 puntos de corte y el mismo horizonte de cinco años, definidos de forma declarativa.
- Comparar el rendimiento de un modelo de Cox con imputación simple frente a tres arquitecturas secuenciales (LSTM, GRU-D y STraTS) bajo un protocolo idéntico, incluida la variante de GRU-D que prescinde de los códigos de diagnóstico. El criterio es que cada modelo tenga sus cinco métricas con intervalo de confianza en el mismo formato de artefacto.

1.5 Contribuciones

La aportación principal es metodológica: un pipeline reproducible que compara, sobre la misma cohorte y el mismo protocolo, un modelo de supervivencia con imputación simple y tres arquitecturas secuenciales, evaluadas en una rejilla de 26 puntos temporales con cinco métricas y sus intervalos de confianza por bootstrap.

Junto a ello, la memoria documenta tres decisiones de diseño y su justificación: el filtrado anti-fuga de los códigos que definen el desenlace, el tratamiento de la *informative missingness* durante la construcción de las secuencias o en el modelo, y la adaptación de STraTS, una arquitectura pensada para clasificación, a un esquema de landmarking con pérdida de Cox.

No se aporta evidencia clínica. Los datos son sintéticos y los resultados describen el comportamiento de los modelos sobre ese generador, no sobre una población real.

1.6 Estructura de la memoria

El capítulo 2 describe los materiales: los datos sintéticos y el alcance de lo que puede concluirse con ellos, las fuentes crudas, los pools de descubrimiento y validación, la definición de la cohorte, los vocabularios de codificación y el entorno computacional.

El capítulo 3 desarrolla los métodos: el marco de supervivencia y el landmarking, la representación de las secuencias, cada uno de los cinco modelos comparados, el protocolo experimental común y las métricas de evaluación con su forma de agregación.

El capítulo 4 presenta los resultados: las características de la cohorte, el análisis exploratorio de las secuencias, la discriminación y la utilidad por landmark, la ablación de los códigos de diagnóstico y el coste computacional.

El capítulo 5 discute qué diferencias sostiene la evidencia, el comportamiento particular de Cox, el acelerón observado en el entorno del landmark 60 y el papel de los códigos de diagnóstico.

El capítulo 6 recoge las limitaciones y el trabajo futuro, y el capítulo 7 cierra con las conclusiones, objetivo por objetivo. Los apéndices recogen el modelo predictivo estático que precedió a este trabajo y sus resultados, y la tabla de atributos reveladores.

2
CAPÍTULO

Materiales

Los datos de este trabajo salen de Synthea, un generador de historias clínicas sintéticas, y de tres vocabularios que se usan para normalizarlos. El entorno computacional completa el cuadro. Antes de describir la metodología conviene fijar de qué materia prima se dispone y qué límites trae consigo.

2.1 Synthea: generación sintética y alcance de las conclusiones

Synthea es un generador de pacientes sintéticos de código abierto, distribuido por MITRE, que simula la historia clínica de una población desde el nacimiento hasta la muerte [23]. Cada módulo de enfermedad es una máquina de estados escrita en JSON, y cada estado puede disparar un diagnóstico, un encuentro, una prescripción o una analítica; la simulación avanza en pasos de siete días [23]. Synthea se alimenta únicamente de estadísticas de salud públicas y de guías clínicas, sin acceso a los registros de pacientes reales, y exporta los resultados a los formatos habituales de historia clínica electrónica [24].

El mundo sintético se construye siguiendo el marco PADARSER (*Publicly Available Data Approach to the Realistic Synthetic EHR*), que combina datos del censo y estadísticas sanitarias de Estados Unidos [23]. Los datos de esta memoria no se generaron para ella: proceden de un trabajo previo que usó Synthea para estudiar un sistema de aprendizaje continuo en la predicción del riesgo de cáncer de pulmón [25]. Ese estudio generó diez poblaciones de unos 15 000 pacientes con semillas distintas y las agrupó en cinco conjuntos acumulativos, de 30 000 a 150 000 pacientes. Para el modelado, aplanó cada historia clínica en una sola fila, conservando el último valor de cada código, y entrenó sus modelos con esa tabla. Ese planteamiento se reproduce en el apéndice A; sin embargo, esta memoria necesita las historias clínicas completas, la secuencia de visitas, diagnósticos y analíticas, porque son la materia prima de los modelos secuenciales. Ni el artículo ni su material suplementario declaran la versión de Synthea utilizada, lo que limita la trazabilidad de los registros.

El alcance de las conclusiones viene dado por ese origen. Synthea produce datos realistas, pero no reales: sus propios autores advierten de que no son adecuados para investigación clínica que exija precisión sobre pacientes [23]. El trabajo del que proceden los datos añade que las diferencias entre los pacientes sintéticos y los reales acotan dónde pueden aplicarse los modelos, y señala entre sus limitaciones el número reducido de enfermedades representadas, el sesgo hacia ciertas poblaciones y la ausencia de síntomas [25]. Para esta memoria la consecuencia es concreta: las prevalencias y las correlaciones que explotan los modelos son las del generador, no las de una población hospitalaria, así que los resultados describen el comportamiento de los modelos sobre estos registros y no trasladan evidencia clínica. El capítulo 6 retoma esta limitación.

2.2 Fuentes crudas: pacientes, condiciones y observaciones

Cada población del conjunto original incluye trece ficheros del exportador CSV de Synthea [26], pero nuestro pipeline usa tres por pool: `patients.csv.gz`, `conditions.csv.gz` y `observations.csv.gz`. El fichero `patients.csv.gz` aporta la demografía estática (`Id`, `BIRTHDATE`, `DEATHDATE`, `GENDER`). El

fichero `conditions.csv.gz` los diagnósticos en SNOMED CT con su fecha de inicio (`PATIENT`, `START`, `CODE`). Y el fichero `observations.csv.gz` las analíticas y constantes en LOINC con su valor (`PATIENT`, `DATE`, `CODE`, `VALUE`). El resto de dominios de los datos sintéticos originales (encuentros, medicaciones, procedimientos, inmunizaciones, alergias y demás) no se utiliza.

El volumen de los dos pools es comparable, como recoge la Tabla 2. Los dos rondan los quince mil quinientos pacientes y los once millones de observaciones.

Tabla 2: «Filas de los ficheros crudos de cada pool (cabecera excluida), y tamaño comprimido del conjunto.»

Fichero	discovery	holdout
`patients.csv.gz`	15 354	15 591
`conditions.csv.gz`	866 514	871 547
`observations.csv.gz`	11 161 255	11 115 019
Tamaño comprimido del pool (MB)	135,2	134,9

Los dos pools son las dos poblaciones de quince mil pacientes del conjunto de datos publicado por Chen [26]. Los ficheros crudos no se versionan en el repositorio; el pipeline los espera en `data/{pool}/`.

2.3 Pools discovery y holdout

Los datos se reparten en dos pools que nunca se mezclan. `discovery` es el pool del que sale todo lo que ajusta los modelos y `holdout` permanece aislado hasta la evaluación final. El reparto de `discovery` en train y validación ocurre antes de construir ninguna secuencia, porque la normalización de las analíticas se calcula con las estadísticas de train y se reutiliza en el resto, y el nodo que fija esas estadísticas queda como un artefacto propio dentro del grafo.

El reparto es 80/20, estratificado por evento, a nivel de paciente y con semilla fija. La Tabla 3 recoge el resultado en pacientes y eventos. La tasa de evento es prácticamente la misma en train y en validación (3,57 % y 3,58 %), que es lo que se busca al estratificar.

Tabla 3: «Pacientes y eventos por pool y por split.»

Pool o split	Pacientes	Eventos	Tasa de evento
discovery	15 087	539	3,57 %
holdout	15 346	618	4,03 %
train (80 %)	12 069	431	3,57 %
validación (20 %)	3 018	108	3,58 %

2.4 Definición de la cohorte: criterios de entrada, evento y censura

La cohorte de cada pool se construye con un único script y se guarda con tres columnas: `Id`, `duration` y `event`. La duración es el seguimiento en años, desde la fecha índice hasta el evento o hasta la censura, y el evento vale uno cuando hay cáncer de pulmón. El punto de partida es común a todos los pacientes: la fecha índice es el decimoctavo cumpleaños, es decir, la fecha de nacimiento más 18 años, y la duración se mide desde ahí y no desde el nacimiento. Ese origen explica la escala de la columna, de modo que una duración de 49 años son 49 años de seguimiento a partir de los 18. La fecha índice no se guarda como columna, porque se reconstruye a partir de la fecha de nacimiento cuando hace falta.

Entran en la cohorte los pacientes que cumplen tres condiciones:

- Estar vivos en la fecha índice, es decir, sin fecha de muerte o con una posterior a los 18 años.

- No tener un diagnóstico de cáncer de pulmón anterior a esa fecha ni simultáneo, para que el evento no sea prevalente y el caso no esté ya diagnosticado al entrar. Es lo que garantiza que el evento sea siempre posterior al decimoctavo cumpleaños.
- Tener al menos un contacto, un diagnóstico o una analítica, en la fecha índice o después, que es lo que permite seguir al paciente.

Los tres filtros descartan a pocos pacientes: de los 15 354 del fichero de `discovery` entran 15 087, y de los 15 591 de `holdout`, 15 346.

El evento es el primer diagnóstico de cáncer de pulmón, y se identifica con cuatro conceptos de SNOMED CT, que recoge la Tabla 4. Los cuatro describen neoplasia maligna confirmada.

Tabla 4: «Conceptos SNOMED CT que definen el evento, con la descripción oficial de SNOMED CT International Edition (2025-02-01) [1].»

Código SNOMED CT	Descripción oficial
`254632001`	Small cell carcinoma of lung
`254637007`	Non-small cell lung cancer
`424132000`	Non-small cell carcinoma of lung, TNM stage 1
`67811000119102`	Primary small cell malignant neoplasm of lung, TNM stage 1

El estudio de Chen y Chen [25] identifica el evento con tres códigos, dos de ellos comunes con estos y uno distinto: `162573006`, *Suspected lung cancer*, que aquí no se usa porque el evento exige un diagnóstico confirmado y no una sospecha. Tampoco tiene correspondencia en el mapa SNOMED a ICD-10-CM de Sección 2.5, así que no habría podido entrar como variable explicativa.

El final del seguimiento se fija por prioridad: la fecha del diagnóstico si existe, que es entonces la fecha del evento, si no, la fecha de muerte y si no, la del último contacto registrado en `conditions` o en `observations`. Cuando el seguimiento termina sin diagnóstico, se dice que el paciente llega a la censura. La duración es la diferencia en años entre ese final y la fecha índice, en el pool de `discovery` va de 0 a 81 años, con una mediana de 49, que medida desde los 18 años deja a la mitad de la cohorte con seguimiento hasta los 67 años de edad.

2.5 Vocabularios: LOINC y mapeo de SNOMED a ICD-10-CM

Las variables del modelo se apoyan en tres sistemas de codificación estándar de la informática clínica. SNOMED CT y LOINC son terminologías clínicas con estructura de ontología, es decir, sus conceptos se organizan en jerarquías y se relacionan entre sí. Los diagnósticos de `conditions` llegan codificados en SNOMED CT [1] y las analíticas y constantes de `observations`, en LOINC [2]. ICD-10-CM es de otra familia, una clasificación estadística, la de la OMS en su modificación clínica estadounidense, que aquí cumple una función distinta de la codificación, porque agrupa los diagnósticos para convertirlos en variables.

De LOINC se conservan 23 códigos, fijados antes de construir las secuencias: siete signos vitales y medidas antropométricas, quince analíticas de laboratorio. La Tabla 5 recoge los 23 con su nombre oficial.

Tabla 5: «Los 23 códigos LOINC que entran al modelo, con su denominación oficial y el grupo al que pertenecen [2].»

Código	Denominación oficial (LOINC)	Grupo
8480-6	Systolic blood pressure	Signos vitales
8462-4	Diastolic blood pressure	Signos vitales
9279-1	Respiratory rate	Signos vitales
8867-4	Heart rate	Signos vitales
29463-7	Body weight	Antropometría
8302-2	Body height	Antropometría
39156-5	Body mass index (BMI) [Ratio]	Antropometría
70274-6	Generalized anxiety disorder 7 item (GAD-7) total score [Reported.PHQ]	Cuestionario
718-7	Hemoglobin [Mass/volume] in Blood	Hemograma
777-3	Platelets [#/volume] in Blood by Automated count	Hemograma
785-6	MCH [Entitic mass] by Automated count	Hemograma
786-4	MCHC [Entitic Mass/volume] in Red Blood Cells by Automated count	Hemograma
787-2	MCV [Entitic mean volume] in Red Blood Cells by Automated count	Hemograma
32623-1	Platelet [Entitic mean volume] in Blood by Automated count	Hemograma
32207-3	Platelet distribution width [Entitic volume] in Blood by Automated count	Hemograma
4544-3	Hematocrit [Volume Fraction] of Blood by Automated count	Hemograma
6690-2	Leukocytes [#/volume] in Blood by Automated count	Hemograma
789-8	Erythrocytes [#/volume] in Blood by Automated count	Hemograma
21000-5	Erythrocyte distribution width [Entitic volume] by Automated count	Hemograma
2085-9	Cholesterol in HDL [Mass/volume] in Serum or Plasma	Lípidos
2571-8	Triglyceride [Mass/volume] in Serum or Plasma	Lípidos
2093-3	Cholesterol [Mass/volume] in Serum or Plasma	Lípidos
18262-6	Cholesterol in LDL [Mass/volume] in Serum or Plasma by Direct assay	Lípidos

Los diagnósticos entran al modelo agrupados por categoría, no como conceptos sueltos de SNOMED CT. El mapa que hace esa conversión es el oficial del NLM, la *National Library of Medicine* estadounidense, de SNOMED CT a ICD-10-CM [27], en la redistribución que publica The Tuva Project [28]. El mapa es de relación n:1, es decir, muchos conceptos de SNOMED CT se agrupan en una sola categoría de ICD-10-CM. De hecho, 100 881 conceptos de SNOMED se reducen a 1 497 categorías de tres caracteres.

Sobre ese mapa, el pipeline descarta tres cosas antes de usar los códigos como variables. Los conceptos sin correspondencia, las categorías `C33` y `C34`, que agrupan tráquea, bronquios y pulmón y por tanto son reveladoras, y las categorías que empiezan por `O`, `Z`, `V`, `W`, `X` o `Y`, que recogen el embarazo, los factores que condicionan el estado de salud y las causas externas. Tras el filtro quedan 1 312 categorías posibles.

No obstante, el vocabulario que aparece de verdad en los datos es mucho menor: 119 categorías distintas en train, 112 en validación y 120 en holdout, 121 en la unión de los tres. El modelo maneja del orden de 120 categorías y no 1 300; los capítulos 3 y 4 se leen con esa cifra presente. El recuento bajo es una consecuencia del generador: las 1 312 categorías que ofrece el mapa son muchas más de las que produce esta población, porque Synthea representa un número reducido de enfermedades, la limitación que ya se señaló en Sección 2.1. Entre las categorías observadas solo tres son oncológicas: `C18` (colon), `C50` (mama) y `C78`. Esta última no tiene relación con el pulmón: procede de un único concepto (`94260004`, metástasis en el colon), porque `C78` agrupa en una misma categoría los órganos respiratorios y los digestivos.

2.6 Entorno computacional y pipeline reproducible

El pipeline se apoya en dos herramientas. El entorno se reproduce con pixi, que fija Python 3.12 y las versiones de las bibliotecas que intervienen (pandas, PyTorch en su variante de CPU, scikit-survival, lifelines y el resto). La orquestación la lleva Snakemake [29], que resuelve las dependencias entre reglas y las ejecuta en el orden que exigen. El entorno reúne Snakemake, PyTorch y pandas en un mismo espacio, que es lo que permite que cada regla sea un script de Python que corre con la biblioteca ya cargada.

La Figura 1 muestra el grafo de reglas, nueve en total, y las dependencias que las ligan.

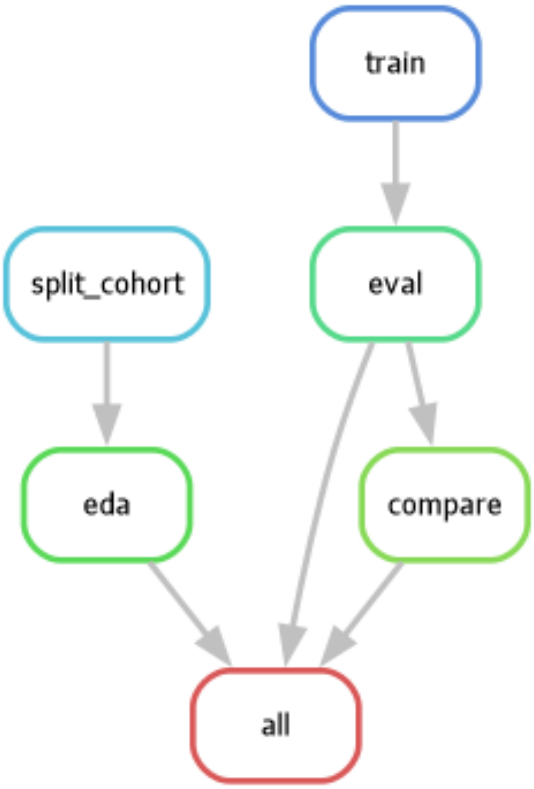


Figura 1: Grafo de reglas del pipeline: dependencias entre las nueve reglas de Snakemake.

2.6.1 Las tres etapas del grafo

La primera etapa construye los datos. `build_cohort` genera la cohorte de cada pool a partir de los ficheros crudos, `split_cohort` reparte `discovery` en train y validación; `fit_lab_stats` calcula la media y la desviación de cada analítica solo con train y las guarda como artefacto independiente, de manera que validación y holdout se normalizan con esas mismas cifras, `build_icd10_map` reduce el mapa de SNOMED a ICD-10-CM; y `build_sequences` produce las secuencias de cada split.

La segunda etapa es el análisis exploratorio, una sola regla que trabaja sobre las secuencias de train y genera el resumen y las figuras que se comentan en el capítulo 4.

La tercera entrena, evalúa y compara. `train` ajusta un modelo por cada entrada del catálogo, `eval` calcula sus métricas en cada landmark y sobre los tres splits, y `compare` reúne los resultados en una tabla y en la figura principal.

Los artefactos que encadenan las etapas son la cohorte (`cohort.parquet`), las secuencias (`sequences.pkl`), las estadísticas de normalización (`lab_stats.json`), el mapa compacto de diagnósticos (`snomed_to_icd10.json`), los modelos (`models/{nombre}.pkl`), sus métricas (`metrics/{nombre}.json`) y la comparación final (`comparison.csv`).

2.6.2 Configuración declarativa: añadir un modelo es editar YAML

El catálogo de modelos vive en el fichero de configuración y no en el código. Cada entrada declara un nombre, la arquitectura (`grud`, `lstm`, `cox` o `strats`) y sus hiperparámetros, y las reglas de entrenamiento y evaluación se instancian solas para cada nombre. Añadir un modelo consiste, por tanto, en añadir un bloque a la configuración, sin tocar las reglas. El estudio compara cinco entradas: `grud`, que incorpora los códigos de diagnóstico, `grud_labs`, solo con analíticas, `cox`, `lstm` y `strats`.

2.6.3 Entorno y ejecución

Los comandos de ejecución viven también en el entorno, y el estudio se ha ejecutado por completo en local: Snakemake lanza las reglas sobre una única máquina, con los núcleos disponibles (ocho en el equipo que produjo los resultados) y sin GPU. El entrenamiento corre en CPU, con las secuencias cargadas en memoria, de modo que ampliar la cohorte o añadir arquitecturas encarece el ciclo completo y los tiempos crecen con el número de modelos. A cambio, los cinco modelos se entrenaron y se evaluaron en el mismo entorno fijado y en las mismas condiciones, que es lo que hace comparables sus métricas.

CAPÍTULO 3

Métodos

Reproducir el estudio exige cinco piezas, el marco de supervivencia sobre el que se formula el problema, la representación de los datos, las arquitecturas entrenadas, el protocolo experimental y las métricas de evaluación. Cada una se describe en el orden en que el pipeline la ejecuta, de modo que el apartado pueda seguirse con el código al lado.

3.1 Marco de supervivencia

El estudio formula el cribado como un problema de tiempo hasta el evento, y este apartado fija el vocabulario que usan el resto del capítulo y el capítulo 5. Concretamente, qué se entiende por evento y por censura, cómo se estima la probabilidad de seguir en observación, qué añade el modelo de Cox y cómo se traduce todo a una probabilidad a cinco años en cada edad de corte.

3.1.1 Tiempo hasta evento, censura y riesgos competitivos

Los modelos de tiempo hasta el evento describen, para cada paciente, cuánto tarda en ocurrir un suceso y si llegó a ocurrir mientras se le observaba. El suceso se caracteriza con dos variables, el tiempo hasta el evento, T, y un indicador que dice si el seguimiento terminó con el evento o no. La particularidad de este caso es que el evento objetivo no es la muerte, como en un modelo de supervivencia al uso, sino el primer diagnóstico de cáncer de pulmón. Por eso el seguimiento puede terminar de tres maneras, porque aparece el diagnóstico, porque el paciente fallece o porque se le pierde la pista.

Como solo se observa uno de los tres desenlaces, el tiempo registrado es el mínimo entre el instante del diagnóstico y el instante en que se deja de observar al paciente:

$$T_i = \min(T_i^e, C_i)$$

donde T_i^e es el tiempo hasta el diagnóstico y C_i el tiempo hasta el final del seguimiento por muerte o por pérdida. El indicador copia el convenio habitual, vale uno cuando el mínimo lo marca el diagnóstico y cero en los otros dos casos.

La censura es el final del seguimiento sin que haya ocurrido el evento y sin que haya fecha de muerte. Con esta definición, un paciente censurado no es un paciente que no vaya a desarrollar el tumor, sino uno del que se deja de tener noticia en un punto concreto, en realidad, puede diagnosticarse después, fuera de la ventana de observación, y eso es exactamente lo que el modelo no puede ver. De ahí que la probabilidad de censura, $G(t) = P(C > t)$, no sea un detalle accesorio, sino una magnitud que entra en la evaluación. Se estima con Kaplan-Meier sobre los tiempos de censura de train,

$$\hat{G}(t) = \prod_{s \le t} (1 - d_s / n_s)$$

con d_s censuras en el instante s y n_s pacientes aún en observación. El estimador se calcula sobre los tiempos de cada paciente, y en la evaluación se ajusta por separado en cada landmark con las filas de

train de ese corte, de modo que cada edad tiene su propia referencia de censura. Un ejemplo breve ayuda a ver qué mide. Si a los diez años de seguimiento la mitad de la cohorte ya ha salido de la observación, la probabilidad de seguir en observación vale $0,5$ y un evento observado a esa edad pesa el doble que uno observado al principio. Las métricas que dependen de ella ponderan a cada paciente por la inversa de esa probabilidad (apartado 3.6.3), de modo que un paciente que ha llegado lejos sin censurarse pesa más, porque representa a los que se habrían perdido por el camino.

Un riesgo competitivo es un suceso que impide que ocurra el evento de interés. Aquí lo es la muerte por una causa ajena al cáncer de pulmón, porque un paciente que fallece sin diagnóstico no puede ser diagnosticado después, y su desenlace no es equivalente a una pérdida de seguimiento. El tratamiento de riesgos competitivos queda fuera del alcance de este trabajo. La muerte se trata como una censura más, y esa decisión está declarada como limitación en el capítulo 6. La consecuencia práctica es que las probabilidades que se reportan deben leerse como riesgo de diagnóstico mientras el paciente siga vivo y en seguimiento, y no como probabilidad de enfermar a lo largo de la vida.

3.1.2 El modelo de Cox y la verosimilitud parcial

El modelo de Cox supone que el riesgo de cada paciente es el producto de un riesgo basal común a toda la cohorte y de un factor exponencial que depende de sus covariables [30]:

$$h_i(t) = h_0(t) \cdot e^{\theta_i}$$

donde θ_i es un predictor calculado sobre las covariables del paciente, lineal en el caso clásico y la salida de una red neuronal en las variantes profundas. El riesgo basal $h_0(t)$ queda sin forma funcional impuesta. No se supone que crezca, que decrezca ni que siga una exponencial, y no se estiman parámetros que lo describan. Se deja libre y se recupera después a trozos con el estimador de Breslow. Por eso el modelo se llama semiparamétrico, porque la parte de las covariables es paramétrica y la del tiempo, no.

El interés de esta formulación está en que permite estimar θ sin conocer h_0. Si en un instante ocurre un evento, la probabilidad de que le ocurra al individuo i y no a otro del conjunto de pacientes aún en riesgo en ese instante, $R(t_i)$, es:

$$\frac{h_i(t_i)}{\sum_{j \in R(t_i)} h_j(t_i)} = \frac{h_0(t_i)\, e^{\theta_i}}{\sum_{j \in R(t_i)} h_0(t_i)\, e^{\theta_j}} = \frac{e^{\theta_i}}{\sum_{j \in R(t_i)} e^{\theta_j}}$$

El primer paso sustituye cada riesgo por su forma multiplicativa y el segundo cancela el riesgo basal, que aparece como factor común en el numerador y en el denominador. Con él desaparece la necesidad de modelarlo. Multiplicando esa probabilidad sobre los instantes con evento se obtiene la verosimilitud parcial,

$$L_p(\theta) = \prod_{k} \frac{e^{\theta_{(k)}}}{\sum_{j \in R\left(t_{(k)}\right)} e^{\theta_j}}$$

y tomando logaritmos y cambiando el signo, la función que el pipeline minimiza:

$$\mathcal{L}(\theta) = -\ln L_p(\theta) = -\sum_{k} \left[\theta_{(k)} - \ln \sum_{j \in R\left(t_{(k)}\right)} e^{\theta_j} \right]$$

donde el sumatorio recorre los instantes k con evento y $\theta_{(k)}$ es el predictor del paciente que lo sufre. La implementación ordena a los pacientes por duración descendente, del seguimiento más largo al más corto. Así, el conjunto de riesgo de un paciente es el tramo de la lista que va desde el principio

hasta él, es decir, todos los que seguían en observación en ese instante, y el cálculo se resuelve con una suma acumulada. La exponencial se evalúa restando antes el máximo de los predictores del lote, una precaución numérica que evita desbordamientos y que no cambia el resultado. Solo los pacientes con evento aportan a la suma, y los censurados entran únicamente en los conjuntos de riesgo de los demás.

La forma de la pérdida dice lo que el modelo optimiza. Para cada evento compara su predictor con una media suavizada de los predictores de todos los que estaban en riesgo. El primer término empuja hacia arriba el del paciente diagnosticado y el logaritmo del sumatorio lo empuja contra los demás, de modo que el modelo aprende a dar más riesgo a quien se diagnostica antes. El resultado no es una probabilidad, sino un orden, y da igual en cuánto supere un riesgo al otro. Un ejemplo de una línea lo aclara. Si dos pacientes están en riesgo y solo uno se diagnostica, la pérdida baja cuando el riesgo del diagnosticado supera al del otro, sin que importe la magnitud de la diferencia.

3.1.3 Riesgo basal de Breslow y probabilidad a horizonte

Para pasar del orden relativo a una probabilidad absoluta hace falta recuperar el riesgo basal, y el estimador de Breslow lo reconstruye a partir de los propios datos [31]. La idea es repartir los eventos observados en cada instante entre los pacientes que estaban en riesgo, en proporción a su riesgo relativo. Si en el instante t_k hay d_k eventos y el conjunto de riesgo es $R(t_k)$, a cada paciente le corresponde una fracción $e^{\theta_j} / \sum_{l \in R(t_k)} e^{\theta_l}$ de esos eventos, y sumando esas fracciones sobre todos los instantes hasta t se obtiene el riesgo acumulado:

$$\hat{H}_0(t) = \sum_{t_k \le t} \frac{d_k}{\sum_{j \in R(t_k)} e^{\theta_j}}$$

donde d_k son los eventos observados en el instante t_k. De ahí sale la probabilidad de supervivencia de cada paciente. El riesgo acumulado de un paciente concreto es el basal multiplicado por su factor relativo, $H(t \mid x_i) = \hat{H}_0(t) \cdot e^{\theta_i}$, y la supervivencia es la exponencial negativa de ese riesgo acumulado:

$$S(t \mid x_i) = \exp\!\left(-\hat{H}_0(t) \cdot e^{\theta_i}\right)$$

El pipeline fija este riesgo basal solo con los datos de train y no lo recalcula nunca sobre validación ni sobre `holdout`, que es la misma precaución que se toma con la distribución de censura y evita que información del conjunto de prueba se cuele en la predicción. La versión nula del modelo, con todos los riesgos a cero, da la incidencia basal de train, que es la referencia contra la que se mide el índice de precisión en el apartado 3.6.4.

3.1.4 Landmarking: predicción a edad fija, ventana de cinco años y anidamiento de cohortes

El análisis se plantea como un problema de predicción en un instante concreto de la vida del paciente, no como una predicción única. El esquema es el del *landmarking* [18], y consta de cuatro pasos. Se fija una edad de corte, se selecciona a los pacientes que siguen vivos y libres del evento en esa edad, se recoge su historia clínica hasta ese momento y se predice el evento en una ventana futura fija.

En este trabajo la rejilla de cortes son 26 edades, de los 45 a los 70 años, y la ventana es de cinco años, ambos declarados en el fichero de configuración. El filtro de elegibilidad se aplica con el tiempo transcurrido desde el corte,

$$\tilde{T}_i = T_i - (t_{LM} - 18)$$

de manera que la muestra se descarta si ese tiempo no es positivo, y la historia que ve el modelo se recorta a las observaciones anteriores al corte. Un paciente que en el momento del corte ya había sufrido el evento, o que ya había salido del seguimiento, no entra en esa cohorte.

Las cohortes de los distintos cortes comparten pacientes y están anidadas. Quien sigue en observación a los 70 años ya lo estaba a los 45, así que la cohorte de un landmark tardío es un subconjunto de la de uno temprano. En `holdout`, el corte de 45 años reúne 12 616 filas de paciente y landmark y el de 70 reúne 6 996, de modo que se retiene el 55,5 % y el tamaño decrece de forma monótona en los 26 cortes. En train el primer corte coincide con la cohorte del modelo, 9 917 pacientes, y el último baja a 5 458. Sumando los 26 cortes de `holdout` salen 258 685 filas sobre 12 616 pacientes únicos, es decir, cada paciente aparece en unos veinte cortes de media. Ese anidamiento es el problema que hay que resolver al agregar las métricas, y se trata en el apartado 3.6.6.

3.2 Descripción de la cohorte y de las secuencias

El estudio trabaja con dos objetos. La cohorte es un fichero con una fila por paciente y tres columnas (`Id`, `duration` y `event`), que define quién entra y cuándo termina su seguimiento. Las secuencias son la historia de cada paciente reconstruida como una serie de instantes con sus analíticas y sus diagnósticos.

3.2.1 Variables y estadísticos de la tabla de características

La tabla descriptiva de la cohorte se construye cruzando el artefacto de cohorte con el fichero crudo de pacientes, que aporta la fecha de nacimiento, la de muerte y el sexo, y se calcula una sola vez sobre los cuatro conjuntos. Las variables son seis. El número de pacientes y el de eventos salen directamente de la cohorte. La tasa de evento es el cociente entre ambos. El seguimiento mediano es la mediana de `duration`, medida desde la fecha índice de los 18 años. La edad mediana al final del seguimiento es esa misma mediana más 18. El porcentaje de mujeres sale del indicador de sexo que la secuencia guarda por paciente.

La tabla se acompaña de dos elementos más. El embudo de la muestra encadena la cohorte de `discovery`, el reparto en train y validación, las secuencias construidas, los pacientes con al menos un par válido y los pares paciente-landmark, de modo que cada cifra se lee como el resto de la anterior. La curva de incidencia acumulada por split se estima con Kaplan-Meier sobre los tiempos hasta el evento. `discovery` no lleva curva propia, porque es la unión de train y validación y duplicaría la figura.

3.2.2 Medidas de dispersión, co-ocurrencia y muestreo informativo

El análisis exploratorio se organiza en cuatro bloques, y cada uno responde a una pregunta distinta sobre los mismos datos.

- Lo que ve el modelo en cada corte. Por cada landmark se cuentan las muestras, cuántas no tienen ninguna analítica anterior al corte, la mediana y los cuantiles de analíticas y de códigos por muestra, y la mediana de instantes con registro. Es la única vista que responde a qué recibe la red.
- Densidad de observación. Se mide el número de analíticas por visita y la presencia de cada analítica en dos unidades distintas, el porcentaje de pacientes que la tienen alguna vez y el porcentaje de visitas que la incluyen. Se añade la intensidad por banda de edad, en observaciones por paciente y año, calculada como el solapamiento entre la ventana de cada paciente y la banda.
- Muestreo informativo. Para cada paciente se calcula la tasa de visitas con analítica por año de seguimiento, contando solo las que caen entre los 18 años y el final de su seguimiento. Las tasas de los pacientes con evento y sin evento se contrastan con una prueba de Mann-Whitney, y el tamaño del efecto se mide con la δ de Cliff, que vale $P(X > Y) - P(X < Y)$, con X la tasa del grupo con evento e Y la del grupo sin evento. Vale cero cuando las dos distribuciones se solapan por completo y ± 1 cuando todos los pacientes de un grupo se miden más que todos los del otro, y los empates cuentan en el término que resta.

- Magnitudes y normalización. Por analítica se resume la distribución de los valores estandarizados observados y se contrasta con las medias y desviaciones que el pipeline guardó en train. Las analíticas que se salen de la tolerancia se marcan y no se corrigen.

Dos reglas sostienen el conjunto. El paciente es la unidad de inferencia, nunca el par ni el valor, porque un mismo paciente aparece hasta en 26 cortes y contar sobre la muestra del modelo multiplicaría cada observación. Por eso la densidad, el muestreo y las magnitudes se calculan sobre la historia completa, y la muestra del modelo se usa solo donde la pregunta es qué ve la red. La otra regla es que toda cifra vive en un artefacto con su unidad, su población y su denominador, y que cada figura muestra un solo mensaje.

3.3 Representación de los datos

La representación es la pieza que decide qué puede aprender cada modelo. Una misma historia clínica se puede escribir de varias formas, y cada una impone sus supuestos sobre qué es un hueco, cuánto dura el pasado y cómo se codifica un diagnóstico. Este apartado describe cómo se construye la representación del estudio (Sección 3.3.1), las dos formas de leerla que usan los modelos (Sección 3.3.2) y el filtro que impide que el desenlace entre como variable (Sección 3.3.3).

3.3.1 Secuencias irregulares con códigos ICD-10-CM

La representación de partida se construye con una única regla que lee los tres ficheros crudos, `patients.csv.gz`, `conditions.csv.gz` y `observations.csv.gz`, y escribe por paciente cinco elementos, que son los instantes de la historia, la matriz de analíticas, su máscara de observación, el sexo y los códigos de diagnóstico.

Los instantes son la unión ordenada de las edades en que hay una analítica o un diagnóstico, de modo que la secuencia avanza de visita en visita y no sobre una rejilla de tiempo fijo. La matriz de analíticas tiene una fila por visita y una columna por cada una de las 23 analíticas fijadas, con el valor estandarizado en media y desviación. La máscara tiene la misma forma y marca qué se midió y qué no, y es lo que permite distinguir un valor ausente de un valor que casualmente vale cero. Los códigos de diagnóstico se guardan como una lista por visita, ya traducidos a categorías ICD-10-CM, tal como se describe en el capítulo 2.

La matriz se organiza como un tensor de tres dimensiones, lote, tiempo y variable, con una fila por visita y una columna por analítica. El eje temporal cuenta visitas y no años, y por eso los lotes se rellenan hasta la longitud máxima del lote en lugar de hasta una rejilla fija. Junto a la matriz viaja el intervalo desde la visita anterior, que se calcula como la diferencia entre instantes consecutivos y vale cero en la primera. Ese intervalo es el δ_t con el que GRU-D decide cuánto decae cada valor entre una visita y la siguiente.

La estandarización usa la media y la desviación calculadas solo con train, y esas mismas cifras se reutilizan en validación y en `holdout`, para que ningún paciente del conjunto de prueba participe en la normalización. El vocabulario de códigos se fija igual, en train. Se ordenan alfabéticamente las categorías que aparecen, se les asigna un índice a partir del uno y se reserva el cero para el relleno. Son 119 categorías observadas en train, y esa es la cifra que manejan los modelos, no las 1 312 que el mapa permite.

3.3.2 Tripletas (t, f, v) frente a matriz densa

Los modelos recurrentes y el transformer consumen esta misma historia, pero no la leen igual, y esa diferencia es la que separa las dos representaciones del capítulo.

La representación densa es la de GRU-D y la LSTM. Cada visita ocupa una fila de la matriz, con sus 23 analíticas, su máscara de observación y un intervalo adicional, el tiempo transcurrido desde la

visita anterior, que vale cero en la primera. Los lotes se rellenan a la longitud máxima del lote, con la dimensión temporal contando visitas y no años, de modo que cada paciente aporta tantas filas como visitas tiene.

La representación en tripletas es la de STraTS. Cada observación elemental se escribe como una terna (t_i, f_i, v_i), el instante exacto, un identificador de variable y su valor respectivamente. El identificador unifica analíticas y diagnósticos en un mismo espacio, con las 23 analíticas en los primeros índices y los códigos desplazados a continuación, y el valor es el z-score de la analítica o un uno constante cuando la observación es un diagnóstico. La serie queda entonces como una secuencia ordenada de observaciones sueltas, sin rejilla común y sin necesidad de rellenar huecos.

Las dos máscaras se llaman igual y no son lo mismo. La de la representación densa es una máscara de observación y por tanto dice qué variables se midieron en cada visita, y GRU-D la usa además para decidir qué imputar. La del transformer es una máscara de relleno, por lo que solo dice qué posiciones son artificiales porque el lote se ha igualado en longitud, y no lleva información clínica.

3.3.3 Fuga de información: eliminación de variables reveladoras

Un modelo que predice un diagnóstico no puede recibir como entrada el código de ese diagnóstico. El capítulo 2 ya describe los tres descartes que el pipeline aplica sobre los diagnósticos crudos antes de traducirlos a categorías (Sección 2.5). Aquí interesa su efecto sobre la representación, y ese efecto es que el vocabulario que llega al modelo no contiene ninguna categoría del desenlace. Como los cuatro conceptos SNOMED del evento se traducen a `C34`, el descarte de `C33` y `C34` los elimina aunque no se hubieran excluido por código, y las categorías que empiezan por `O`, `Z`, `V`, `W`, `X` o `Y` quedan fuera por el mismo filtro.

El filtro se ha comprobado sobre el vocabulario que queda. Ninguna categoría `C33` ni `C34` aparece, ninguno de los cuatro conceptos SNOMED que definen el evento está presente y no se cuela ninguna de las iniciales excluidas.

3.4 Modelos

El estudio entrena cinco modelos que representan tres familias. La línea base es un modelo de Cox sobre una tabla estática, sin ninguna noción de secuencia. Dos son recurrentes, la LSTM y GRU-D, y la segunda se entrena en dos variantes, con y sin códigos de diagnóstico. El quinto es un transformer, STraTS, que trata la historia como un conjunto de observaciones sueltas. Todos producen un riesgo escalar por paciente y corte, que la verosimilitud parcial del apartado 3.1.2 ordena. Cada subsección sigue el mismo esquema, la idea, las ecuaciones que la definen y los parámetros que se entrenan, y los parámetros de los cinco se recogen juntos al final del apartado.

3.4.1 Línea base tabular: Cox con LOCF

La línea base del estudio es un modelo de Cox sobre una matriz tabular por landmark. Para cada corte se construye una matriz con una fila por paciente y una columna por variable, rellenando las analíticas con la última observación disponible hacia delante. Si una analítica no se ha medido nunca en ese paciente, se imputa con la mediana de train de esa columna. A esas 23 columnas se añade el sexo y, cuando la variante los usa, un indicador por cada categoría de diagnóstico presente en la historia hasta el corte, lo que deja 143 columnas de entrada.

El modelo es una capa lineal sobre ese vector, de modo que el predictor es $\theta_i = x_i^\top \beta$ y el riesgo se obtiene aplicando la exponencial del apartado 3.1.2. Es la variante más simple de las cinco y sirve de referencia, porque mide cuánto se puede explicar con las últimas analíticas conocidas y el sexo, sin ninguna noción de secuencia ni de tiempo entre visitas.

La particularidad es que no hay un modelo, sino 26, ya que cada corte se ajusta por separado con sus propios pacientes y su propia matriz. Es el único del catálogo que se reentrena en cada corte, y su coste es proporcionalmente el más bajo de los cinco.

3.4.2 Procesamiento secuencial y RNN básicas

Una red recurrente procesa la historia visita a visita y mantiene un estado oculto que resume lo visto hasta el momento. La celda es siempre la misma y se aplica en cada paso, aunque al dibujarla se despliegue en el tiempo para ver el cálculo completo (figura Figura 2). Ese despliegue no es una red distinta, sino la misma celda repetida tantas veces como visitas tenga la historia.

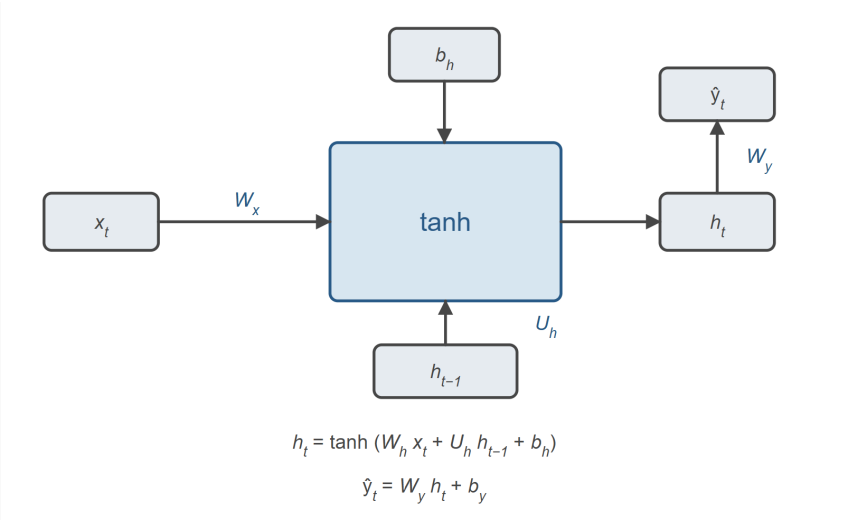


Figura 2: Esquema de una celda recurrente, con la entrada del instante, el estado anterior y la salida.

La figura Figura 3 muestra el despliegue temporal. En cada instante la celda recibe la entrada x_t y el estado anterior h_{t-1}, y produce un estado nuevo. La salida puede tomarse en cada paso, si la tarea pide una predicción por visita, o solo en el último, si lo que se quiere es un resumen de toda la secuencia. Este estudio usa la segunda opción, porque el riesgo se calcula una vez por paciente y corte y no en cada visita. El entrenamiento se hace sobre el grafo desplegado, con retropropagación a través del tiempo.

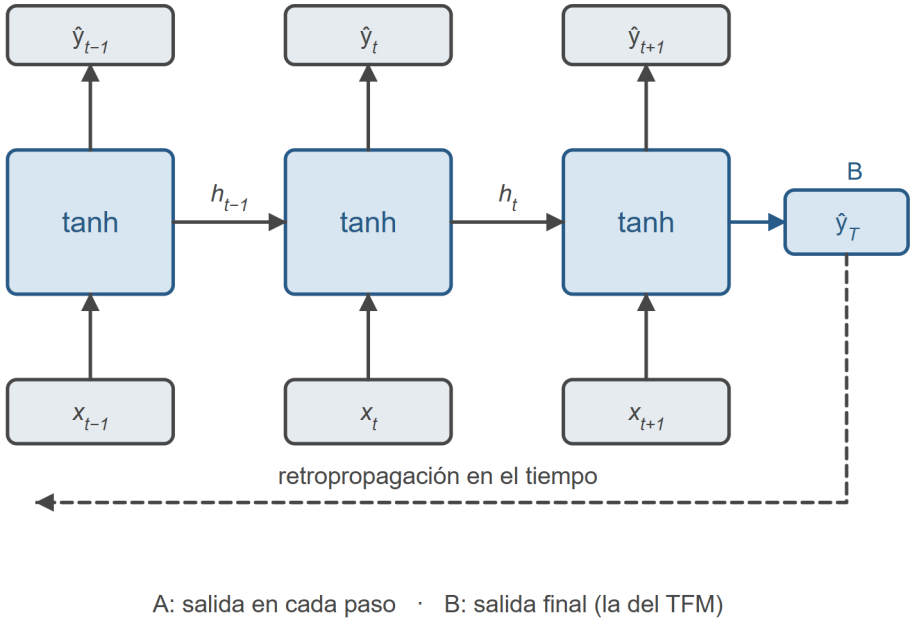


Figura 3: La misma celda desplegada en el tiempo. El despliegue es una forma de ver el cálculo, no una red distinta.

La celda más simple actualiza el estado con una tangente hiperbólica sobre la entrada actual y el estado anterior:

$$h_t = \tanh(W_h x_t + U_h h_{t-1} + b_h)$$

Los parámetros entrenables son las dos matrices y el sesgo, en total $d_h(d_x + d_h + 1)$, muy pocos en comparación con una capa densa del mismo tamaño. El problema de esta celda es que la señal se diluye a lo largo de la secuencia, porque el gradiente que llega desde el final hasta el principio se multiplica por tantos factores que tiende a desvanecerse, y la red acaba olvidando lo antiguo. De ahí salen las dos celdas que sí usa el estudio, la LSTM y la GRU, y de ahí también que el transformer sea una alternativa razonable cuando la historia es larga.

En el catálogo del pipeline no hay ninguna red recurrente básica. Las dos celdas que resuelven el problema del olvido son las que se describen en las dos subsecciones siguientes, y este apartado es el marco que las introduce.

3.4.3 LSTM

La LSTM resuelve el problema del olvido con una memoria separada del estado oculto y tres compuertas que deciden qué se guarda, qué se olvida y qué se muestra [32]. La figura **?@fig-lstm** recoge la celda completa, con la memoria recorriendo la banda superior y las compuertas alimentadas por la entrada y el estado anterior.

La compuerta de olvido y la de entrada actualizan la memoria,

$$c_t = f_t \odot c_{t-1} + i_t \odot g_t$$

y la compuerta de salida decide qué parte de esa memoria pasa al estado oculto,

$$h_t = o_t \odot \tanh(c_t)$$

con las tres compuertas calculadas como una sigmoide sobre la entrada y el estado anterior, y el candidato g_t como una tangente hiperbólica. El camino de la memoria a través de la suma es lo que permite que el gradiente llegue lejos sin desvanecerse.

En el pipeline la celda es una LSTM sobre un vector por visita que concatena las analíticas ya imputadas, la máscara de observación y el sexo, más un vector aprendido por categoría de diagnóstico cuando la variante los incorpora. La imputación es la media de train, sin decaimiento, porque la LSTM no usa el tiempo transcurrido entre visitas, y esa es su diferencia principal con GRU-D. El riesgo se toma del estado en la última visita real, no en el relleno, y una capa lineal lo convierte en el escalar que consume la pérdida de Cox.

3.4.4 GRU y GRU-D

La GRU es una versión reducida de la LSTM. En lugar de tres compuertas y una memoria aparte, usa dos compuertas y un único estado, con menos parámetros y un rendimiento parecido en la práctica. La figura **?@fig-gru** muestra la celda, con la compuerta de actualización decidiendo cuánto estado se conserva y la de reinicio controlando cuánto del anterior entra en el candidato.

Sobre esa celda construye Che et al. su modelo para series con valores ausentes, y esa es la variante que entrena el estudio [14]. La aportación de GRU-D es tratar el tiempo transcurrido como información. Cada analítica y el propio estado oculto decaen hacia su valor de referencia con una velocidad aprendida:

$$\gamma_x = \exp(-\max(0, W_x \delta_t + b_x))$$

donde δ_t es el tiempo desde la visita anterior. Con ese decaimiento se imputa el valor ausente mezclando la última observación conocida y la media de la población,

$$\hat{x}_t = m_t x_t + (1 - m_t)(\gamma_x x_{t-1} + (1 - \gamma_x)\bar{x})$$

y se atenúa el estado oculto antes de actualizarlo. Un paciente al que no se le mide el colesterol durante tres años arrastra un valor más parecido a la media que otro al que se le midió la semana pasada, y eso lo decide el modelo con sus propios parámetros en lugar de fijarlo a mano.

La celda recurrente recibe la concatenación de las analíticas imputadas, la máscara, el sexo y el tiempo transcurrido, más el vector de códigos cuando los usa, y la cabeza de riesgo es la misma que en la LSTM. La adaptación respecto al artículo original está en cómo se introduce la máscara. En lugar de las matrices separadas para cada compuerta, el pipeline concatena máscara y tiempo en una celda GRU estándar, lo que simplifica el código sin cambiar el comportamiento. La variante sin códigos es la que sirve para la ablación del apartado 3.5.2.

3.4.5 STraTS: Transformer sobre tripletas de observación

STraTS es un transformer pensado para series clínicas dispersas e irregulares [15]. Su tarea original es clasificación, con una tarea auxiliar de predicción de valores observados que se entrena antes del ajuste fino. De esa propuesta se toma aquí la arquitectura, no el preentrenamiento. El modelo se entrena desde cero y solo con la pérdida de Cox, y el aprendizaje autosupervisado queda como línea futura en el capítulo 6. La razón es de alcance, porque aquí el objetivo no es reducir las etiquetas necesarias, sino comparar arquitecturas bajo un protocolo común. Según el propio artículo, la fase autosupervisada es la que permite a la arquitectura mantener su rendimiento con menos etiquetas, y esa ventaja queda sin explorar en esta memoria.

Antes de entrar en el modelo conviene recordar cómo funciona un transformer. Un transformer procesa toda la secuencia en paralelo, sin recorrerla en orden, y lo hace con un mecanismo de atención que relaciona cada elemento con todos los demás. La atención se construye con tres proyecciones lineales

de cada elemento, la consulta, la clave y el valor, de modo que el peso entre dos posiciones sale del producto escalar de la consulta de una con la clave de la otra, normalizado y pasado por una softmax (figura **?@fig-atencion**). Cada posición se queda entonces con una combinación ponderada de los valores de todas las demás.

El mecanismo se repite en varias cabezas en paralelo, cada una con sus propias proyecciones, y el resultado se concatena. Con eso cada cabeza puede especializarse en un tipo de relación distinta. Después, el bloque del codificador añade una conexión residual y una normalización, y una capa densa con su propia residual (figura **?@fig-encoder**). Esas dos piezas son las que hacen entrenable una red de este tipo, porque mantienen el gradiente en un camino directo a través de las capas.

En el caso de las series clínicas, el transformer no necesita codificación posicional como la de un texto, porque cada observación trae su instante real y ese instante se usa como una entrada más. El modelo trabaja sobre las tripletas del apartado 3.3.2 y construye cada una como la suma de tres piezas, el instante, la variable y el valor, cada una proyectada a la dimensión interna del modelo. El instante y el valor pasan por una red de dos capas con una tangente hiperbólica en medio, que es lo que permite tratar un tiempo o un valor continuo como un vector. La variable se resuelve con un vector aprendido por identificador. Cuando la observación es un diagnóstico, la contribución del valor se anula, de modo que la representación del código es íntegramente la de la variable y el uno constante no introduce ninguna falsa noción de magnitud.

Sobre esas representaciones actúa un codificador de dos capas con cuatro cabezas de atención, que relaciona cada observación con todas las demás sin recorrer la secuencia en orden. La máscara de relleno impide que las posiciones artificiales participen en la atención. Después, la secuencia se resume con una atención aprendida, en la que cada observación recibe un peso proporcional a su relevancia y el resumen es la media ponderada,

$$e = \sum_i \alpha_i h_i$$

El riesgo se calcula a partir de ese resumen y de un vector demográfico que codifica el sexo, y el modelo devuelve un único escalar por muestra. No devuelve riesgos intermedios, porque el transformer procesa la secuencia entera en paralelo y no tiene pasos temporales.

La Tabla 6 recoge el tamaño de los cinco modelos. La cifra de Cox es por landmark, porque se ajusta uno en cada corte, y las demás son el total del modelo.

Tabla 6: «Parámetros entrenables por modelo, contados sobre los artefactos entrenados. En Cox el número es por landmark, porque se ajusta un modelo distinto en cada corte.»

Modelo	Familia	Parámetros entrenables
`cox`	Lineal sobre tabla	144 por landmark, 3 744 en los 26 cortes
`lstm`	Recurrente (LSTM)	12 449
`grud`	Recurrente (GRU-D con códigos)	11 471
`grud_labs`	Recurrente (GRU-D sin códigos)	8 015
`strats`	Transformer	23 149

3.5 Protocolo experimental

Los cinco modelos compiten con el mismo presupuesto y sobre las mismas particiones. Las diferencias de configuración se limitan a lo que exige cada arquitectura (el tamaño oculto de las redes, el número de épocas de la línea base y el decaimiento de pesos del transformer), y no hay búsqueda de hiperparámetros, el fichero de configuración define una única combinación por modelo. La razón es el coste. Entrenar y evaluar los cinco modelos completos lleva más de tres horas en una máquina de ocho núcleos (apartado 4.7), y una búsqueda en rejilla multiplicaría esa cifra por cada combinación probada, algo que queda fuera del alcance de este trabajo.

3.5.1 Partición por paciente, sobremuestreo de eventos y parada temprana

La partición se hace a nivel de paciente y estratificada por evento, con un 80 % para train y un 20 % para validación, sobre el pool `discovery` y con semilla fija. `holdout` no se reparte, porque es una población generada aparte que no entra en el ajuste en ningún momento. El reparto busca que la tasa de evento sea la misma en los dos conjuntos, porque con una prevalencia del 3,6 % una partición al azar desequilibrada cambiaría el punto de partida de los modelos.

Aun así, la prevalencia es baja, y para que el entrenamiento no se limite a aprender la clase mayoritaria se usa un muestreador que da tres veces más peso a los pacientes con evento. Es un sobremuestreo con reemplazamiento, no una reponderación de la pérdida, y el factor es el mismo para los cinco modelos.

La parada temprana vigila la pérdida de validación con un umbral de mejora de 10^{-4} y guarda el mejor estado del modelo. Cada arquitectura lleva su propia paciencia. El optimizador es Adam, con el decaimiento de pesos de la configuración y un planificador que reduce la tasa de aprendizaje a la mitad cuando la pérdida de validación se estanca durante tres épocas.

3.5.2 Ablación de códigos ICD-10-CM

La única ablación del estudio compara las dos variantes de GRU-D, la que recibe los códigos de diagnóstico junto a las analíticas y la que solo usa analíticas. Las dos comparten arquitectura, hiperparámetros y particiones, y se diferencian únicamente en la dimensión del vector de códigos, que se anula en la segunda. La comparación mide, por tanto, qué aporta el bloque de diagnósticos con todo lo demás fijo, y sus resultados están en el apartado 4.6.

No hay ninguna otra ablación en el catálogo, y esa ausencia forma parte de las limitaciones del capítulo 6.

3.5.3 Presupuesto de entrenamiento e hiperparámetros

La Tabla 7 recoge la configuración de los cinco modelos. Las filas que coinciden en todas las columnas son el presupuesto común, y las que no se explican por las exigencias de cada arquitectura.

Tabla 7: «Configuración de cada modelo. Las filas idénticas en las cinco columnas forman el presupuesto común, y las diferencias se deben a la arquitectura.»

Hiperparámetro	`cox`	`lstm`	`grud`	`grud_labs`	`strats`
Tamaño de lote	128	128	128	128	128
Tasa de aprendizaje	0,001	0,001	0,001	0,001	0,001
Decaimiento de pesos	0,01	0,01	0,01	0,01	0,0001
Épocas máximas	100	20	20	20	20
Paciencia de parada	20	3	3	3	3
Sobremuestreo de eventos	3,0	3,0	3,0	3,0	3,0
Longitud máxima de historia	200	200	200	200	200
Dimensión oculta	no aplica	32	32	32	32
Cabezas de atención	no aplica	no aplica	no aplica	no aplica	4
Capas de atención	no aplica	no aplica	no aplica	no aplica	2
Dimensión de la capa densa	no aplica	no aplica	no aplica	no aplica	64
Códigos de diagnóstico	sí	sí	sí	no	sí

Las tres diferencias tienen su motivo. Cox lleva más épocas y más paciencia porque es un modelo lineal, entrena en segundos y no necesita la contención que exigen las redes. El decaimiento de pesos es una penalización sobre la magnitud de los pesos que se suma a la pérdida y los empuja hacia cero, de modo que el modelo no se ajuste de más a los datos de entrenamiento. El transformer lo lleva cien veces menor que las redes recurrentes, y el resto de sus valores son propios de la arquitectura (número de cabezas, capas y dimensión de la capa densa). La línea base no tiene dimensión oculta porque no tiene capa recurrente.

3.6 Evaluación

Cada modelo se evalúa con las mismas cinco métricas, sobre los mismos cortes y con los mismos datos de referencia. Este apartado define qué mide cada una y por qué están las cinco, porque dos miran el orden, una mira el error, otra lo compara con el modelo nulo, y cada una deja fuera algo que las demás cubren.

3.6.1 Discriminación: el C-index de Harrell y su falta de horizonte

El C-index de Harrell mide la proporción de parejas de pacientes en las que el modelo ordena correctamente el riesgo, es decir, en las que asigna más riesgo al que sufre el evento antes [33]. La implementación cuenta tres tipos de parejas. Las concordantes son aquellas en que el orden del riesgo coincide con el del tiempo, las discordantes son las que lo invierten, y las empatadas son aquellas en que los dos riesgos son iguales, con una tolerancia numérica configurable que decide cuándo dos riesgos distintos cuentan como empate. Con esos tres conteos,

$$C = \frac{n_c + \frac{1}{2} n_t}{n_c + n_d + n_t}$$

donde el medio refleja que una pareja empatada no se acierta ni se falla. Vale $0,5$ cuando el modelo ordena al azar y 1 cuando ordena a todos por su tiempo real.

Su limitación es la que explica el capítulo 5, porque no mira la ventana de predicción. Un modelo que distinga bien entre un evento a un año y otro a veinte obtiene un C-index alto aunque, en el horizonte de cinco años que aquí interesa, apenas separe a quien va a enfermar de quien no. Es una medida del orden global a lo largo de todo el seguimiento, no de la utilidad a cinco años. A ello se suma que el estimador descarta las parejas en que uno de los dos está censurado antes del evento del otro, sin reponderarlas, lo que lo hace optimista cuando la censura depende del tiempo. Las dos cosas son la razón de existir de las métricas siguientes.

La implementación usa la versión censurada de la biblioteca de supervivencia y guarda, además del valor, el número de parejas concordantes, discordantes y empatadas, que es lo que permite agregar después sin volver a emparejar.

3.6.2 AUROC dependiente del tiempo a cinco años

El AUROC dependiente del tiempo mide la capacidad de separar a los pacientes que sufren el evento dentro del horizonte de los que siguen libres al terminarlo [34]. Los casos son los diagnósticos ocurridos antes de los cinco años, los controles son los pacientes aún libres en ese instante y los censurados antes del horizonte entran ponderados, no descartados. Formalmente es una proporción de parejas caso--control, ponderadas por la inversa de la probabilidad de censura:

$$\mathrm{AUC}(t) = \frac{\sum_i \sum_j w_i w_j \, \mathbb{1}\left[\hat{r}_i > \hat{r}_j\right] \mathbb{1}\left[T_i \le t < T_j\right]}{\sum_i \sum_j w_i w_j \, \mathbb{1}\left[T_i \le t < T_j\right]}$$

donde el numerador cuenta las parejas bien ordenadas y el denominador todas las comparables, con $w_i = 1/\hat{G}(T_i)$ para los casos y $w_j = 1/\hat{G}(t)$ para los controles.

En el pipeline se calcula en un único instante, el horizonte de cinco años, con lo que se obtiene una cifra por corte comparable entre landmarks y alineada con lo que el modelo pretende hacer. La implementación espera un riesgo, con el valor alto indicando más riesgo. Intercambiar el signo invierte la métrica y devuelve valores por debajo de $0,5$, un error que ya está documentado en el propio repositorio.

3.6.3 Ponderación IPCW y el C-index de Uno

La ponderación por la inversa de la probabilidad de censura es el mecanismo que permite usar los datos de los censurados sin sesgo. Cada pareja de pacientes se pondera por el inverso del producto de sus probabilidades de seguir en observación,

$$w_{ij} = \frac{1}{\hat{G}(T_i) \cdot \hat{G}(T_j)}$$

de modo que una pareja en la que los dos llegan lejos sin censurarse cuenta más que otra interrumpida pronto, porque representa a más pacientes. El C-index de Uno es el de Harrell con esa corrección [35], y es consistente incluso cuando la censura depende del tiempo. Con el peso, el índice es el mismo cociente del apartado 3.6.1, sumando las parejas ponderadas:

$$C_w = \frac{\sum_{i<j} w_{ij}\left(c_{ij} + \frac{1}{2}\tau_{ij}\right)}{\sum_{i<j} w_{ij}\,\kappa_{ij}}$$

donde c_{ij}, τ_{ij} y κ_{ij} valen uno cuando la pareja es concordante, empatada o comparable, respectivamente.

La distribución de censura $G(t)$ se estima, como se dijo en el apartado 3.1.1, con Kaplan-Meier sobre los tiempos de censura de train de cada landmark, y no se recalcula nunca sobre validación ni sobre `holdout`.

La función de la biblioteca que calcula este C-index devuelve los conteos sin ponderar, idénticos a los del C-index de Harrell. Agrupar los 26 landmarks sumando esos conteos daría, bit a bit, el C-index de Harrell agrupado, no el de Uno. Por eso el valor agrupado se calcula como media ponderada por el número de parejas comparables de cada corte, y se declara explícitamente como aproximación al estimador estratificado, en lugar de presentarse como el estimador exacto.

3.6.4 Brier IPCW e IPA frente al modelo nulo

El Brier IPCW es el error cuadrático medio de la probabilidad predicha, con la misma reponderación por censura [36], [37]:

$$\mathrm{BS}(t) = \frac{1}{n}\sum_{i} w_i(t)\cdot\left(\mathbb{1}[T_i > t] - \hat{S}(t \mid x_i)\right)^2$$

Rango de cero a uno y, al contrario que las anteriores, menor es mejor. Requiere probabilidades de supervivencia, no riesgos, y por eso se alimenta de la supervivencia derivada del riesgo basal de Breslow del apartado 3.1.3 en lugar del orden que produce el modelo.

El valor absoluto de esta métrica no se interpreta solo. Con una incidencia del 4 %, un modelo que no aporte nada obtiene ya un Brier muy bajo, y una cifra de $0,008$ no dice si el modelo sirve. Para poder leerla hace falta una referencia, y la referencia es el modelo nulo, el mismo cálculo con el riesgo basal de train y todos los riesgos a cero, es decir, la incidencia basal sin covariables.

El índice de precisión es exactamente eso, el cociente entre los dos [38]:

$$\mathrm{IPA} = 1 - \frac{\mathrm{BS}_{\text{modelo}}}{\mathrm{BS}_{\text{nulo}}}$$

Vale cero cuando el modelo no aporta nada sobre la incidencia basal y es negativo cuando predice peor que no usar ninguna covariable. En la agregación, el índice se calcula como cociente de los Brier agrupados, no como media de los índices por landmark, porque el segundo procedimiento da un valor distinto y menos interpretable.

3.6.5 Intervalos de confianza por bootstrap a nivel de paciente

Todas las métricas se acompañan de un intervalo de confianza al 95 % obtenido por remuestreo con reemplazamiento. El remuestreo se hace sobre pacientes. Dentro de un landmark cada paciente aporta una sola fila, así que remuestrear filas o pacientes daría lo mismo. La diferencia aparece al agregar, donde cada paciente tiene unas veinte filas repartidas por los cortes, y ahí sortear filas rompería esa correspondencia. El procedimiento sortea identificadores de paciente, recupera en bloque todas sus filas y calcula la métrica sobre esa pseudopoblación.

Los intervalos son los percentiles 2, 5 y 97, 5 de la distribución de las réplicas. Es el método del percentil, que estima el intervalo poblacional sin suponer normalidad y cuya precisión crece con el número de réplicas. Con 200 por landmark se obtiene un intervalo estable, y el coste es la razón de no subir más, porque cada réplica evalúa un corte completo. Las referencias que se fijan en train, la distribución de censura y el riesgo basal, no se remuestrean en ninguna réplica, de modo que el intervalo mide la incertidumbre del conjunto de evaluación y no la de los datos de ajuste.

Un detalle de lectura. Por el reemplazamiento, cada réplica deja fuera alrededor del 37 % de los pacientes, que es la proporción esperada cuando el muestreo es con reemplazamiento. Esos pacientes no se descartan del cálculo, simplemente no aparecen en esa réplica concreta.

3.6.6 Agregación sobre landmarks anidados: estimando agrupado y cluster bootstrap

Agregar los 26 cortes en una sola cifra por modelo tiene un problema que no es aritmético, sino estadístico. Como se vio en el apartado 3.1.4, las cohortes de los distintos landmarks comparten pacientes. En `holdout`, 258 685 filas corresponden a 12 616 pacientes, unos veinte cortes por cabeza. Las filas no son independientes, y promediar los 26 resultados como si lo fueran daría una cifra razonable pero un intervalo de confianza falso, más estrecho de lo que permite la evidencia.

La respuesta tiene dos partes. Para el valor agrupado, cada métrica se combina con la aritmética que le corresponde. El C-index de Harrell suma las parejas de todos los cortes y divide una sola vez, el Brier es una media ponderada por el número de pacientes de cada corte y el índice de precisión es el cociente de los Brier agrupados. El AUROC y el C-index de Uno se agregan también como media ponderada, y quedan declarados como aproximación por la razón explicada en 3.6.3. En ningún caso se comparan pacientes de cortes distintos entre sí.

Para el intervalo, el remuestreo se hace una sola vez sobre la cohorte de pacientes y se arrastran todas sus filas de todos sus cortes en bloque. Así, cada réplica reconstruye una pseudopoblación coherente en la que el paciente sigue apareciendo en los mismos veinte cortes, se evalúan los 26 landmarks sobre ella y se combinan con la misma aritmética, lo que produce un único valor agrupado por réplica. Con 100 réplicas se obtienen los percentiles que forman el intervalo. La alternativa, remuestrear cada landmark por separado, rompería la dependencia entre cortes y estrecharía el intervalo.

4
CAPÍTULO

Resultados

Los números que siguen describen lo que hacen los cinco modelos sobre la cohorte, sin interpretarlos. La interpretación ocupa el capítulo siguiente. Salvo donde se indique lo contrario, todas las cifras son del pool `holdout`, que no participó en el ajuste ni en la selección de modelos.

4.1 Características de la cohorte

La Tabla 8 resume la cohorte con la que se trabaja en cada split. Los tres conjuntos proceden del mismo generador y el reparto de `discovery` es estratificado por evento, de modo que la tasa de diagnóstico es casi idéntica en train y en validación (3,57 % y 3,58 %) y algo mayor en `holdout` (4,03 %), que es una población generada aparte y no una partición de la anterior.

Tabla 8: «Composición de la cohorte por split. El seguimiento se mide desde la fecha índice (18 años) y los pacientes sin evento quedan censurados.»

Característica	train	validación	holdout
Pacientes	12 069	3 018	15 346
Eventos observados	431	108	618
Tasa de evento	3,57 %	3,58 %	4,03 %
Seguimiento mediano desde edad índice (años)	49,1	48,5	49,3
Edad mediana al final del seguimiento (años)	67,1	66,5	67,3
Mujeres	46,4 %	47,3 %	46,8 %

Una mediana de seguimiento de 49 años medida desde los 18 sitúa el final del seguimiento en torno a los 67 años de edad, por lo que la cohorte cubre la vida adulta completa de cada paciente y no una ventana de pocos años. La proporción de mujeres queda cerca de la mitad en los tres conjuntos, así que un desequilibrio por sexo no puede explicar las diferencias que aparezcan después.

La Figura 4 recoge la incidencia acumulada de diagnóstico por split, con su intervalo al 95 %, sobre la ventana de landmarks. La curva crece con la edad, `holdout` queda por encima de train y validación en toda la ventana, y el intervalo se ensancha en los cortes finales.

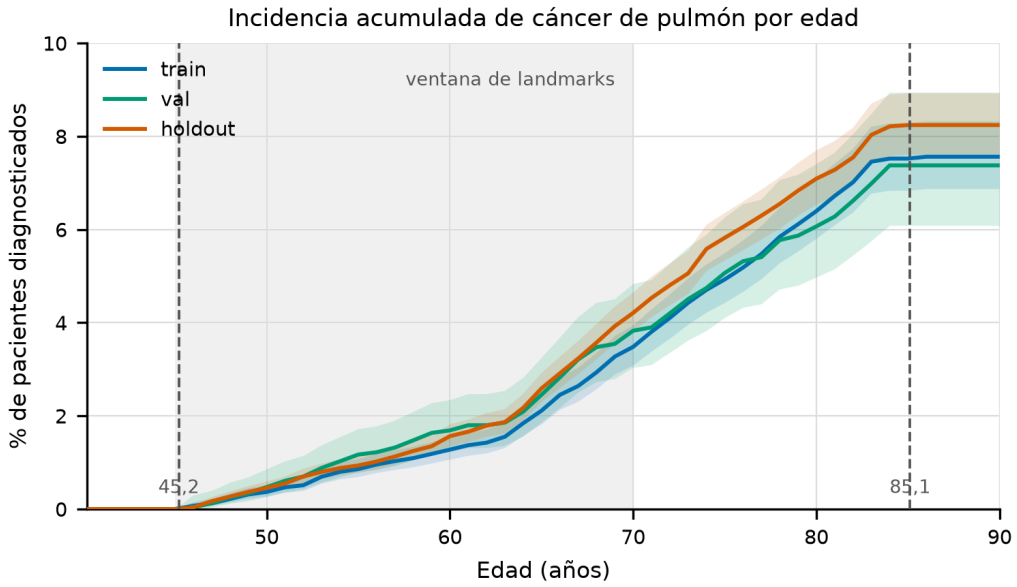


Figura 4: Incidencia acumulada de diagnóstico por split, con intervalo de confianza al 95 %.

4.2 Caracterización de las secuencias

El análisis exploratorio describe los datos antes de que ningún modelo los use. Se apoya en un artefacto único que declara su procedencia, su versión de esquema y los hashes de sus entradas, y distingue tres vistas de la historia, la completa, la truncada en el corte y la muestra que consume el modelo. Esa distinción importa porque un mismo paciente aparece hasta en 26 cortes, y contar visitas sobre la muestra del modelo multiplicaría por 26 cada observación. Las cifras de este apartado salen de train.

4.2.1 Lo que ve el modelo en cada corte

La Figura 5 muestra las tres cosas que cambian con la edad del corte, cuántas muestras hay, qué proporción de ellas no tiene ninguna analítica previa y cuántas magnitudes recibe el modelo cuando hay datos. El resultado principal es que el modelo ve sobre todo diagnósticos.

El filtro de landmarks, descrito en el capítulo 3, descarta a quien no tiene ninguna observación previa al corte: de los 12 069 pacientes de train, 9 917 tienen al menos un par válido, lo que produce 202 672 filas sobre los 26 puntos de corte. De ellas, 160 233 (el 79,06 %) no tienen ni una analítica anterior al corte, y la mediana de analíticas por muestra es cero en los 26 cortes. La mediana de códigos de diagnóstico es 3 y el percentil 90 es 8.

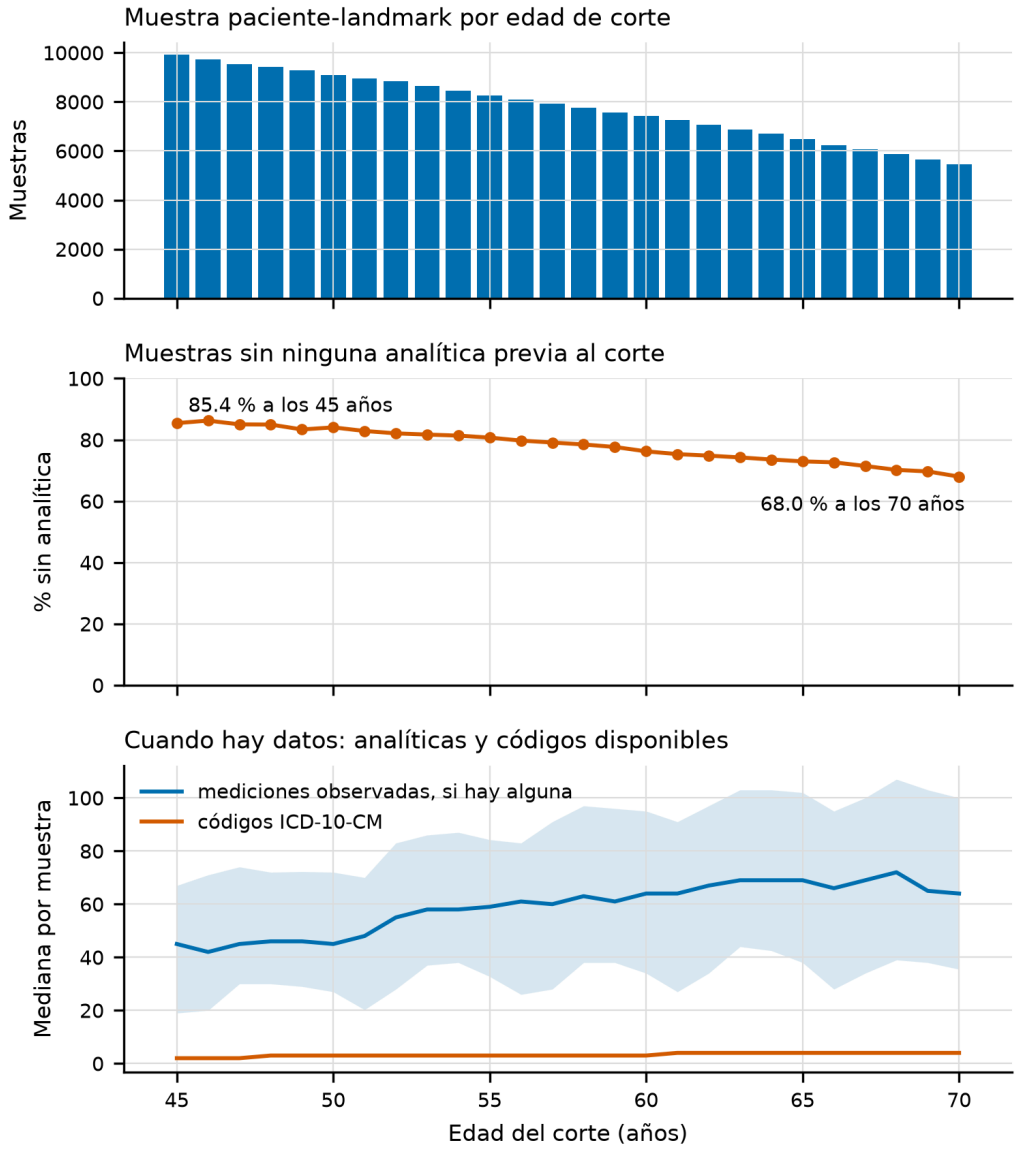


Figura 5: Muestras por corte, proporción sin analítica previa y magnitudes disponibles cuando hay datos.

La cobertura depende de la edad. La proporción de muestras sin analítica baja del 85,44 % en el corte de 45 años al 67,99 % en el de 70, y la mediana de instantes con registro sube de 2 a 5. Cuando el paciente sí tiene analíticas no son pocas, porque la mediana condicional es de 45 mediciones en el corte de 45 años y de 64 en el de 70. La muestra efectiva es, por tanto, una mezcla de pacientes con mucha historia y de pacientes sin ninguna, y esa mezcla cambia con el corte.

4.2.2 Muestreo informativo

La Figura 6 compara la frecuencia de medición de los pacientes según su desenlace. Para cada uno de los 9 917 pacientes del modelo se calcula la tasa de visitas con analítica por año de seguimiento, contando solo las que caen dentro de la ventana que va de los 18 años al final del seguimiento de cada paciente. La mediana es de 0,256 visitas al año en los pacientes sin evento y de 0,192 en los que lo desarrollan, con un contraste de Mann-Whitney de $p = 1{,}1 \times 10^{-21}$ y un δ de Cliff de $-0{,}272$.

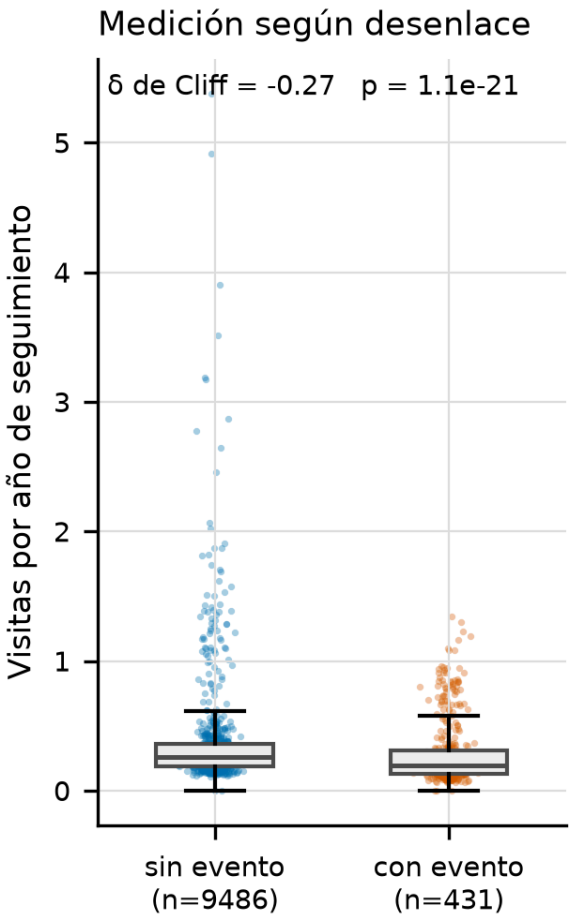


Figura 6: Tasa de visitas con analítica por año de seguimiento en los pacientes sin evento y con evento.

4.2.3 Densidad de observación

La Figura 7 reúne la carga de cada visita, la presencia de cada analítica y la intensidad por edad. En una visita se registran 8 analíticas de mediana y 9,05 de media, con un rango de 1 a 23. La presencia se mide en dos unidades que no son intercambiables. Entre el 97,3 % y el 99,8 % de los pacientes tiene alguna vez cada analítica, pero solo entre el 13,8 % y el 82,7 % de las visitas la incluye. La primera cifra dice que casi todos los pacientes acaban teniendo cada analítica en algún momento, y la segunda que en una visita concreta se mide una fracción. La intensidad por banda de edad crece con los años.

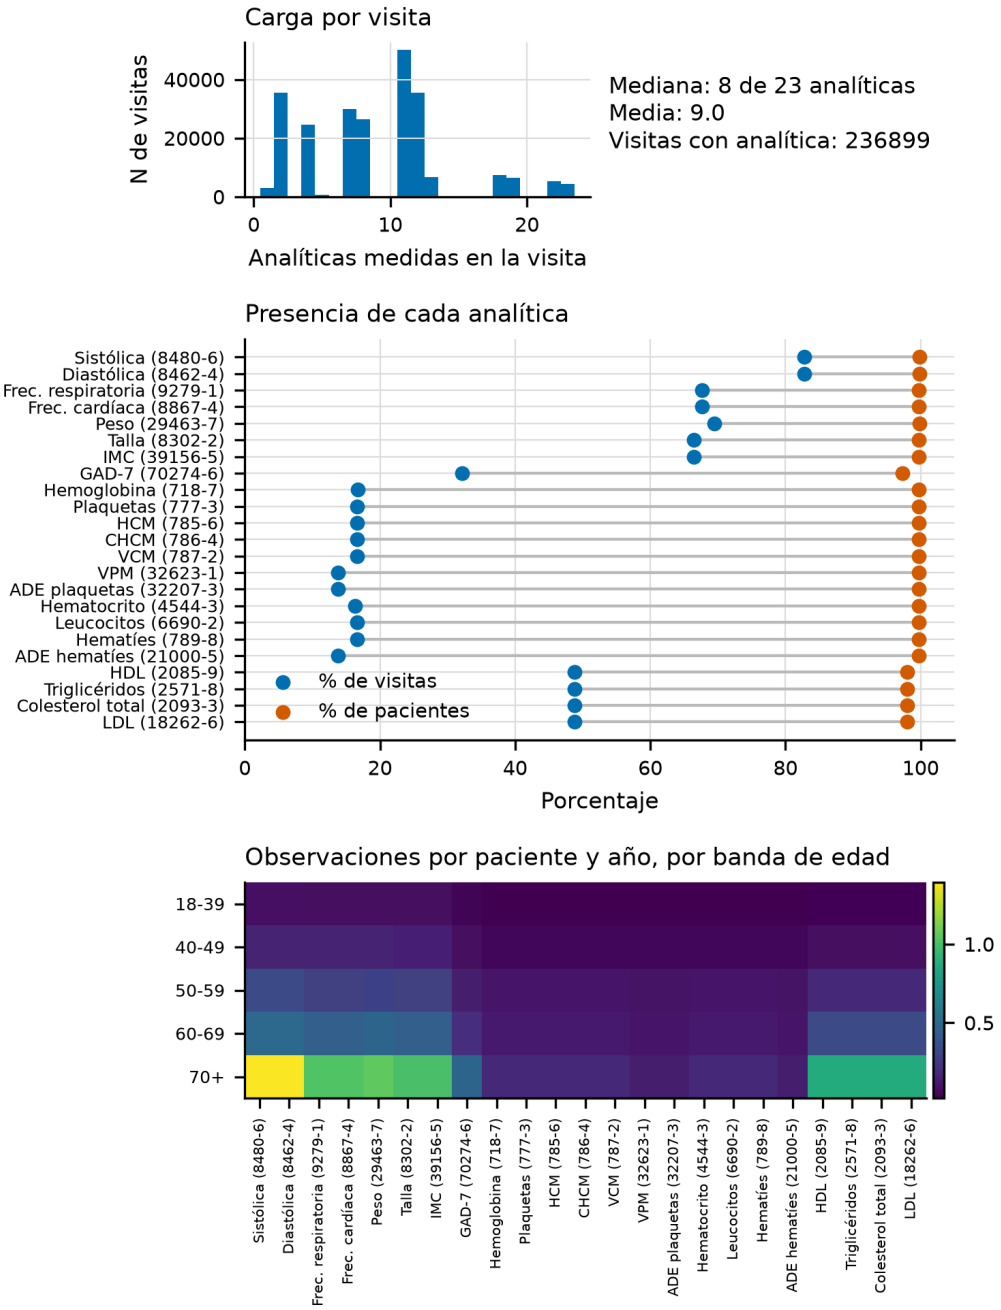


Figura 7: Analíticas por visita, presencia de cada analítica en pacientes y en visitas, e intensidad por banda de edad.

4.2.4 Magnitudes y normalización

La Figura 8 representa, para cada analítica, la distribución de los valores estandarizados que recibe el modelo, con la media en cero y la desviación en uno como referencia. Las bandas de ±5 marcan el límite a partir del cual un valor se considera extremo.

Sobre 2 143 703 valores observados, 19 de las 23 analíticas cumplen la tolerancia de media a ±0,01 de cero y desviación a ±0,01 de uno. Cuatro se salen, todas con una desviación menor del 1,5 %. Son la frecuencia respiratoria (0,972), la frecuencia cardíaca (0,986), la concentración de hemoglobina corpuscular media (media 0,017 y desviación 0,987) y los leucocitos (media −0,012). Se marcan y no se corrigen, porque el z-score se ajustó en train sobre las observaciones antes del filtrado por edad y por código, y ese orden explica la diferencia.

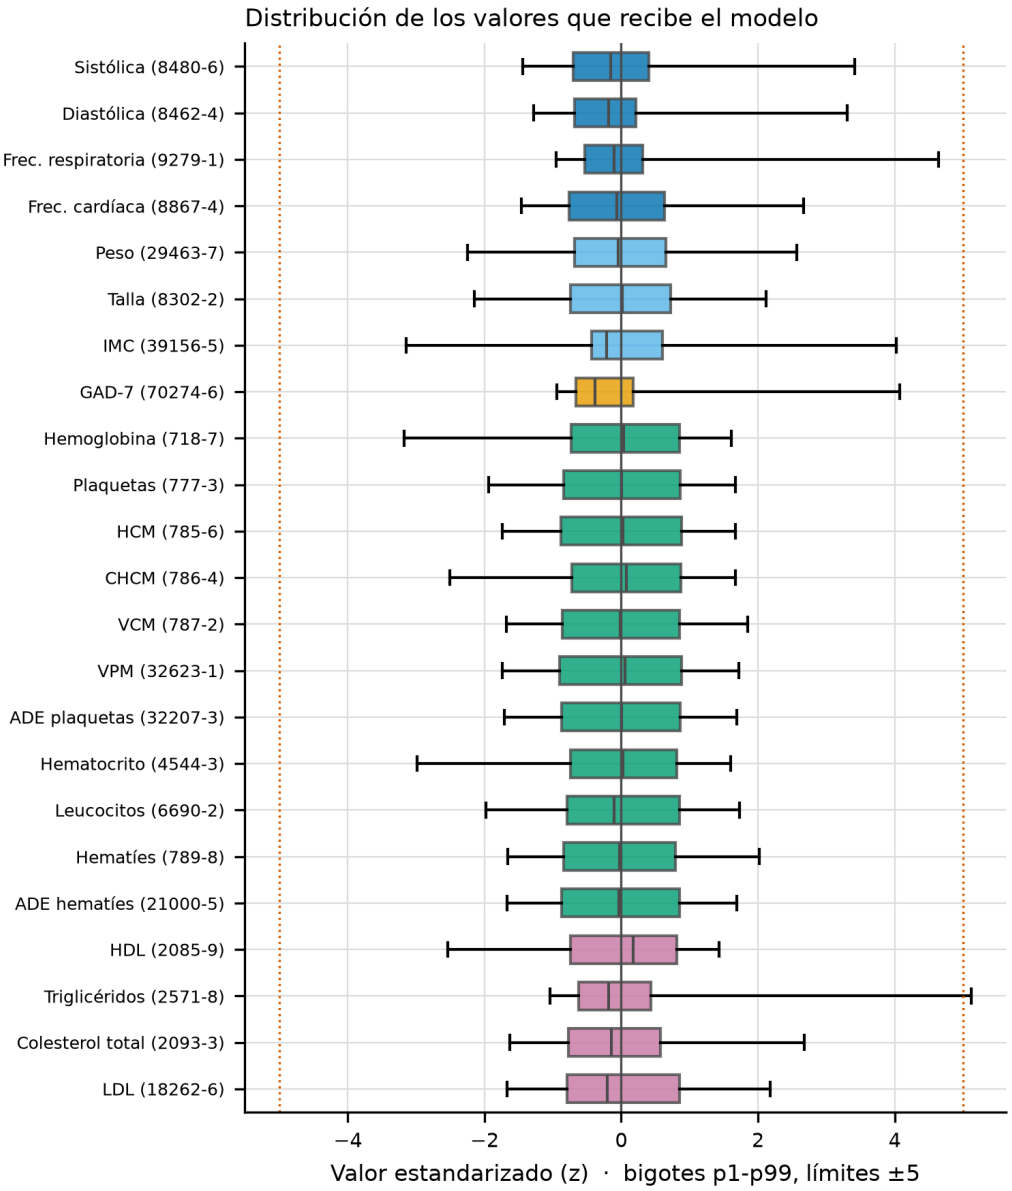


Figura 8: Distribución de los valores estandarizados observados por analítica, con los límites de ±5.

4.3 Discriminación por landmark

La Figura 9 muestra el C-index IPCW de Uno en `holdout` a lo largo de los 26 puntos de corte, de 45 a 70 años, con una banda de intervalo de confianza al 95 % obtenida por bootstrap de paciente en cada landmark. Los cinco modelos mejoran con la edad y ninguno lo hace de forma monótona. Los retrocesos locales aparecen en el 50 y en el 65, y el del 65 es el único que comparten los cinco.

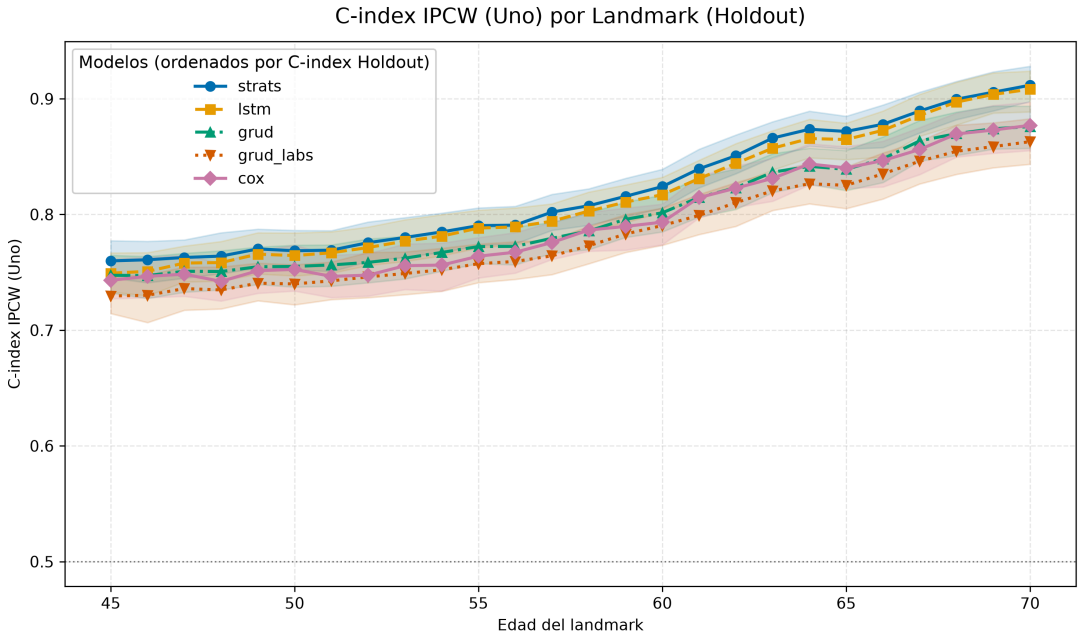


Figura 9: C-index IPCW (Uno) por edad de landmark en holdout, con intervalo de confianza al 95 % por bootstrap de paciente.

En el landmark de 45 años el C-index IPCW va de 0,730 del peor modelo a 0,760 del mejor. En el de 70 años, de 0,863 a 0,912. La tabla Tabla 9 recoge las dos anclas de cada modelo.

Tabla 9: «C-index IPCW (Uno) en holdout en los extremos de la rejilla de landmarks.»

Modelo	Landmark 45	Landmark 70
`strats`	0,760	0,912
`lstm`	0,749	0,908
`grud`	0,747	0,876
`grud_labs`	0,730	0,863
`cox`	0,743	0,877

El tamaño de cada corte no depende del modelo, porque la rejilla es común, y sí cambia mucho con la edad, por ejemplo, en el landmark de 45 años hay 12 616 pacientes evaluables y 618 eventos acumulados, mientras que en el de 70 quedan 6 996 pacientes y 227 eventos. No obstante, los eventos que caen dentro del horizonte de predicción en cada landmark crecen en sentido contrario, de 55 en el horizonte a cinco años en el landmark 45 a 108 en el landmark 70, porque un paciente de 70 años tiene más probabilidad de diagnosticarse en los cinco años siguientes que uno de 45.

4.4 Utilidad frente al modelo nulo

El índice de precisión (IPA) y el Brier IPCW, definidos en el capítulo 3, miden si el modelo mejora la estimación de la incidencia y no solo el orden de los pacientes.

La Figura 10 muestra el error por landmark y la Figura 11 el IPA por landmark. Dos cosas se ven en la segunda, el IPA es positivo en la mayor parte de la rejilla para los cinco modelos, y `cox` es el único que cruza el cero, con valores negativos en los landmarks 48, 49, 51, 53, 55 y 58 y un mínimo de −0,023 en el 48. Los otros cuatro se mantienen por encima de cero en toda la rejilla.

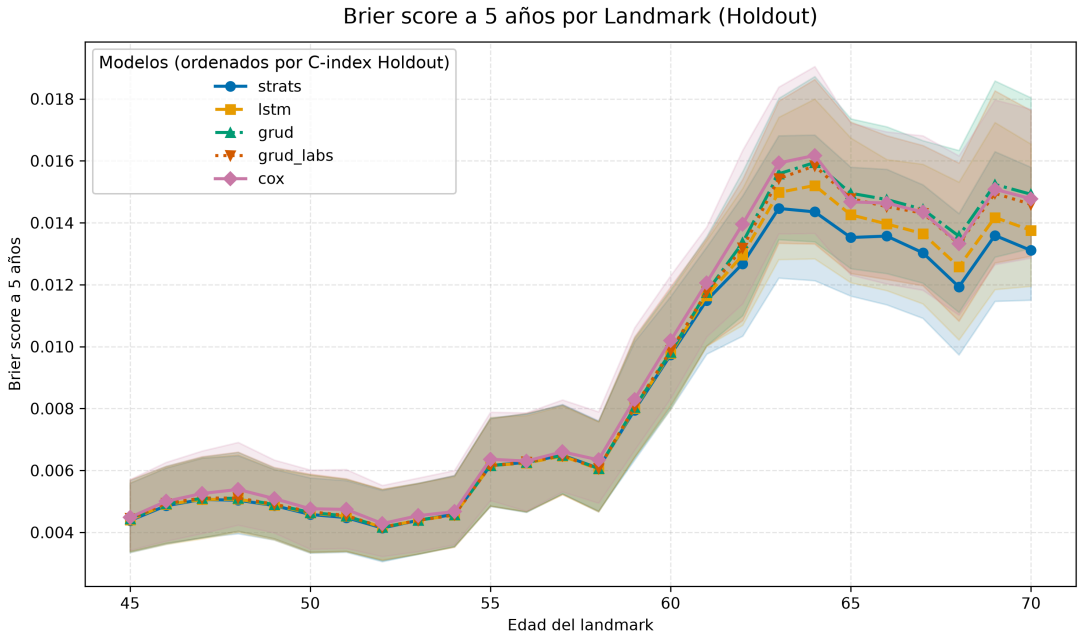


Figura 10: Brier IPCW a cinco años por landmark en holdout.

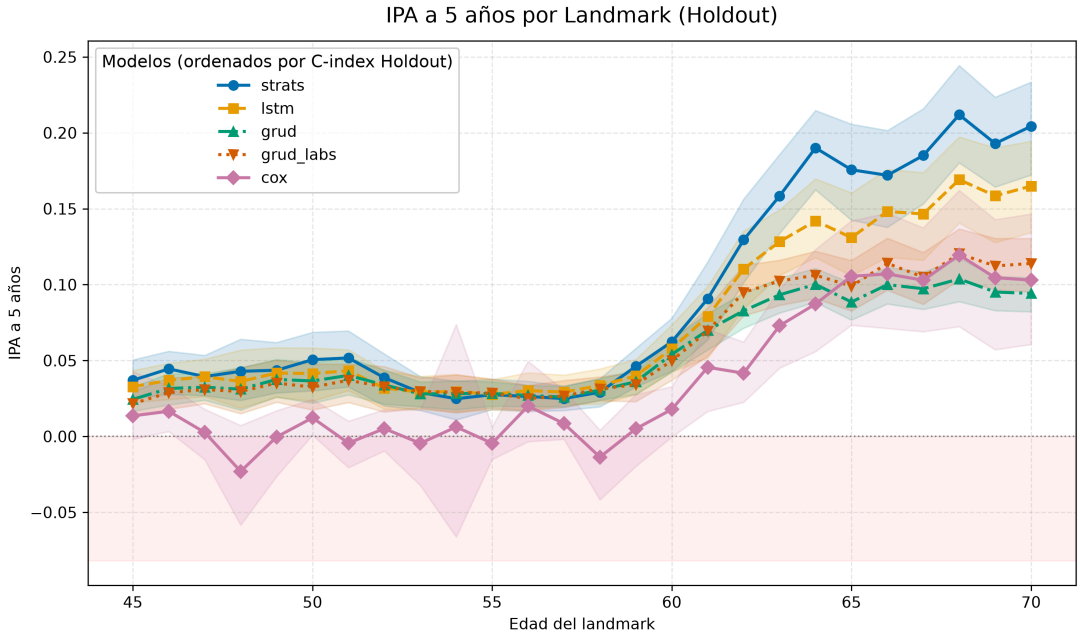


Figura 11: Índice de precisión (IPA) a cinco años por landmark en holdout, con la línea del modelo nulo en cero.

4.5 Resumen agregado por modelo

La Figura 12 reúne el resultado del estudio en tres paneles: la discriminación por landmark, la utilidad frente al nulo por landmark y los cuatro estimandos agrupados con su intervalo de confianza al 95 %. La Tabla 10 traduce el tercer panel a números.

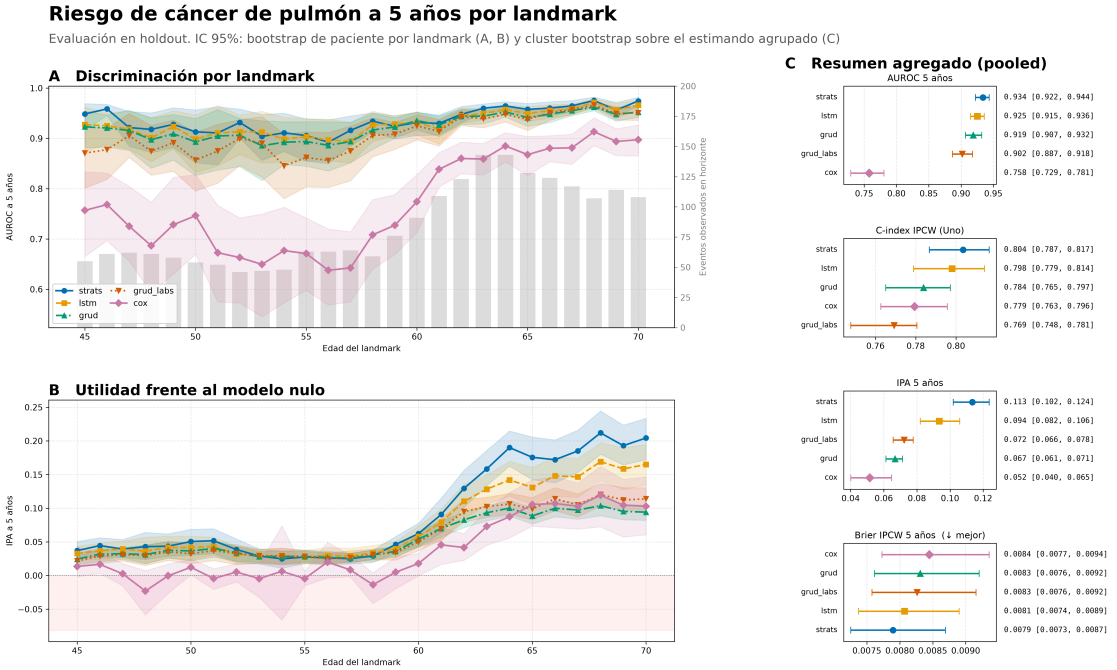


Figura 12: Riesgo de cáncer de pulmón a cinco años por landmark en holdout. Discriminación (A), utilidad frente al modelo nulo (B) y resumen agrupado (C).

Tabla 10: «Estimandos agrupados en holdout con intervalo de confianza al 95 % por cluster bootstrap. En Brier IPCW el valor bajo es el mejor.»

Modelo	AUROC	C-index IPCW	IPA	Brier IPCW
`strats`	**0,934** [0,922; 0,944]	**0,804** [0,787; 0,817]	**0,113** [0,102; 0,124]	**0,0079** [0,0073; 0,0087]
`lstm`	0,925 [0,915; 0,936]	0,798 [0,779; 0,814]	0,094 [0,082; 0,106]	0,0081 [0,0074; 0,0089]
`grud`	0,919 [0,907; 0,932]	0,784 [0,765; 0,797]	0,067 [0,061; 0,071]	0,0083 [0,0076; 0,0092]
`grud_labs`	0,902 [0,887; 0,918]	0,769 [0,748; 0,781]	0,072 [0,066; 0,078]	0,0083 [0,0076; 0,0092]
`cox`	0,758 [0,729; 0,781]	0,779 [0,763; 0,796]	0,052 [0,040; 0,065]	0,0084 [0,0077; 0,0094]

En la Tabla 10 aparecen remarcados los mejores valores de cada columna, que recaen todos en `strats`. Los cuatro modelos secuenciales se agrupan en discriminación y `cox` queda por detrás en AUROC, aunque su C-index IPCW supera al de `grud_labs`. Los cinco intervalos del IPA excluyen el cero, de modo que todos baten al modelo nulo, mientras que los del Brier se solapan por completo y no ordenan a los modelos: con una incidencia del 4 %, el error del modelo nulo ya es bajo y la cifra solo dice algo acompañada del IPA.

4.6 Ablación de códigos ICD-10-CM

Los dos GRU-D del catálogo comparten arquitectura e hiperparámetros y solo se diferencian en que `grud` recibe los códigos de diagnóstico junto a las analíticas y `grud_labs` no. La comparación entre ambos mide, por tanto, qué aporta el bloque de diagnósticos cuando todo lo demás está fijo. La Tabla 11 recoge las cinco métricas agrupadas en holdout.

Tabla 11: «Ablación de los códigos de diagnóstico: mismas arquitectura e hiperparámetros, con y sin el bloque ICD-10-CM.»

Métrica	`grud` (con códigos)	`grud_labs` (sin códigos)	Diferencia
AUROC	**0,919** [0,907; 0,932]	0,902 [0,887; 0,918]	+0,017
C-index IPCW	**0,784** [0,765; 0,797]	0,769 [0,748; 0,781]	+0,015
IPA	0,067 [0,061; 0,071]	**0,072** [0,066; 0,078]	−0,006
Brier IPCW	0,00831 [0,00760; 0,00920]	**0,00826** [0,00758; 0,00916]	+0,00005

La diferencia favorece a la variante con códigos en discriminación y no en calibración, porque gana en AUROC y en C-index IPCW, mientras que la variante sin códigos tiene un IPA algo mayor y un Brier prácticamente idéntico. Los intervalos se solapan en las cuatro métricas, de modo que ninguna diferencia es concluyente. La ganancia en discriminación es mayor en train que en holdout, un patrón compatible con una mejora pequeña y real que el tamaño del pool no permite confirmar.

4.7 Coste computacional

El estudio completo se ejecutó en una máquina local de ocho núcleos, sin GPU, con `snakemake --cores all`. La Tabla 12 recoge la duración de cada regla en esa ejecución.

Tabla 12: «Duración de cada regla en la ejecución final. Los entrenamientos y las evaluaciones se lanzaron en paralelo, de modo que sus tiempos se solapan y no son aditivos.»

Regla	Modelo	Duración
`split_cohort`	—	8 s
`eda`	—	1 m 59 s
`train`	`grud_labs`	28 m 24 s
`train`	`cox`	30 m 03 s
`train`	`grud`	30 m 49 s
`train`	`lstm`	33 m 54 s
`train`	`strats`	5 h 44 m 28 s
`eval`	`strats`	31 m 04 s
`eval`	`cox`	3 h 24 m 10 s
`eval`	`lstm`	3 h 35 m 14 s
`eval`	`grud`	3 h 37 m 25 s
`eval`	`grud_labs`	3 h 39 m 07 s
`compare`	los cinco	15 s

5
CAPÍTULO

Discusión

Los resultados del capítulo anterior piden una interpretación. Lo que se discute es qué diferencias sostienen los intervalos de confianza, por qué el modelo de Cox ordena como los demás y falla al estimar el riesgo a cinco años, qué parte del rendimiento en los cortes tardíos viene del dato y no del modelo, y hasta dónde llega lo que aportan los códigos de diagnóstico.

5.1 Análisis de la cohorte

5.1.1 Por qué la rejilla va de 45 a 70 años

La rejilla de landmarks cubre la franja en la que el cribado tiene algo que decidir. A los 45 años la incidencia acumulada de diagnóstico es prácticamente cero, y a los 70 ha llegado al 4,21 % en `holdout`. Entre esos dos puntos se concentra el crecimiento de la curva, que pasa del 1,57 % a los 60 al 4,21 % a los 70, y es donde el modelo puede separar a quien desarrollará la enfermedad de quien no.

El límite superior se justifica por el coste en muestra. En train se pasa de 9 917 pacientes en el corte de 45 a 5 458 en el de 70, casi la mitad, mientras que los eventos que caen dentro del horizonte de cinco años dejan de crecer. En `holdout` pasan de 55 en el corte de 45 a 108 en el de 70, pero el máximo está en el 63, con 143, y a partir de ahí la cuenta baja. Más allá de 70 se pierde muestra sin ganar eventos evaluables, que es lo que hace que los intervalos se ensanchen.

5.1.2 Lo que el modelo ve y con qué frecuencia se mide

El porcentaje de pacientes sin analíticas es llamativo. En el landmark 70, cerca del 68% de las muestras del modelo no tiene ninguna analítica anterior al corte, y sin embargo el 99 % de los pacientes de train acaba teniendo alguna analítica en su historia, según Figura 7 y Figura 5. Las dos cifras son ciertas y no miden lo mismo. La primera cuenta muestras, que son pares de paciente y landmark, y solo considera las analíticas anteriores al corte. La segunda cuenta pacientes a lo largo de toda su vida, incluidas las analíticas posteriores a ese corte. Como la mayor parte de las analíticas se acumula al final del seguimiento, cerca del evento o de la muerte, casi todos los pacientes acaban teniendo alguna, pero muchos no la tenían todavía en el momento del corte. De ahí que el porcentaje de muestras sin analítica previa baje del 85,44 % en el corte de 45 al 67,99 % en el de 70.

Las dos se mueven además en sentidos opuestos con la edad. La proporción de muestras sin analítica previa baja del 85,44 % en el corte de 45 al 67,99 % en el de 70. Cuando hay analíticas no son pocas, porque la mediana condicional es de 45 mediciones en el corte de 45 y de 64 en el de 70. El modelo ve, por tanto, mucha historia en pocos pacientes y ninguna en la mayoría de las muestras.

La tasa de visitas con analítica por año es menor en los pacientes con evento, con un δ de Cliff de $-0{,}272$ y un p de $1{,}1 \times 10^{-21}$. En términos estadísticos, un paciente con evento presenta menos visitas hasta el fin de seguimiento. No obstante, este contraste está condicionado, porque el fin de seguimiento por

evento se suele producir a menor edad que por otras razones y la intensidad de medición crece con la edad.

5.2 Qué diferencias soporta la evidencia y cuáles no

En discriminación, los cuatro modelos secuenciales no se separan entre sí. En AUROC, el intervalo de `lstm` [0,915; 0,936] se cruza con el de `strats` [0,922; 0,944] y con el de `grud` [0,907; 0,932], y el de `grud` se cruza con el de `grud_labs` [0,887; 0,918]. La única separación entre secuenciales es la de `strats` frente a `grud_labs`, y es estrecha, porque el límite inferior de `strats` queda por encima del superior de `grud_labs` por cuatro milésimas. En C-index IPCW la separación se reduce a ese mismo par. Los valores puntuales de STraTS son los más altos de los cuatro, pero su intervalo se cruza con el de la LSTM y con el de `grud`, así que la ventaja no está respaldada.

La utilidad frente al nulo ordena de otra manera. El IPA sí separa a los modelos en dos bloques. `strats` [0,102; 0,124] y `lstm` [0,082; 0,106] quedan por encima de `grud` [0,061; 0,071] y de `grud_labs` [0,066; 0,078], sin solapamiento en ninguno de los cuatro cruces, y `grud_labs` supera a `cox` [0,040; 0,065]. Entre `strats` y `lstm` no hay separación, y entre `grud` y `grud_labs` tampoco. La conclusión que sí se sostiene es que `strats` y `lstm` estiman mejor la incidencia a cinco años que los dos GRU-D, y no que uno de ellos sea mejor que el otro.

El Brier no separa a nadie. Los cinco intervalos se solapan en bloque, y el orden de los valores puntuales no significa nada cuando la diferencia entre el mejor y el peor cabe dentro de sus propios intervalos. Un Brier de 0,008 no describe un modelo excelente, porque con una incidencia del 4 % el modelo nulo ya obtiene un error parecido. La cifra solo informa acompañada del IPA, que es donde está la separación.

Queda así una jerarquía estrecha. Todos los modelos baten al nulo y todos ordenan por encima del azar, pero la única diferencia entre secuenciales que el bootstrap agrupado respalda es la que separa a `strats` y a `lstm` de los dos GRU-D en utilidad, más la de `strats` frente a `grud_labs` en discriminación. El resto son empates.

5.3 Horizonte frente a orden global

El modelo de Cox ocupa una posición que a primera vista es incoherente. Su C-index IPCW, 0,779, cae dentro del rango de los cuatro secuenciales y su intervalo [0,763; 0,796] se cruza con el de todos ellos, incluido el de `strats`. Su AUROC a cinco años, 0,758, queda catorce centésimas por debajo del peor de los secuenciales y su intervalo [0,729; 0,781] no toca ninguno. Un mismo modelo ordena como los demás y, sin embargo, apenas distingue quién se diagnostica en los próximos cinco años.

Las dos son métricas de discriminación, y la diferencia está en los pares que compara cada una. El C--index recorre todo el seguimiento y comprueba, para cada pareja ordenable, si el de mayor riesgo se diagnostica antes, con independencia de cuándo ocurra el evento. El AUROC a cinco años se queda en la ventana y compara a los diagnosticados dentro de ella con los que siguen vivos al cerrarla. Un modelo puede acertar en el orden a lo largo de cuarenta años y fallar en la ventana corta, y eso es lo que le ocurre a Cox. Su entrada es tabular y con la última observación arrastrada, de modo que su riesgo apenas cambia con el tiempo y describe bien qué paciente tiene más riesgo, pero no cuándo se va a diagnosticar. El cribado pregunta lo segundo, y ahí el modelo se queda en 0,758. El Brier y el IPA, que sí dependen del nivel del riesgo y no solo de su orden, también lo sitúan el último.

El desequilibrio no lo convierte en un modelo peor en todo. Es un modelo que ordena y no calibra, y esa distinción tiene consecuencias prácticas. Para decidir a quién se le hace un seguimiento más estrecho basta el orden, y Cox sirve. Para decidir a quién se le ofrece una prueba con un umbral de riesgo concreto hace falta el nivel, y ahí Cox se queda corto.

Entre los secuenciales el equilibrio es más parecido. `strats` y `lstm` son los que mejor combinan las dos caras, porque están arriba en discriminación y también en IPA, mientras que los dos GRU-D bajan en

ambas. Ninguno de los cuatro muestra el desacuerdo interno de Cox, y por tanto ninguno plantea la elección entre orden y nivel.

5.4 El tramo en torno al landmark 60

El capítulo anterior muestra una trayectoria creciente del C-index con la edad y un tramo en torno a los 60 donde la pendiente se acentúa. El paso de 60 a 61 es el mayor incremento anual de toda la serie en `strats` (+0,0154), en `lstm` (+0,0139) y en `cox` (+0,0212), el tercero en `grud` (+0,0133).

La razón es que entre los cortes de 59 y 63, los eventos que caen dentro del horizonte de cinco años pasan de 76 a 143 en `holdout`, casi el doble, mientras que el número de pacientes baja de 9 639 a 8 796. Con más eventos y menos pacientes, la discriminación se estima mejor y sube. El acelerón no dice que el modelo mejore a esa edad, dice que la tarea se vuelve más fácil de medir, por ejemplo en el corte de 63, donde hay 143 eventos en la ventana frente a los 55 del corte de 45.

5.5 Qué aportan realmente los diagnósticos

La ablación de los códigos deja una ganancia pequeña en discriminación y ninguna en calibración. `grud`, que recibe los códigos, gana 0,017 de AUROC y 0,015 de C-index IPCW sobre `grud_labs`, y la ganancia se mantiene en train (0,800 frente a 0,783), así que no es un artefacto de `holdout`. Los intervalos, en cambio, se solapan en las cuatro métricas, y en calibración el orden se invierte, porque `grud_labs` tiene un IPA mayor (0,072 frente a 0,067) y un Brier prácticamente igual.

Con estos datos no se puede afirmar que los códigos aporten. Se puede decir que la ganancia en discriminación es pequeña y consistente, y que no hay evidencia de que mejoren la estimación de la incidencia.

El resultado choca con lo que cabría esperar. El tamaño del vocabulario es la primera explicación, porque las categorías observadas en train son 119 sobre las 1 312 posibles, de modo que el canal de códigos dispone de poca señal que aprender. La segunda sale del análisis exploratorio. Si el 79,06 % de las muestras no tiene ninguna analítica previa, los diagnósticos son la única información disponible en cuatro de cada cinco muestras, y quitar los códigos debería hundir el rendimiento de `grud_labs` en esas muestras. No lo hunde, y eso deja una pregunta abierta sobre de dónde sale su discriminación. La respuesta más probable es que proceda del 21 % de muestras que sí tienen analíticas y de la edad del corte, pero comprobarlo exige un análisis por subgrupo que este trabajo no ha hecho.

La ablación está bien construida, porque mantiene fijos arquitectura e hiperparámetros y solo cambia la entrada, y por eso el empate es informativo. El resultado, en cambio, no se puede extrapolar al valor clínico de los diagnósticos en general. Lo que se mide es la contribución marginal de un vocabulario de 119 categorías en una cohorte sintética, no el peso de un diagnóstico en la práctica.

La discriminación no separa a los modelos secuenciales y la utilidad sí, de modo que el resultado del estudio se sostiene en el IPA y no en el C-index. Cox ordena y no calibra, y esa distinción pesa más que su posición en la tabla. Los códigos de diagnóstico aportan poco en esta cohorte, y el motivo sigue abierto. De ahí salen las preguntas que ocupan el capítulo siguiente, la calidad del generador, el tamaño de la muestra efectiva, la ausencia de búsqueda de hiperparámetros y la dependencia del proceso asistencial que revela el muestreo informativo.

CAPÍTULO 6

Limitaciones y trabajo futuro

Ningún resultado de esta memoria está libre de condiciones. Unas vienen del código, porque el transformer no encaja en el contrato común de los modelos recurrentes. Otras vienen del dato, porque la cohorte es sintética y el generador no está documentado hasta el último detalle. A esas dos se suman ocho amenazas a la validez, y el final del capítulo recoge el trabajo que las cerraría.

6.1 Límites del contrato común de encoder ante arquitecturas no recurrentes

Los cuatro modelos recurrentes comparten un mismo contrato de entrada. Cada lote llega como trece elementos (analíticas, máscaras de observación, intervalos entre visitas, longitudes, sexo, tiempo desde la fecha índice, códigos de diagnóstico aplanados con sus desplazamientos, duraciones, eventos, edades de landmark, pesos e identificadores de paciente) y el modelo los recibe por posición. Ese contrato funciona porque GRU-D y LSTM esperan la misma forma de tensor, y es lo que permite que el bucle de evaluación sea uno solo para los cuatro.

STraTS no encaja en él. Consume la historia como una secuencia de tripletas (instante, variable, valor), su lote tiene doce elementos y su función de avance recibe argumentos por nombre en lugar de por posición. Ante esa diferencia, el pipeline no amplió el contrato común: escribió un adaptador paralelo que recopila las predicciones del transformer por su cuenta. El transformer no es incompatible con la evaluación: el adaptador devuelve la misma tupla de predicciones y las métricas se calculan con las mismas funciones para los cinco modelos. El problema es de contrato: no se pudo extender y hubo que bifurcarlo, con un coste de mantenimiento que no afecta a la comparación.

El coste de esa bifurcación es de mantenimiento, dos rutas de recolección que hay que mantener sincronizadas, con el riesgo de que una corrección aplicada en una no llegue a la otra. A ello se suma un límite de la adaptación que comparten las dos familias, porque tanto los modelos recurrentes como el transformer truncan la secuencia a los 200 eventos anteriores al landmark. El efecto no es el mismo en ambos casos, porque la unidad de la secuencia no es la misma. Los recurrentes trabajan con instantes, de modo que cada posición agrupa todas las analíticas y los diagnósticos de una misma fecha, mientras que el transformer trabaja con eventos y cada posición es una medición suelta. Con el mismo tope de 200 posiciones, el transformer cubre menos tiempo clínico y atiende a una historia más corta. A eso se añade que devuelve un riesgo escalar por muestra y no una trayectoria de riesgos a lo largo del tiempo.

6.2 Límites del dato sintético

Ninguna conclusión de esta memoria describe pacientes reales. Los autores de Synthea advierten que sus registros son realistas pero no reales y que no son lo bastante ricos para la investigación clínica, y el trabajo del que proceden estos ficheros cierra su discusión diciendo que el modelo resultante no puede usarse en la asistencia real [23], [25].

Lo que sobreviviría a datos reales es la parte metodológica, o sea todo el pipeline de extremo a extremo, el protocolo común de cohorte, rejilla de landmarks y horizonte, la maquinaria de evaluación con

reponderación por censura y bootstrap, y la documentación de las decisiones de diseño. Nada de eso depende del generador.

Lo que no sobreviviría son los valores. Los cinco juegos de métricas describen el comportamiento de los modelos sobre este generador, así que no hay razón para esperar que se mantengan. La conclusión sobre los códigos de diagnóstico es el caso más claro, porque en una historia clínica real esos códigos proceden de la práctica asistencial y pueden ser mucho más informativos que en una población simulada.

Queda un límite de trazabilidad que afecta a la reproducibilidad. La versión del generador no consta ni en el artículo ni en su material complementario, así que los ficheros no pueden regenerarse con exactitud desde su descripción, y la semilla con la que se produjeron tampoco está documentada. Los datos, eso sí, están identificados y son los mismos que publicó el trabajo de referencia.

6.3 Amenazas a la validez

Estas son las amenazas que pueden discutirse al resultado, con la evidencia que las sostiene y lo que no permiten concluir. Las cuatro primeras estaban ya identificadas, las cuatro últimas se añaden tras comprobar el alcance de cada una.

6.3.1 Riesgos competitivos tratados como censura independiente

La cohorte define el evento como el primer diagnóstico de cáncer de pulmón y cierra el seguimiento por prioridad: diagnóstico, después muerte y después último contacto. Un paciente que muere sin diagnóstico queda por tanto censurado en la fecha de su muerte, y la evaluación trata esa censura como independiente del riesgo. El aparato de métricas está construido para censura a la derecha con reponderación por la inversa de la probabilidad de censura, y no incorpora ningún modelo de riesgos competitivos. La consecuencia es que las probabilidades deben leerse como riesgo de diagnóstico mientras el paciente siga vivo y en seguimiento, no como probabilidad de enfermar a lo largo de la vida.

6.3.2 Una sola semilla por modelo

Cada modelo se entrena una vez. La partición de `discovery` en train y validación usa una semilla fija y los bootstrap también, pero no hay réplicas de entrenamiento ni semilla de inicialización en el código de entrenamiento, de modo que los pesos no son reproducibles bit a bit y no existe una medida de la variabilidad entre entrenamientos. Los intervalos que acompañan a todas las métricas son de bootstrap sobre el conjunto de evaluación, es decir, cubren el remuestreo de pacientes y no la varianza de inicialización: dos ejecuciones del mismo pipeline pueden dar cifras distintas sin que eso sea un error de cálculo.

6.3.3 Ausencia de línea base clínica y de validación externa

Los cinco modelos se comparan entre sí y contra un modelo nulo estadístico, pero ninguno se compara contra un modelo de riesgo clínico establecido, del tipo cuestionario estático con un puñado de predictores. Tampoco hay validación externa, ya que, aunque `holdout` es una población distinta de `discovery`, sale del mismo generador y del mismo proceso de construcción, así que mide capacidad de generalización dentro del simulador y no traslado a otra población. Es la amenaza que más acota el alcance de la comparación, porque las diferencias entre modelos pueden convivir con un rendimiento absoluto distinto en cuanto cambie la población.

6.3.4 STraTS sin preentrenamiento autosupervisado

El transformer se entrenó desde cero y solo con la verosimilitud parcial de Cox, mientras que la arquitectura publicada se apoya en una tarea auxiliar de predicción de valores observados que se entrena primero y se afina después. El artículo distingue dos variantes en su estudio de ablación, ss-

y ss+, que se refieren a los modelos entrenados sin y con autosupervisión respectivamente [15]. La adaptación conserva el codificador pero no la fase previa, así que lo que se evalúa aquí equivale a ss-, de modo que la comparación mide el rendimiento de STraTS con este pipeline y no el de STraTS en su forma publicada. Es un límite de fidelidad al método citado y, a la vez, una desventaja concreta para el transformer frente a los modelos recurrentes, que no tienen una fase equivalente.

6.4 Trabajo futuro

Casi todo lo anterior se traduce en trabajo concreto:

- Semillas y réplicas: entrenar cada modelo con varias semillas y reportar la varianza entre entrenamientos, además del intervalo por bootstrap que ya existe. Es el cambio más barato y el que más refuerza cualquier afirmación comparativa, porque hoy solo se puede hablar de un entrenamiento por arquitectura.
- Preentrenamiento autosupervisado de STraTS: recuperar la tarea auxiliar de predicción de valores observados del artículo original antes del ajuste con la pérdida de Cox. Es lo que permitiría comparar el transformer en las condiciones en que se propuso.
- Una línea base clínica y validación externa: añadir un modelo de riesgo establecido al catálogo, con su cuestionario estático, y repetir la evaluación sobre una cohorte real de otra procedencia. Sin ese paso, las diferencias entre arquitecturas no dicen nada sobre su utilidad en cribado.
- Riesgos competitivos: sustituir la censura por muerte por un modelo de riesgos competitivos, con la muerte por otras causas como evento que compite con el diagnóstico, y recalcular la incidencia con esa estructura. Es lo que permitiría leer las probabilidades como riesgo de enfermar a lo largo de la vida y no como riesgo mientras el paciente siga vivo y en seguimiento.

A esa lista se suman dos mejoras de ingeniería que salen del propio análisis, unificar el contrato de recolección de predicciones para que el transformer deje de tener una ruta propia y revisar el truncamiento de historias largas, porque el recorte deja fuera la cola de las historias más largas.

CAPÍTULO 7

Conclusiones

Los tres objetivos de Sección 1.4 se pueden cerrar con la evidencia que ya está sobre la mesa. No hay resultados nuevos en lo que sigue ni debate abierto, solo el balance de qué se cumplió y con qué.

7.1 Cierre de objetivos

El pipeline quedó construido y ejecutado de extremo a extremo. Una sola orden encadena la partición de la cohorte, el análisis exploratorio, los cinco entrenamientos, las cinco evaluaciones y la comparación, y el catálogo de modelos vive en el fichero de configuración, de modo que añadir una arquitectura consiste en añadir un bloque.

La representación se resolvió por arquitectura y no con una codificación única. Los cinco modelos parten de la misma cohorte (12 069 pacientes en train, 3 018 en validación y 15 346 en `holdout`), de las mismas secuencias construidas una sola vez y de los mismos 26 cortes entre los 45 y los 70 años con un horizonte de cinco años. Cada arquitectura recibe esa historia en la forma que su mecanismo admite, y la comparación sigue siendo justa porque el dato de partida es el mismo y el filtro de variables reveladoras se aplica a todas.

La comparación se hizo bajo un protocolo idéntico para los cinco, incluida la variante sin códigos de diagnóstico. Los cinco modelos tienen sus cinco métricas con intervalo de confianza en el mismo formato de artefacto.

7.2 Reflexión final

Lo que este trabajo deja es un método, y las cifras que lo acompañan son de un generador sintético. El pipeline, el protocolo común de cohorte, rejilla y horizonte, y el aparato de evaluación con reponderación por censura y bootstrap son piezas que no dependen del generador y que se pueden aplicar a un registro real sin cambios de fondo. Los números, en cambio, describen lo que hacen estos modelos sobre estos datos, y no hay razón para esperar que se sostengan fuera de ellos.

En lo personal, este trabajo ha supuesto un reto. El análisis de supervivencia y las series temporales irregulares quedan fuera del núcleo habitual del máster, y el marco teórico de este trabajo, junto con la orientación del tutor, me ha permitido incorporarlos y completar mi formación en un ámbito que no había trabajado antes. Ha sido gratificante comprobar que esos conocimientos sirven para algo tan concreto e importante como un cribado médico, un campo en el que el desarrollo de la inteligencia artificial puede ser de mucha utilidad a los profesionales facultativos en la labor de prevenir enfermedades.

Apéndice

A

Apéndice

Modelo predictivo estático sobre corte transversal

Este primer capítulo aborda un cribado general con el objetivo de predecir indicios de cáncer de pulmón. Se trata de un estudio estático, con una base de datos puntual, es decir, no se implementarán modelos longitudinales en el tiempo, sino un corte transversal en el historial médico de los pacientes en el preciso momento de la toma de datos.

A.1 Presentación de los datos

Se introduce el conjunto de datos que se utilizará para este primer capítulo. Los datos provienen de la plataforma de datos sintéticos *Synthea*, y usaremos como referencia el estudio realizado en el artículo [25].

Como un primer aproach, realizaremos un preprocesamiento básico de los datos, imputando NAs y estandarizando las variables numéricas para el correcto funcionamiento de los algoritmos de aprendizaje automático. Para ello, creamos el siguiente pipeline de preprocesamiento y planteamiento de un modelo de regresión logística:

```
from sklearn.compose import make_column_selector, ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import OrdinalEncoder, StandardScaler
from sklearn.feature_selection import SelectKBest
from sklearn.impute import SimpleImputer


cat_pipeline = Pipeline([
    ("codif", OrdinalEncoder(handle_unknown='use_encoded_value',
unknown_value=-1)),
    ("imputer",SimpleImputer(strategy="constant",
fill_value=0.0,keep_empty_features=True)),
])

num_pipeline = Pipeline([
    ("imputer",SimpleImputer(strategy="constant",
fill_value=0.0,keep_empty_features=True)),
    ("scaler", StandardScaler())
])

preprocesamiento = ColumnTransformer([
    ("cat", cat_pipeline, make_column_selector(dtype_include="object")),
    ("num", num_pipeline,make_column_selector(dtype_exclude="object"))
```

```
], remainder=(SimpleImputer(strategy="constant", fill_value=0.0)),
verbose_feature_names_out=False)

seleccion = Pipeline([
    ("preprocesamiento", preprocesamiento),
    ("50mejores", SelectKBest(k=50)),
])

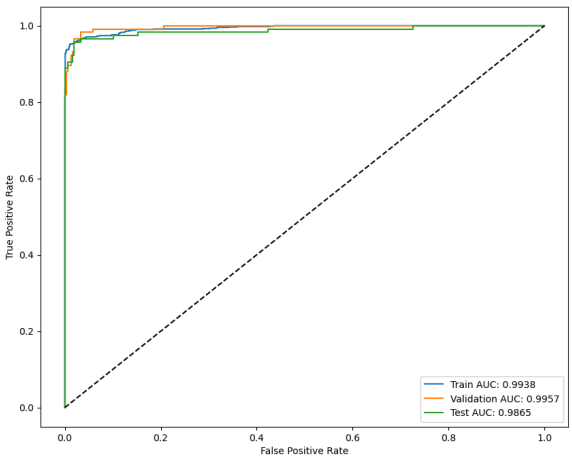
regresor = Pipeline([
    ("seleccion", seleccion),
    ("logistic_regression", LogisticRegressionCV(max_iter=1000,
n_jobs=-1,scoring="recall", cv=5,random_state=625)),
])
```

Este pipeline obtiene un rendimiento excelente en el conjunto de test:

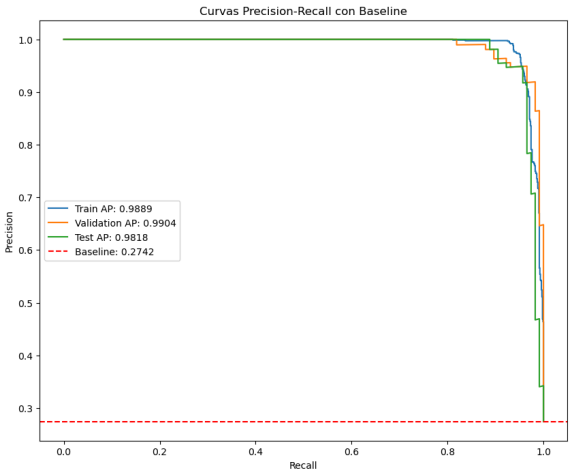
Tabla A.1: «Reporte de clasificación del modelo logístico con pipeline inicial.»

Accuracy	Recall	F1	AUC
0.97	0.95	0.97	0.986

Y unas curvas ROC y PR:



(a) Curvas ROC en los conjuntos de train, test y validación.



(b) Curvas PR para el modelo logístico

Figura A.1: Curvas de evaluación del modelo logístico.

A.2 Selección de características

En el anterior apartado hemos obtenido un rendimiento excelente en el conjunto de test con únicamente 50 variables del dataset original. Es lógico preguntarse, ¿cuántas variables son necesarias para obtener un rendimiento óptimo?. En esta sección se elabora un análisis del rendimiento del modelo aplicando técnicas de cross-validation anidado para obtener una estimación veraz del rendimiento del modelo, teniendo en cuenta tanto el sesgo como la varianza del modelo.

La idea es la siguiente: en lugar de realizar una única partición del conjunto de datos, se emplea una estrategia robusta denominada validación cruzada anidada (*Nested Cross-Validation*). En el bucle externo (`outer_cv`), se evalúa la capacidad de generalización dividiendo el conjunto de entrenamiento en 5 particiones estratificadas. A su vez, para cada una de estas iteraciones, se ejecuta un bucle interno (`inner_cv` con otras 5 particiones) mediante un ajustador paramétrico (`GridSearchCV`) encargado de encontrar los hiperparámetros óptimos. En este espacio de búsqueda se evalúa el rendimiento

del *pipeline* iterando sobre el número de características seleccionadas ($k \in \{1, 3, 5, 10, 20, 50\}$) y penalizaciones de regularización matemática (C), usando el área bajo la curva exhaustiva (PR-AUC o `average_precision`) como métrica objetivo.

FIGURA FALTANTE (referencia huérfana preexistente del TFM anterior). `nestedCV_num_variables.png` no está en el repositorio ni en el historial git. Regenerar o marcar como perdida.

Figura A.2:

A.3 Ingeniería de características médicas

En este apartado, vamos a adentrarnos en los sistemas de nomenclatura médicos estándar usados para la codificación de las variables del dataset. En primer lugar, se debe acceder al repositorio github del artículo y extraer la codificación de las variables. Se observan que todas las variables, excepto tres, empiezan con el prefijo «C-» y luego un número identificativo cuya nomenclatura dependerá del tipo de variable médico.

Principalmente, en el análisis de datos médicos solemos encontranos con cuatro tipos de variables:

- **Diagnósticos:** Se refiere al registro médico de enfermedades, signos o síntomas padecidos por el paciente a lo largo de su historia clínica. En nuestros datos, estas dolencias suelen mapearse utilizando **SNOMED-CT**[39].
- **Procedimientos:** Pruebas analíticas, estudios por imagen o intervenciones quirúrgicas solicitadas por el equipo médico a un paciente para la prevención, detección o tratamiento de diagnósticos y riesgos subyacentes. También se usa para estos el sistema SNOMED-CT.
- **Medicamentos:** Comprende el historial de fármacos y principios activos prescritos, dispensados o administrados al paciente con fines terapéuticos o paliativos. Se mapean mediante el vocabulario **RxNorm** [40]
- **Resultados de laboratorio:** Consiste en mediciones de laboratorio o evaluaciones fisiológicas (por ejemplo, analíticas de sangre o valores de presión). Estos resultados sirven como indicadores del estado biológico del modelo. En el dataset siguen la nomenclatura **LOINC** [2].

A continuación, declararemos el plan de ejecución según el sistema de nomenclatura para realizar una extracción de características adecuado al objetivo de nuestro análisis.

A.3.1 Atributos reveladores de cáncer de pulmón

El alto rendimiento del primer pipeline básico implementado anteriormente hace sospechar acerca de un problema de *data leakage* en el dataset inicial. Probablemente, entre las 765 variables predictoras de las que disponemos existan algunas de ellas que constituyan marcadores tumorales que pueden estar influyendo de manera crucial en el modelo pero que, sin embargo, no son marcadores habituales en la población general sino muestras de que un paciente ya está en altas sospechas o confirmación del tumor.

A simple vista, podemos detectar variables sospechosas como: `C-88040-1`: *Response to cancer treatment* o `C-59557-9`: *Treatment status Cancer*, que son marcadores tumorales del estado oncológico del paciente. Además, de estas variables evidentes, buscaremos en el análisis anterior las variables más extrañamente relevantes.

Los resultados de esta revisión se encuentran en el apendice

A.3.2 Diagnósticos y procedimientos

Para la estandarización de este tipo de variables, se emplea SNOMED-CT (*Systematized Nomenclature of Medicine – Clinical Terms*). Tal y como indica el Ministerio de Sanidad español [39], se trata de la terminología clínica de mayor amplitud y precisión a nivel global, cuyo propósito es permitir a los profesionales sanitarios codificar y comunicar información clínica de forma adecuada e inequívoca.

Las variables del dataset ya siguen esta nomenclatura, sin embargo, aprovecharemos la estructura jerárquica de SNOMED para elaborar agrupaciones ontológicas y conseguir de esta manera reducir la granularidad de la base de datos inicial.

A.3.2.1 Despliegue SNOMED Browser local

Inicialmente, se trató de interactuar con la API pública de SNOMED International [41] con consultas ECL con el objetivo de poder extraer la estructura de padres e hijos de un cierto diagnóstico. Por ejemplo, tener *anemia* (con código SNOMED 271737000), se situa en la estructura de SNOMED como descendiente de *trastorno de componente celular sanguíneo* (414022008), que a su vez es descendiente de *hallazgo relacionado con el sistema inmunitario, la sangre y los linfáticos* (299691001). Y todo esto es accesible mediante la consulta ECL: `>> 271737000 |anemia|`.

No obstante, durante este intento surgieron limitaciones debido al gran número de consultas que se debía realizar. Para superar estas limitaciones, se optó por desplegar una infraestructura propia de servidor terminológico. Se seleccionó **Snowstorm**, la implementación de referencia de código abierto mantenida por SNOMED International y se realizó mediante contenedorización con **Docker.**

La carga de la ontología médica se realizó mediante la importación de archivos *International Edition* de SNOMED CT, debido a que esta era la versión usada en nuestras variables iniciales. Se completó la indexación de conceptos con aproximadamente 526000 conceptos activos , relaciones y descripciones.

A.3.2.2 Extracción de ancestros

En este punto, se realiza el reconocimiento de los códigos SNOMED de las variables y las consultas de ancestros de estos códigos para su agrupación por ontología médica. La metodología seguida fue la siguiente:

- Los diagnósticos, divididos en *disorder* y *finding* en la nomenclatura SNOMED se sometieron al proceso de análisis de ancestros con la heurística de agrupar unicamente las enfermedades poco frecuentes en nuestros datos. Además, se eliminaron las variables con más de un 99% de los registros nulos. El resultado obtenido fue: de las 178 variables iniciales de *disorder* y *finding* se redujo hasta unas 90 variables más generales.
- Los procedimientos, comprendidos en SNOMED por las categorías *procedure* y también *therapy* fueron sometidos al mismo proceso, teniendo en este caso como resultado la reducción del número de variables de 186 a 123.
- El resto es una mezcla de variables sociodemográficas, situaciones sociales o atributos relevantes no incluidos en los grupos anteriores. Este grupo aporta 14 variables.

A.3.2.3 Referencias cruzadas con nomenclatura CIE-10 diagnósticos

La Clasificación Internacional de Enfermedades (CIE) es un sistema de codificación desarrollado por la Organización Mundial de la Salud (OMS) para clasificar enfermedades y otros problemas relacionados con la salud [42]. Este sistema se utiliza ampliamente en todo el mundo para la codificación de diagnósticos médicos, lo que facilita la comunicación entre profesionales de la salud y la recopilación de datos epidemiológicos.

El repositorio oficial de SNOMED CT ofrece también un mapeo de sus conceptos a CIE-10, lo que nos permite realizar una referencia cruzada entre ambas nomenclaturas. La relación no es biyectiva, de manera que podremos perder conceptos específicos de SNOMED, pero a cambio ganaremos en interpretabilidad y una reducción de variables que puede ser beneficiosa para el análisis estadístico.

A.3.3 Medicamentos

Originalmente aparecen codificados en RxNorm. Desarrollado por la Biblioteca Nacional de Medicina de EE. UU. (NLM), esta es una nomenclatura terminológica que normaliza los nombres de los medicamentos clínicos y presentan una granularidad profunda (una variable por principio activo). [40]

Nuestro objetivo fue reducir la granularidad y agrupar medicamentos por zona y efecto. Para ello, realizamos un mapeo de RxNorm a ATC. La nomenclatura RxNorm está pensada para logística y

prescripción, por lo que su alta especifidad es innecesaria para un análisis estadístico y puede llegar a generar demasiado ruido. El sistema ATC (Anatomical Therapeutic Chemical) es mantenido por la Organización Mundial de la Salud (OMS) [43]. A diferencia de RxNorm, que se centra en el principio activo y la receta exacta, el ATC organiza los fármacos según dónde actuan y qué hacen. Además, la codificación ATC presenta niveles de especifidad del 1 al 5 siendo el nivel 5 el nivel más específico (principio activo) y el 1 la zona del cuerpo a la que afectan, por lo que nos permite escoger el nivel de granularidad que deseemos.

En este caso, se realizó el mapeo de los principios activos de RxNorm a ATC nivel 5 y después se generalizó, agrupando con códigos ATC nivel 2. A continuación se muestra el ejemplo:

Tabla A.2: «Ejemplo de mapeo de RxNorm a ATC nivel 2.»

RxNorm	Nombre RxNorm	ATC nivel 5	ATC nivel 2	Nombre ATC nivel 2
562251	Amoxicillin 250 MG / Clavulanate 125 MG Oral Tablet	J01CR02	J01	Antibacterianos para uso sistémico

Finalmente, se redujo en número de medicamentos de 200 principios activos iniciales a 43 variables interpretables y con sentido clínico para nuestro análisis.

A.4 Resultados de laboratorio

Estas variables están codificadas según la nomenclatura LOINC, que es el estándar internacional para la identificación de mediciones de salud, observaciones clínicas y documentos [2].

De todas las incluidas originalmente, haremos una selección de las más comunes para el análisis.

A.5 Modelos predictivos de aprendizaje automático.

El proyecto que plantamos se enmarca en el mundo de la inteligencia artificial y el aprendizaje automático como un problema de aprendizaje supervisado, donde tenemos un conjunto de datos con variables predictoras y una variable objetivo, y queremos entrenar un modelo que pueda predecir la variable objetivo a partir de las variables predictoras. En nuestro caso, la variable objetivo es el diagnóstico de cáncer de pulmón, y las variables predictoras son el resto de variables del dataset.

Para la realización del aproach inicial recurrimos a uno de los modelos más tradicionales en el mundo del aprendizaje automático, la regresión logística. Este modelo es un modelo lineal, es decir, se trata de modelar la variable objetivo en base a una combinación lineal de características. A pesar de su simplicidad, es un modelo efectivo que puede ser utilizado como línea base para comparar con otros modelos más complejos.

Nuestro objetivo ahora es aumentar la complejidad y trabajar con algoritmos más sofisticados, que puedan extraer información más completa de los datos (relaciones no lineales, interacciones complejas, etc.) y que nos permitan obtener mejores resultados. A continuación se describen con detalle los algoritmos que se usan en este proyecto. Principalmente, introduciremos métodos basados en árboles. Estos algoritmos nacen de aplicar a un conjunto de árboles de decisión distintos métodos de ensamblaje. Dependiendo del tipo de ensamblaje tenemos:

- Bagging: Se basa en la idea de usar un predictor determinado sobre distintos subconjuntos de datos del conjunto de entrenamiento elegidos muestra a muestra con reemplazamiento. Gracias a esto, el modelo predictivo final es más robusto ante el sobreajuste, ya que pierde la dependencia excesiva de los modelos al conjunto de entrenamiento.
- Boosting: se refiere a cualquier método de ensamblaje que combine una serie de aprendices débiles para conformar un modelo predictivo más complejo y potente.

A.5.1 Random Forest

Es un método de ensamblaje de árboles de decisión entrenado con la metodología bagging. Se basa en la generación de un gran número de árboles en una muestra *bootstrap*.

Consiste en aplicar secuencialmente el siguiente algoritmo,

1. Tomar $B = 500, 1000, \ldots$ Desde $b = 1$ hasta B
    1. Generar una muestra con reposición del mismo tamaño que la muestra de aprendizaje (muestra bootstrap)
    2. Construir un árbol T_b en la muestra anterior repitiendo recursivamente los siguientes pasos hasta que cada nodo terminal del árbol alcance un número mínimo κ_0 de registros:
        1. Generar una muestra aleatoria simple sin reposición de $\tilde{m}$ variables de las r totales.
        2. Seleccionar la mejor variable entre las $\tilde{m}$ escogidas y el corte que minimice la impureza.
        3. Ramificar el nodo en sus dos nodos hijos
2. Para hacer predicciones sobre nuevos puntos x, consideramos la media de las predicciones de los distintos árboles.

$$\hat{f}_{rf}^{B} = \frac{1}{B}\sum_{b=1}^{B} T_b(x)$$

Se observa que la muestra generada para la construcción de los árboles de regresión de los Bosques Aleatorios se considera con reposición, esto quiere decir que podemos encontramos el mismo registro varias veces y a su vez, registros de la muestra de aprendizaje que no aparezcan en la muestra usada

por el árbol. Estos últimos se conocen como registros *fuera de la bolsa* y nos pueden ser útiles como muestra independiente para estimar el error de predicción del bosque $\frac{1}{B}\sum_b e(T_b)$, siendo

$$e(T_b) = \frac{1}{T}\sum_{t=1}^{T}(y_t - T_b(x_t))^2$$

Luego gracias a los registros fuera de bolsa se construye el estimador de error de predicción del bosque $\frac{1}{B}\sum_b \widehat{e(T_b)}$ mediante el estimador del error de predicción de cada árbol,

$$\widehat{e(T_b)} = \frac{1}{U}\sum_{i=1}^{U}(y_i - T_b(x_i))^2$$

con U el número de elementos en la muestra fuera de bolsa.

A.5.2 Gradient Boosting

B

Apéndice

Resultados y evaluación del modelo estático

En este capítulo se detallan los resultados obtenidos en los distintos experimentos realizados a partir de diferentes procesamientos y configuraciones del dataset inicial. Destacamos tres modelos principales:

- Modelo con todas las variables tras ingeniería de características: Tras el preprocesamiento de los distintos conjuntos de datos (diagnósticos clínicos, procedimientos, histórico de medicamentos y pruebas de laboratorio) y el posterior entrenamiento y evaluación de diversos algoritmos de *Machine Learning*.
- Modelo solo con variables de diagnósticos mapeadas a CIE-10: Tras realizar un mapeo de los diagnósticos clínicos a la nomenclatura CIE-10, se entrenaron y evaluaron los mismos algoritmos para comparar su rendimiento con el modelo anterior.
- Modelo solo con variables de analíticas de laboratorio: Se entrenaron y evaluaron los mismos algoritmos utilizando únicamente las variables relacionadas con las pruebas de laboratorio, para evaluar su capacidad predictiva en comparación con los modelos anteriores.

El objetivo principal de esta fase experimental ha sido encontrar el modelo más preciso y robusto, tratando de evitar los resultados inverosímiles que se obtuvieron en el modelo inicial.

B.1 Modelo tras ingeniería de características.

Se realizó el preprocesamiento de variables médicas descritasen el primer capítulo. En primer lugar, se eliminaron variables reveladoras de cáncer de pulmón y no adecuadas para un cribado general. Posteriormente, se agruparon las variables de diagnóstico y procedimientos usando la extracción y agrupación por ancestros de SNOMED CT. En cuanto a los medicamentos, se realizó un mapeo a la nomenclatura ATC y se agruparon por nivel 2. Finalmente, se seleccionaron las variables de laboratorio más comunes.

Se entrenó un algoritmo *XGBoost* con hiperparámetros por defecto. El rendimiento de este nuevo modelo fue, de nuevo, totalmente ficticio, con métricas extremedamente altas (F1-Score > 0.99).

Tabla A.3: «Métricas de evaluación en modelo tras ingeniería de características completo en conjunto de test.»

Modelo	F1-Score	Precision	Recall
XGBoost	0.99	0.99	0.99

Se analizaron las variables más importantes para el modelo, siendo la edad, género, algunas patologías como la anemia o procedimientos como la citopatología las más relevantes.

Tabla A.4: «Top 5 variables más importantes del modelo tras ingeniería de características.»

Rank	Variable
1	Cytopathology procedure preparation of smear
2	age
3	Sodium
4	Hypertriglyceridemia (disorder)
5	Urine screening for glucose

B.2 Modelo solo con variables de laboratorio.

Se seleccionaros solo variables relacionadas con las pruebas de laboratorio comunes. La lista de variables está compuesta por características numéricas y categóricas, por lo que previamente al preprocesamiento se realizó una separación de estas variables. Las variables numéricas fueron imputadas con con valor constante cero. Posteriormente, se codificaron las variables categóricas y se escalaron las variables.

Por último, se realizó la busqueda de hiperparámetros para los algoritmos *Random Forest*, *SVM*, *XGBoost* y *MLPClassifier*.

B.2.1 Metodología y Búsqueda de Hiperparámetros (Tuning)

Previo a la evaluación final, se ejecutó un proceso sistemático para optimizar los hiperparámetros de diferentes familias de algoritmos y determinar su configuración con mayor capacidad predictiva. Esta validación se realizó aplicando validación cruzada estratificada con 5 particiones (5-Fold Cross-Validation), empleando como métrica de optimización principal el `f1_weighted`. Elegir esta métrica asegura un buen balance penalizando correctamente predicciones desproporcionadas entre clases.

Se evaluaron e iteraron combinaciones para cuatro tipos de modelos:

- **Random Forest**: Se evaluaron 36 combinaciones ajustando el número de árboles estimadores, la profundidad máxima, el mínimo de muestras para la partición y la selección de características.
- **SVM (Máquinas de Vectores de Soporte)**: Se evaluaron 16 combinaciones explorando el parámetro de regularización matemática C, tipos de kernel y su grado.
- **XGBoost (Extreme Gradient Boosting)**: Las pruebas abarcaron alteraciones sobre la ratio de aprendizaje (*learning rate*), reguladores de penalización L1 (`reg_alpha`) y L2 (`reg_lambda`), profundidad de los árboles y porcentajes de submuestreo.
- **MLPClassifier (Red Neuronal Multicapa)**: Dos combinaciones con topología predefinida y variaciones en la tasa de aprendizaje adaptativa.

B.2.2 Rendimiento en el Conjunto de Test

A las las métricas críticas evaluadas (F1-score, Precision y Recall) fueron añadidas nuevas métricas sobre las probabilidades del modelo, como el Área bajo la Curva Operativa del Receptor (ROC-AUC) y el Área Bajo la Curva de Precisión Exhaustiva (PR-AUC). El mejor modelo resultante de esta fase fue el **MLPClassifier**.

Tabla A.5: «Métricas de evaluación en conjunto de test del modelo con variables de laboratorio.»

Modelo	F1-Score	Precision	Recall	ROC-AUC	PR-AUC
MLPClassifier	0.7100	0.7800	0.6600	0.9330	0.8334

Los resultados confirmaron que el modelo basado únicamente en variables de laboratorio tiene un rendimiento significativamente inferior al modelo completo, aunque sigue mostrando una capacidad predictiva razonable teniendo en cuenta que estás tomando solo unas pocas variables muy generales.

No obstante, estos resultados son mucho más realistas y plausibles que los obtenidos en el modelo completo.

B.3 Modelo solo con variables de CIE-10 diagnósticos.

Se realizó un mapeo de los diagnósticos clínicos a la nomenclatura CIE-10, lo que permitió reducir el número de variables y se entrenó un modelo solo con estas variables. Se redujo el número de variables de unas 450 de SNOMED CT a unas 150 de CIE-10.

El modelo está compuesto por un preprocesamiento de las variables de diagnóstico (imputación y codificación) seguido de una selección de características para la reducción a las 25 variables más importantes. Posteriormente, se realizó búsqueda de hiperparámetros para los algoritmos *Random Forest*, *SVM*, *XGBoost* y *MLPClassifier*.

B.3.1 Análisis explaratorio de variables

Estadísticamente, estas variables (al ser binarias) siguen una distribución Bernoulli $X_i \sim Be(p_i)$. Es decir, los pacientes tienen la enfermedad i con probabilidad p_i. Una pregunta lógica es preguntarse si esta probabilidad es diferente en la cohorte.

En las siguientes gráficas se muestra la distribución de las variables de diagnóstico mapeadas a CIE-10 en la cohorte, comparando entre pacientes con cáncer de pulmón y sin cáncer de pulmón. Se observa que todas las variables muestran diferencias marcadas en su distribución, lo cual no suele ocurrir y que explica en parte el inversímil rendimiento de los modelos.

B.3.2 Metodología y Búsqueda de Hiperparámetros (Tuning)

El proceso de optimización de hiperparámetros fue totalmente análogo al descrito en el modelo anterior, aplicando validación cruzada estratificada con 5 particiones y utilizando `f1_weighted` como métrica de optimización. Se evaluaron las mismas combinaciones para los cuatro tipos de modelos, ajustando los hiperparámetros específicos de cada algoritmo.

B.3.3 Rendimiento en el Conjunto de Test

Con las configuraciones óptimas descubiertas, los modelos fueron entrenados de forma final y desplegados sobre un conjunto de test independiente, un entorno de simulación equivalente a operar con datos clínicos nunca antes vistos por el sistema.

A las las métricas críticas evaluadas (F1-score, Precision y Recall) fueron añadidas nuevas métricas sobre las probabilidades del modelo, como el Área bajo la Curva Operativa del Receptor (ROC-AUC) y el Área Bajo la Curva de Precisión Exhaustiva (PR-AUC).

Tabla A.6: «Métricas de evaluación en conjunto de test del modelo con variables de CIE-10.»

Modelo	F1-Score	Precision	Recall	ROC-AUC	PR-AUC
SVM	0.8800	0.8900	0.8800	0.9807	0.9525

B.4 Evaluación del modelo en nuevas cohortes

Usaremos el modelo con resultados más realistas (modelo con variables de laboratorio) para evaluar su rendimiento en nuevas cohortes de pacientes, sin necesidad de reentrenar el modelo. Para ello, se han cargado nuevos conjuntos de datos de pacientes con cáncer de pulmón y sin cáncer de pulmón, y se han aplicado los mismos preprocesamientos que se realizaron en el conjunto de entrenamiento.

C

Apéndice

Atributos reveladores de cáncer de pulmón

C.1 Variables eliminadas por riesgo de data leakage

En el modelo predictivo estático que se describe en el Apéndice A, se eliminaron del conjunto de variables las siguientes columnas por constituir marcadores directos del estado oncológico del paciente. Su presencia habría inflado artificialmente el rendimiento del modelo y no responde a un patrón observable en un cribado general.

Tabla A.7: «Variables y marcadores reveladores de estado oncológico eliminados para prevenir data leakage.»

Código	Descripción
C-33756-8	Polyp size greatest dimension by CAP cancer protocols
C-88040-1	Response to cancer treatment
C-59557-9	Treatment status Cancer
C-21908-9	Stage group.clinical Cancer
C-85318-4	HER2 [Presence] in Breast cancer specimen by FISH
C-85319-2	HER2 [Presence] in Breast cancer specimen by Immune stain
C-85337-4	Estrogen receptor Ag [Presence] in Breast cancer specimen by Immune stain
C-85339-0	Progesterone receptor Ag [Presence] in Breast cancer specimen by Immune stain
C-21924-6	Tumor marker Cancer
C-367336001	Chemotherapy (procedure)
C-703423002	Combined chemotherapy and radiation therapy
C-108290001	Radiation oncology AND/OR radiotherapy
C-385798007	Radiation therapy care
C-597195	Carboplatin 10 MG/ML Injectable Solution
C-583214	Paclitaxel 100 MG Injection
C-1860480	DOCEtaxel 20 MG/ML Injection
C-1734919	Cyclophosphamide 1000 MG Injection
C-429609002	Lung volume reduction surgery
C-88039007	Transplant of lung
C-232657004	Lung Transplant
scc	Squamous Cell Carcinoma Antigen

Referencias

[1] SNOMED International, «SNOMED CT International Edition (consultada en el servidor terminológico HL7 FHIR)». Accedido: 16 de octubre de 2026. [En línea]. Disponible en: https://tx.fhir.org/r4/

[2] LOINC, Accedido: 4 de marzo de 2026. [En línea]. Disponible en: https://loinc.org/

[3] H. Sung *et al.*, «Global cancer statistics 2024: GLOBOCAN estimates of incidence and mortality worldwide for 34 cancers in 186 countries», *CA: A Cancer Journal for Clinicians*, vol. 76, n.º 4, p. e70090, 2026, doi: 10.3322/caac.70090.

[4] Red Española de Registros de Cáncer (REDECAN), «Estimaciones de la incidencia del cáncer en España, 2026». Accedido: 16 de octubre de 2026. [En línea]. Disponible en: https://redecan.org/es/publicaciones/40/redecan-publica-las-estimaciones-de-la-incidencia-del-cancer-en-espana-2026

[5] Instituto Nacional de Estadística (INE), «Estadística de Defunciones según la Causa de Muerte. Año 2024. Datos provisionales». Accedido: 16 de octubre de 2026. [En línea]. Disponible en: https://www.ine.es/dyngs/Prensa/pEDCM2024.htm

[6] Proyecto CASSANDRA (SEPAR), «Hoy en España». Accedido: 16 de octubre de 2026. [En línea]. Disponible en: https://separcontenidos.es/proyectocassandra/equipo

[7] National Cancer Institute, SEER Program, «SEER Cancer Stat Facts: Lung and Bronchus Cancer». Accedido: 16 de octubre de 2026. [En línea]. Disponible en: https://seer.cancer.gov/statfacts/html/lungb.html

[8] National Lung Screening Trial Research Team, D. R. Aberle, A. M. Adams, C. D. Berg, W. C. Black, y others, «Reduced lung-cancer mortality with low-dose computed tomographic screening», *New England Journal of Medicine*, vol. 365, n.º 5, pp. 395-409, 2011, doi: 10.1056/NEJMoa1102873.

[9] H. J. de Koning, C. M. van der Aalst, P. A. de Jong, E. T. Scholten, K. Nackaerts, y others, «Reduced lung-cancer mortality with volume CT screening in a randomized trial», *New England Journal of Medicine*, vol. 382, n.º 6, pp. 503-513, 2020, doi: 10.1056/NEJMoa1911793.

[10] US Preventive Services Task Force, A. H. Krist, K. W. Davidson, C. M. Mangione, y others, «Screening for lung cancer: US Preventive Services Task Force recommendation statement», *JAMA*, vol. 325, n.º 10, pp. 962-970, 2021, doi: 10.1001/jama.2021.1117.

[11] N. Zhou, J. Deng, C. Faltermeier, T. Peng, H. Mandl, y others, «The majority of patients with resectable incidental lung cancers are ineligible for lung cancer screening», *JTCVS Open*, vol. 13, pp. 379-388, 2023, doi: 10.1016/j.xjon.2022.11.021.

[12] M. M. Pasquinelli, M. C. Tammemägi, K. L. Kovitz, M. L. Durham, Z. Deliu, y others, «Addressing sex disparities in lung cancer screening eligibility: USPSTF vs PLCOm2012 criteria», *Chest*, vol. 161, n.º 1, pp. 248-256, 2022, doi: 10.1016/j.chest.2021.06.066.

[13] M. C. Tammemägi, H. A. Katki, W. G. Hocking, T. R. Church, N. Caporaso, y others, «Selection criteria for lung-cancer screening», *New England Journal of Medicine*, vol. 368, n.º 8, pp. 728-736, 2013, doi: 10.1056/NEJMoa1211776.

[14] Z. Che, S. Purushotham, K. Cho, D. Sontag, y Y. Liu, «Recurrent Neural Networks for Multivariate Time Series with Missing Values», *Scientific Reports*, vol. 8, n.º 1, p. 6085, 2018, doi: 10.1038/s41598-018-24271-9.

[15] S. Tipirneni y C. K. Reddy, «Self-supervised transformer for sparse and irregularly sampled multivariate clinical time-series», *ACM Transactions on Knowledge Discovery from Data*, vol. 16, n.º 6, pp. 1-17, 2022, doi: 10.1145/3516367.

[16] J. L. Katzman, U. Shaham, A. Cloninger, J. Bates, T. Jiang, y Y. Kluger, «DeepSurv: Personalized treatment recommender system using a Cox proportional hazards deep neural network», *BMC Medical Research Methodology*, vol. 18, n.º 1, p. 24, 2018, doi: 10.1186/s12874-018-0482-1.

[17] D. Jarrett, J. Yoon, y M. van der Schaar, «Dynamic prediction in clinical survival analysis using temporal convolutional networks», *IEEE Journal of Biomedical and Health Informatics*, vol. 24, n.º 2, pp. 424-436, 2020, doi: 10.1109/JBHI.2019.2929264.

[18] H. C. van Houwelingen, «Dynamic prediction by landmarking in event history analysis», *Scandinavian Journal of Statistics*, vol. 34, n.º 1, pp. 70-85, 2007, doi: 10.1111/j.1467-9469.2006.00529.x.

[19] Fundació Institut de Recerca de l'Hospital de la Santa Creu i Sant Pau, «Lung cancer screening pilot programme: Cancer Screening Smoking Cessation and Respiratory Assessment (CASSANDRA)». Accedido: 16 de octubre de 2026. [En línea]. Disponible en: https://clinicaltrials.gov/study/NCT06157957

[20] Sociedad Española de Neumología y Cirugía Torácica (SEPAR), «Proyecto CASSANDRA. Cribado del cáncer de pulmón mediante TC de baja dosis». Accedido: 16 de octubre de 2026. [En línea]. Disponible en: https://www.separ.es/proyecto-cassandra

[21] Proyecto CASSANDRA (SEPAR), «Web oficial del Proyecto CASSANDRA». Accedido: 17 de octubre de 2026. [En línea]. Disponible en: https://separcontenidos.es/proyectocassandra/

[22] B. Diego, «El cribado de cáncer de pulmón da sus primeros pasos con el Proyecto Cassandra». Accedido: 17 de octubre de 2026. [En línea]. Disponible en: https://diariofarma.com/2025/06/16/el-cribado-de-cancer-de-pulmon-da-sus-primeros-pasos-con-el-proyecto-cassandra

[23] J. Walonoski, M. Kramer, J. Nichols, A. Quina, C. Moesel, y others, «Synthea: An approach, method, and software mechanism for generating synthetic patients and the synthetic electronic health care record», *Journal of the American Medical Informatics Association*, vol. 25, n.º 3, pp. 230-238, 2018, doi: 10.1093/jamia/ocx079.

[24] MITRE Corporation, «Synthea: Synthetic patient generator (repositorio de código)». Accedido: 16 de octubre de 2026. [En línea]. Disponible en: https://github.com/synthetichealth/synthea

[25] A. Chen y D. O. Chen, «Simulation of a machine learning enabled learning health system for risk prediction using synthetic patient data», *Scientific Reports*, vol. 12, n.º 1, p. 17917, 2022.

[26] A. J. Chen, «Medical records of 30K Synthea synthetic patients». Harvard Dataverse, 2022. doi: 10.7910/DVN/BWDKXS.

[27] U.S. National Library of Medicine, «SNOMED CT to ICD-10-CM Map». Accedido: 16 de octubre de 2026. [En línea]. Disponible en: https://www.nlm.nih.gov/research/umls/mapping_projects/snomedct_to_icd10cm.html

[28] The Tuva Project, «SNOMED-CT to ICD-10 Map». Accedido: 16 de octubre de 2026. [En línea]. Disponible en: https://www.thetuvaproject.com/terminology/snomed-to-icd10-map

[29] F. Mölder, K. P. Jablonski, B. Letcher, M. B. Hall, y others, «Sustainable data analysis with Snakemake», *F1000Research*, vol. 10, p. 33, 2021, doi: 10.12688/f1000research.29032.2.

[30] D. R. Cox, «Regression Models and Life-Tables», *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 34, n.º 2, pp. 187-202, 1972, doi: 10.1111/j.2517-6161.1972.tb00899.x.

[31] N. E. Breslow, «Covariance Analysis of Censored Survival Data», *Biometrics*, vol. 30, n.º 1, pp. 89-99, 1974, doi: 10.2307/2529620.

[32] S. Hochreiter y J. Schmidhuber, «Long Short-Term Memory», *Neural Computation*, vol. 9, n.º 8, pp. 1735-1780, 1997, doi: 10.1162/neco.1997.9.8.1735.

[33] F. E. Harrell, K. L. Lee, y D. B. Mark, «Multivariable prognostic models: issues in developing models, evaluating assumptions and adequacy, and measuring and reducing errors», *Statistics in Medicine*, vol. 15, n.º 4, pp. 361-387, 1996, doi: 10.1002/(SICI)1097-0258(19960229)15:4<361::AID-SIM168>3.0.CO;2-4.

[34] P. Blanche, J.-F. Dartigues, y H. Jacqmin-Gadda, «Estimating and comparing time-dependent areas under receiver operating characteristic curves for censored event times with competing risks», *Statistics in Medicine*, vol. 32, n.º 30, pp. 5381-5397, 2013, doi: 10.1002/sim.5958.

[35] H. Uno, T. Cai, M. J. Pencina, R. B. D'Agostino, y L. J. Wei, «On the C-statistics for evaluating overall adequacy of risk prediction procedures with censored survival data», *Statistics in Medicine*, vol. 30, n.º 10, pp. 1105-1117, 2011, doi: 10.1002/sim.4154.

[36] E. Graf, C. Schmoor, W. Sauerbrei, y M. Schumacher, «Assessment and comparison of prognostic classification schemes for survival data», *Statistics in Medicine*, vol. 18, n.º 17–18, pp. 2529-2545, 1999, doi: 10.1002/(SICI)1097-0258(19990915/30)18:17/18<2529::AID-SIM274>3.0.CO;2-5.

[37] T. A. Gerds y M. Schumacher, «Consistent Estimation of the Expected Brier Score in General Survival Models with Right-Censored Event Times», *Biometrical Journal*, vol. 48, n.º 6, pp. 1029-1040, 2006, doi: 10.1002/bimj.200610301.

[38] M. W. Kattan y T. A. Gerds, «The index of prediction accuracy: an intuitive measure useful for evaluating risk prediction models», *Diagnostic and Prognostic Research*, vol. 2, n.º 1, p. 7, 2018, doi: 10.1186/s41512-018-0029-2.

[39] Ministerio de Sanidad, «Definición de SNOMED CT». Accedido: 5 de marzo de 2026. [En línea]. Disponible en: https://www.sanidad.gob.es/areas/saludDigital/interoperabilidadSemantica/factoriaRecursos/snomedCT/home.htm

[40] RxNorm, Accedido: 4 de marzo de 2026. [En línea]. Disponible en: https://www.nlm.nih.gov/research/umls/rxnorm/index.html

[41] SNOMED International, «SNOMED CT Browser». Accedido: 5 de marzo de 2026. [En línea]. Disponible en: https://browser.ihtsdotools.org/?perspective=full&conceptId1=404684003&edition=MAIN/SNOMEDCT-ES/2026-02-10&release=&languages=es,en

[42] Organización Mundial de la Salud, «Clasificación Internacional de Enfermedades (CIE-10)». Accedido: 2 de mayo de 2026. [En línea]. Disponible en: https://www.eciemaps.sanidad.gob.es/browser/metabuscador

[43] Vademecum, «Clasificación ATC». Accedido: 5 de marzo de 2026. [En línea]. Disponible en: https://www.vademecum.es/atc